开放世界知识图谱关系候选排序的可审计结构反事实对比学习

Anonymous authors
Paper under double-blind review

Abstract

生成式知识图谱关系预测需要来源可追溯、能够提供关系辨别信号的训练候选。本文提出结构反事实对比学习（Structure-Counterfactual Contrastive Learning, SC-CL），融合训练图关系画像与冻结基线的分数违例度，在过滤训练已知关系后构建固定候选库，并联合优化候选级 InfoNCE 与原始生成目标。在三个数据集的单种子本地评估中，验证选定配置相对匹配 B1 的直接解码 EM 高 2.24–8.03 个百分点；该比较包含 Stage 2 调参，不能隔离采样机制。FB15K237-2 固定配置对照中，Full 达到 89.90%，均匀随机为 86.48%，而保留 Full 逐题训练频率桶配额的随机对照达到 89.83%，仅差 0.07 个百分点。按训练关系频率分层后，Full 在低频组未显示优势。上述结果表明，需要分别评价具体候选身份与其诱导的频率组成；当前证据支持可追溯的候选学习流程与条件性性能观察，尚未建立超出频率配额匹配的独有联合选择收益。

1 引言

给定实体对及其图上下文，关系预测需要识别相应的关系标签。GRIP 将图结构融入语言模型参数，通过生成式问答完成这一任务 (Feng et al., 2026)。候选级对比学习让目标关系与替代关系直接竞争，而候选选取决定模型接收到哪些关系辨别信号。因此，需要同时研究候选如何构造，以及观测差异究竟来自具体候选身份还是其统计组成。

训练图的关系统计能够描述关系间的结构接近程度，模型分数能够揭示已有的关系混淆；两者都可能改变候选的频率分布。知识图谱的不完整性还要求区分学习用途与事实真值：未标注关系在开放世界中保留未判定状态。本文研究如何将结构与模型反馈用于可追溯的候选构造，并通过来源替换和条件匹配对照界定其性能解释。

为此，我们提出结构反事实对比学习（SC-CL）。它以训练图关系画像刻画统计接近程度，以冻结的 generation-only 基线 B1 分数违例度刻画模型混淆，共同决定带均匀下限的采样分布；在过滤实体对训练已知关系后固定候选库。SC-CL 接入 GRIP Stage 2，联合优化候选级 InfoNCE 与原始生成目标，沿用 Stage 1 和原始提示。本文的结构反事实操作是在固定实体对上替换关系标签，构造与学习流程见图 1。

在 NELL23K、CoDEx-M 和 FB15K237-2 的单种子完整测试中，验证选定的 Stage 2 配置相对本地 B1 获得更高的直接解码 EM；这一比较包含训练调参，不能单独识别候选机制。为进一步分析候选来源，我们在 FB 固定 Full 配置下比较均匀随机、Profile-only、Violation-only 和保留 Full 逐题频率配额的随机对照。Full 的 89.90% 高于均匀随机的 86.48%，但与配额匹配组的 89.83% 仅差 0.07 个百分点；低频关系上也未显示 Full 优势。因此，候选构造的双信号设计与其独有性能收益需要分开评价。

本文的贡献包括三个方面：定义结构画像与冻结模型违例度共同驱动的固定候选分布；构建包含训练已知关系过滤及逐候选来源记录的可追溯学习流程；通过完整测试、固定配置的候选来源对照和训练频率分层分析，区分模型配置收益与当前证据尚未建立的独有机制收益。历史 NELL 候选重排作为独立模型的补充证据保留，直接解码与重排采用各自的评价规则。

2 相关工作

关系预测与生成式图推理。 TransE、ComplEx、RotatE 和 ConvE 通过不同的三元组打分函数建模实体与关系 (Bordes et al., 2013; Trouillon et al., 2016; Sun et al., 2019; Dettmers et al., 2018)。KG-BERT 将三元组判断转为文本建模 (Yao et al., 2019)，SimKGC 在预训练语言模型上使用多种实体负例进行对比学习 (Wang et al., 2022)。GRIP 以图上下文和生成式问答学习参数化图推理，并比较图到嵌入方法 OFA/GOFA 与有无边列表上下文的 Qwen/Llama；其知识图谱结果同时报告准确率和输入 token 数 (Feng et al., 2026)。这些方法界定了关系预测的外部参照面，但不能替代对候选构造作用的同协议检验。本文关注固定实体对上的关系标签竞争，在 GRIP 的生成式训练框架中研究候选来源与候选级对比目标的结合；相关原文数值与本地比较边界见表 1。

困难候选与假阴性。 结构感知负采样 SANS 和对抗式采样 KBGAN 分别从图结构与模型反馈寻找困难负例 (Ahrabian et al., 2020; Cai & Wang, 2018)。去偏对比学习与 ProGCL 讨论了对比学习中候选难度和假阴性风险的关系 (Chuang et al., 2020; Xia et al., 2022)。SC-CL 将训练图关系画像与冻结模型的分数违例度共同用于关系候选构造，并以训练已知关系过滤、均匀采样下限和固定候选库明确候选的构造规则。本文采用的开放世界真值约定见问题定义节。

关系候选评估。 传统 link prediction 常在实体替换候选上报告 MRR/Hits，CoDEx 还提供经过人工核验的实体替换困难负例 (Safavi & Koutra, 2020)。实体替换与关系替换对应不同的候选空间。本文在固定实体对上评价关系标签排序，并分别使用直接解码与逐候选评分衡量两种答案选择方式；实体替换负例保留其三元组判断用途，关系候选按各自的已知事实与未判定状态记录。

3 问题定义

3.1 训练图与候选关系

令训练知识图谱为 $\mathcal{G}_{\text{tr}} = (\mathcal{V}, \mathcal{E}_{\text{tr}})$，其中 $\mathcal{E}_{\text{tr}} \subseteq \mathcal{V} \times \mathcal{R}_{\text{tr}} \times \mathcal{V}$，$\mathcal{R}_{\text{tr}}$ 是训练关系词表。一个关系问答样本表示为 $q = (h, t, r^+)$，其中 r^+ 是目标关系，h, t 是有序实体对。定义同一实体对在训练图中的已知关系集合为

$$T_{\text{tr}}(h, t) = \{r : (h, r, t) \in \mathcal{E}_{\text{tr}}\}. \tag{1}$$

候选池为

$$P_q = \mathcal{R}_{\text{tr}} \setminus \big(\{r^+\} \cup T_{\text{tr}}(h, t)\big). \tag{2}$$

式 2 从训练关系词表中排除目标关系和该实体对的已知训练关系。其余关系作为真值未判定的训练替代项，遵循知识图谱的开放世界假设 (Ji et al., 2022; Hogan et al., 2021)。本文的结构反事实操作固定实体对 (h, t)，将目标关系替换为 $r \in P_q$；“负候选”表示其在对比目标中的角色，事实真值保持未判定。

3.2 答案选择与候选学习目标

本文区分两种答案选择规则。直接解码在列出十个关系选项的题目上输出关系文本，以 Exact Match（EM）评价原始解码路径下的预测。候选重排给定同一题目的候选集合，用关系续接分数（continuation score）$z_\theta(q, r)$ 逐项排序，以 Hits@1（H@1）、H@3 和 MRR 评价候选间的关系辨别。重排 H@1 等于按最高分选项计算的 EM。两种规则分别报告，模型间的表现差异采用相同答案选择规则比较。

给定冻结 bank $B(q) = \{r_1^-, \ldots, r_K^-\}$，候选损失写为

$$\mathcal{L}_{\text{cand}}(q) = -\log \frac{\exp(z_\theta(q, r^+)/\tau_c)}{\exp(z_\theta(q, r^+)/\tau_c) + \sum_{k=1}^{K} \exp(z_\theta(q, r_k^-)/\tau_c)}. \tag{3}$$

其中 τ_c 是候选温度。训练阶段联合优化原始生成损失 $\mathcal{L}_{\text{gen}}$ 与候选损失：

$$\mathcal{L} = \mathcal{L}_{\text{gen}} + \lambda_{\text{cand}} \mathcal{L}_{\text{cand}}. \tag{4}$$

SC-CL 沿用 Stage 1 和生成目标，将新增训练项明确为候选级 InfoNCE。

4 结构反事实对比学习

SC-CL 将候选构造与 Stage 2 优化分为两个阶段（图 1）。离线阶段融合训练图关系画像与冻结 B1 在训练问题上的违例度，在过滤后的关系池中采样并固定每题九个候选。学习阶段从 Stage 1 adapter 初始化 GRIP，在固定候选库上联合优化候选损失与原始生成损失。

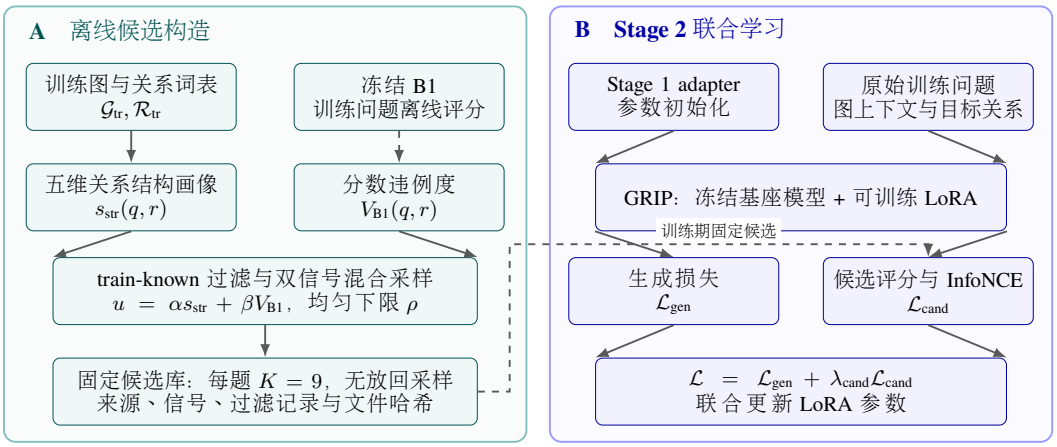


Figure 1: SC-CL 的候选构造与联合学习。A：训练图结构画像与冻结 B1 违例度共同指导采样，train-known 过滤与无放回采样形成每题 $K = 9$ 的固定候选库。B：Stage 2 从 Stage 1 adapter 初始化，联合优化生成损失与加权候选 InfoNCE；冻结 B1 为离线候选构造提供评分。

4.1 训练图关系画像

对每一个 $r \in \mathcal{R}_{\text{tr}}$，我们从 $\mathcal{E}_{\text{tr}}$ 计算五维关系画像

$$\phi(r) = \big(\log(1+|E_r|), \log(1+|H_r|), \log(1+|T_r|), \log(1+\bar{d}_{H,r}), \log(1+\bar{d}_{T,r})\big), \tag{5}$$

其中 $|E_r|$ 为关系边数，$|H_r|$ 和 $|T_r|$ 分别为关系覆盖的头实体数与尾实体数，$\bar{d}_{H,r} = |H_r|^{-1}\sum_{h\in H_r} d_{\text{out}}(h)$ 是不同头实体在训练图中的平均出度，$\bar{d}_{T,r} = |T_r|^{-1}\sum_{t\in T_r} d_{\text{in}}(t)$ 是不同尾实体的平均入度。五个统计量均使用 $\log(1+x)$ 压缩尺度；度数对训练图全部关系计算。

对目标关系 r^+ 和候选 r，定义归一化结构相似度

$$s_{\text{str}}(q,r) = 1 - \frac{1}{5}\sum_{j=1}^{5}\frac{|\phi_j(r^+) - \phi_j(r)|}{1 + |\phi_j(r^+)| + |\phi_j(r)|}, \tag{6}$$

分母中的常数 1 保证非零，分数裁剪到 $[0,1]$。该分数衡量五维图统计画像的接近程度；实体对的已知关系由式 2 单独过滤。

4.2 冻结 B1 的边界违例度

B1 是原始 GRIP 的 generation-only 基线。我们在训练问题上离线计算全关系词表的 continuation score。若离线记录已有 pairwise confusion，则直接使用裁剪到 $[0,1]$ 的 confusion；否则对候选和正关系的分数差使用平滑违例度

$$V_{\text{B1}}(q,r) = \sigma\left(\frac{z_{\text{B1}}(q,r) - z_{\text{B1}}(q,r^+)}{\tau_v}\right). \tag{7}$$

候选分数越接近或超过正关系，V_{B1} 越大。B1 在训练问题上的离线分数于候选库构造时固定，提供与 Stage 2 参数更新分离的候选评分依据。

4.3 结构反事实候选分布

将结构相似度和分数违例度合成为

$$u(q,r) = \alpha s_{\text{str}}(q,r) + \beta V_{\text{B1}}(q,r), \qquad r \in P_q. \tag{8}$$

候选分布使用均匀下限与 utility softmax 的混合：

$$p(r \mid q) = \frac{\rho}{|P_q|} + (1-\rho)\frac{\exp(u(q,r)/\tau_s)}{\sum_{r' \in P_q} \exp(u(q,r')/\tau_s)}. \tag{9}$$

我们从 $p(r \mid q)$ 无放回抽取 $K = 9$ 个负候选。主实验参数为 $\rho = 1/3$、$\alpha = 1$、$\beta = 1$、$\tau_s = 0.25$。当 $|P_q| < K$ 时，记录该样本及候选不足原因，保持每个有效样本的候选互异性；实验报告候选构造失败数。

结构反事实操作在固定实体对上替换关系标签，其候选池与开放世界真值约定见问题定义节。

4.4 固定候选库与来源追溯

SC-CL 为每个训练问题记录问题标识、目标关系、九个候选及其结构相似度、违例度、utility 和 B1 score gap，并保存采样参数、数据划分与已知关系过滤记录。候选库遵循四项来源约束：

1. 问题来源和已知关系过滤均使用训练划分；
2. 每个样本恰有一个正关系和 $K = 9$ 个互异候选，候选均属于 $\mathcal{R}_{\text{tr}}$；
3. 候选与 $T_{\text{tr}}(h,t)$ 不相交，问题标识与训练任务一一对齐；
4. 候选库哈希、脚本版本、随机种子和采样参数写入来源清单，构造后的候选库在训练中保持固定。

训练时，候选 continuation score 代入式 3，生成损失沿用原始 GRIP 路径计算。两项损失按式 4 共同优化 Stage 2 的 LoRA 参数。

4.5 计算复杂度与离线构造

关系画像通过一次线性扫描训练边得到，复杂度为 $O(|\mathcal{E}_{\text{tr}}|)$。给定离线模型分数后，每个问题在关系词表上计算 utility，复杂度为 $O(|\mathcal{R}_{\text{tr}}|)$；采样后的候选库大小为 $O(K|Q_{\text{tr}}|)$，其中 Q_{tr} 为训练问题集合。计算过程包括训练图统计、冻结 B1 离线评分和 Stage 2 联合训练；分阶段资源记录见第 B.6 节。

5 实验与结果

5.1 评价设置与比较层次

本文以 NELL23K、CoDEx-M 和 FB15K237-2 的完整测试直接解码结果评价本地训练配置，并在 FB 上进一步固定训练设置、替换候选来源。基座均为 Qwen2.5-7B-Instruct，训练种子为 2026。直接解码在列出十个关系选项的题目上生成关系文本，按 Exact Match（EM）计分；模型间核对问题标识、提示、选项顺序和目标，报告同题差异。训练候选仅来自训练关系词表，并过滤相同实体对上的训练已知关系。

两层比较回答不同问题。三数据集比较展示验证选定的 Stage 2 配置与本地 generation-only B1 的结果；配置搜索及部分优化设置同时变化，不能将差异单独归因于候选损失。FB 候选来源对照则复用获选 Full 配置，固定训练 QA、Stage 1、损失、LoRA 及优化设置，只替换冻结候选库。后者估计该配置下的候选替换差异，不是各方法等预算调参后的最优性能比较。历史 NELL 候选重排使用独立模型，见附录 B；WN18RR 补充结果见附录 A.2。重排指标与本节直接解码 EM 分别解释。

原始 GRIP 将图到嵌入方法 OFA/GOFA，以及无上下文或附加边列表上下文的 Qwen/Llama 作为外部比较系统；其表格报告十选一准确率和平均输入 token 数。表 1转录这些已发表结果，并保留原文 GRIP 模型作为候选学习方法所依托的外部参照。该文献表不替代本地同题 B1 和候选来源控制：尤其是本文的 FB15K237-2 为 10,000 题子集，且跨来源的提示及候选身份没有逐题核验，因此不从文献数值计算 SC-CL 的增益。

Table 1: GRIP 原文知识图谱关系预测的已发表比较结果。单元依次为准确率（%）/平均输入 token 数。

方法（原文设置）	NELL23K	CoDEx-M	FB15K237
图到嵌入基线			
OFA	–	–	70.84 / 1304.90
GOFA	–	–	80.69 / 1304.90
无显式图上下文的语言模型			
Qwen-7B	77.38 / 160.80	83.09 / 124.21	79.65 / 155.74
Llama-8B	20.05 / 160.33	71.03 / 124.61	56.66 / 152.75
提供边列表上下文的语言模型			
Qwen-7B + context	81.38 / 590.37	73.32 / 1055.29	79.19 / 1330.56
Llama-8B + context	53.33 / 586.15	47.46 / 1044.44	44.68 / 1304.90
GRIP 参数内化模型			
GRIP-Qwen-7B	87.74 / 160.80	94.42 / 124.21	88.75 / 155.74
GRIP-Llama-8B	77.40 / 160.33	91.58 / 124.61	77.79 / 152.75
完整图上下文	OOC / $>$ 0.5M	OOC / $>$ 5M	OOC / $>$ 10M

数据转录自 GRIP 论文表 2–3 (Feng et al., 2026)。准确率为十选一缺失关系预测的精确匹配；第二项为平均输入 token 数。GRIP 论文注明 OFA/GOFA 数值取自其原论文；“–”表示原文未报告该数据集结果，OOC 表示完整图序列超出上下文窗口。
此表是已发表文献结果，不是本地复现实验。原文使用标准 FB15K237；本文本地 FB15K237-2 为 10,000 题子集，且不同来源的逐题提示与候选身份尚未逐项核验。因此本表用于说明既有方法与输入成本，不计算相对 SC-CL 的直接增益；同协议主比较见表 2和表 3。

5.2 三数据集完整测试结果

表 2给出验证选定模型的完整测试结果。NELL23K、CoDEx-M 和 FB15K237-2 相对匹配 B1 分别净增加 159、231 和 803 题正确预测，对应 3.22、2.24 和 8.03 个百分点。这些数值描述单种子本地协议下的模型配置表现，不是严格原论文复现、多种子统计或纯采样机制的隔离收益。

Table 2: 三数据集本地协议的完整测试直接解码结果（%，seed=2026）。B1 与方法的问题、选项顺序和目标对齐；方法为验证选定的 Stage 2 配置。Δ 为方法减 B1 的百分点差。训练调参及部分优化设置同时变化，故该表不隔离候选损失或采样机制。

数据集	n	B1 EM	SC-CL EM	Δ (pp)	净增题数
NELL23K	4,943	84.58	87.80	+3.22	+159
CoDEx-M	10,311	94.34	96.58	+2.24	+231
FB15K237-2	10,000	81.87	89.90	+8.03	+803

5.3 FB 固定配置下的候选来源对照

FB 各组共享 12,136 条训练 QA，其中 3,109 条具备候选损失资格，每题九个候选。均从相同 Stage 1 初始化，实际训练 32 个优化步，并保持原五轮、120 步线性学习率调度。Full 配置由验证集预先选定；后续对照的第 32 步模型在测试前固定，不根据测试结果重采候选、换种子或延长训练。每个新组仅执行一次完整测试；单信号及配额匹配组不再执行全量验证。具体设置见附录 A.7。

均匀随机组从同一合法池无放回抽取九个关系。Profile-only 保留结构项并移除 B1 违例项，Violation-only 保留 B1 违例项并移除结构项；其余采样参数与 Full 一致。表 3显示 Full 的 EM 为 89.90%，高于均匀随机的 86.48%，并分别高于 Violation-only 和 Profile-only 2.81 和 5.01 个百分点。Profile-only 为 84.89%，低于均匀随机 1.59 个百分点。因此，该固定配置下的单信号差异不能被概括为结构画像单独使用总有收益。

保留 **Full** 频率配额的条件随机对照。 令 $f(r)$ 为关系 r 在训练图中的边数，固定频率桶 $b(r) = \lfloor \log_2 f(r) \rfloor$。对每道训练题，先记录 Full 九个候选对应的桶序列，再从同桶合法池内均匀无放回抽取替代关系，保持逐题桶配额和槽位桶不变。3,109 题全部匹配，未跨桶回退；其候选集合均不同于 Full，平均每题共享 0.635 个原候选。27,981 个抽样槽位中 82 个因桶池大小等于配额而被迫选定。该对照保留的是 *Full* 诱导的逐题频率配方，不是独立于 Full 的一般频率采样器；也不要求桶内具体边数或 B1 困难度相同。

Table 3: FB15K237-2 候选来源对照（10,000 题，直接解码 EM，seed=2026）。各组使用同一 Stage 1、训练 QA、合法池、$K = 9$、损失与优化设置，固定 32 步并保持 120 步调度。Δ 为 Full 减该行。配额匹配组继承 Full 逐题频率桶配额，并非独立通用频率采样器；本表不提供跨种子不确定性或统计等效结论。

候选来源	正确数	EM (%)	Δ (pp)
Full SC-CL-9	8,990	89.90	+0.00
均匀随机-9	8,648	86.48	+3.42
Profile-only-9	8,489	84.89	+5.01
Violation-only-9	8,709	87.09	+2.81
Full 配额匹配随机-9	8,983	89.83	+0.07

配额匹配随机组达到 89.83% EM，相对均匀随机提高 3.35 个百分点，与 Full 仅差 0.07 个百分点、净 7 题。这说明均匀随机对照不足以识别 Full 在其诱导频率桶分布之外的额外收益。频率分布仍是需要保留的替代解释；该结果既不证明频率造成全部收益，也不证明结构信息无效或两模型统计等效。配额从 Full 候选库提取，本身携带 Full 的选择信息。

5.4 配对变化与频率分层

表 4并列报告纠错和退化。Full 与配额匹配组共同正确 8,642 题、共同错误 669 题，另有 348 题仅 Full 正确、341 题仅配额匹配组正确。总体 EM 接近仍伴随 689 题判定变化，需要进一步检查其分布。

Table 4: FB 同 10,000 题上的配对变化。纠错表示左侧方法正确、右侧错误，退化为相反情况；净变化为纠错减退化。

比较方向	纠错	退化	净变化
Full − 均匀随机	553	211	+342
Full − Profile-only	755	254	+501
Full − Violation-only	582	301	+281
Full − 配额匹配随机	348	341	+7
配额匹配 − 均匀随机	534	199	+335

为检查总体净差是否掩盖不同频率关系上的相反变化，我们按训练关系词表中各关系边数的三分位次序统计量定义低、中、高频组，同频次不拆分；两条边界为 215 和 689。边界仅由训练图决定，不按测试正确率调整。测试问题按目标关系的训练频次归组，所有 10,000 题均纳入，覆盖 215 个测试中出现的训练关系。该分析是在总体结果观察后的描述性分析，不构成独立确认性检验。

Table 5: 按目标关系训练边数划分的 FB 描述性配对分析。边界为训练关系词表频次的三分位次序统计量，同频次不拆分；未按测试表现调边界。EM 单位为%；配额匹配指 Full 配额匹配随机。所有分组均报告，净变化合计为 7 题，不构成跨种子或因果证据。

目标关系频率	n	Full EM	配额匹配 EM	纠错	退化	净变化
低频（≤ 215）	412	60.92	65.05	24	41	-17
中频（216–689）	1089	82.74	82.64	51	50	+1
高频（> 689）	8499	92.22	91.95	273	250	+23

低频组的 412 题中，Full 相对配额匹配组纠错 24 题、退化 41 题，净减少 17 题（-4.13 个百分点）；中频组净增加 1 题，高频组净增加 23 题。因此，当前数据不支持 Full 在低频关系上的补偿性优势。高频组占测试题目的 84.99%，按题等权的总体 EM 与按关系等权的结果可能不同。以测试中出现的关系等权平均 EM，Full 为 75.21%，配额匹配组为 76.15%；各方法的完整分层及关系平均结果见附录表 9。这些观察说明需要同时报告问题分布与关系分布，不能将总体微小正差外推为所有频率层级的收益。

5.5 比较条件与可追溯性

FB 五组共同使用 464 条训练实体对关系 QA 修复。验证用于开发及 Full 配置选择，既有测试暴露历史不因后续固定对照而消除；NELL 开发也存在先前测试暴露和验证 few-shot 使用。NELL 方法与其 B1 的 Adam epsilon 不同，CoDEx-M 方法与 B1 的微批大小不同；三数据集配置差异在解释主表时保留。表 1只作为外部文献参照，不与本地配对结果混算；本文也不报告未运行种子的均值、方差或显著性。

候选库保存逐题关系、训练频次、结构相似度、B1 违例度和过滤依据；运行保留冻结代码与输入身份、四个训练检查点及优化器和随机状态、训练与评测日志、原始响应和逐题正确标记。FB 五方法的 50,000 条判定及配对汇总均按相同 EM 规则复核。来源审计使这些比较可追溯，但不等于其余候选在开放世界中都已被确认为假关系，真值分类见附录 A.4。

6 讨论

候选身份与候选分布需要分开检验。 FB 的单信号消融显示，在既有 Full 配置下移除任一项都会降低直接解码 EM；然而，保留 Full 逐题频率配额后随机替换关系，获得了接近 Full 的 89.83%。两类结果可以同时成立：单信号替换不仅改变候选关系身份，也改变候选的频率组成。因而，Full 相对 Violation-only 的 2.81 个百分点差异是条件性组件差异，不能自动被解释为排除频率因素后的独有结构收益。

配额匹配对照继承了什么。 配额由 Full 候选库逐题提取，因而保留了结构与模型反馈所诱导的一部分选择信息。桶内随机化检验的是保留这一粗粒度组成后，精确选择关系身份带来多少额外差异。它没有移除全部结构信息，也不是无需 Full 候选库的一般频率算法。因此，结果收窄的是当前直接解码证据能够支持的机制主张，不支持频率决定全部收益或结构无效的因果结论。

总体接近不代表各关系层级一致。 689 题的判定变化在低、中、高频组并不均匀。Full 在低频组净减少 17 题，高频组净增加 23 题；按关系等权的平均 EM 也低于配额匹配组。当前数据没有显示长尾关系上的补偿性优势。训练图关系频次仅描述该关系的边数，不等同于训练 QA 数量、实体稀疏度或结构语义质量；这些分层差异需要在更多种子和独立配置中验证。

性能观察与方法适用范围。 三数据集主表展示的是验证选定配置相对本地 B1 的单次表现，不能隔离优化配置与候选训练的贡献。FB 固定配置对照进一步限定候选选择解释；其结论尚不能推广到 NELL 或 CoDEx-M 的随机及频率控制。历史 NELL 重排比较限于同候选前 200 题，完整 B1 重排仍缺失；闭集排序与直接解码的结果也不能相互替代。多种子、完整持出正例重叠与未知真值风险审计均有待补齐。

固定候选库的价值与代价。 固定候选库将离线评分、候选构造与 Stage 2 优化分开，使每种来源替换及其频率组成能够被复核。它需要离线 B1 全关系评分的预处理，并固定训练期间的候选分布；历史分阶段成本见附录 B.6。本文的可追溯训练接口和条件对照提供了分析候选来源的手段；独有性能优势仍需相应证据，不能由来源审计本身推出。

7 结论

本文提出 SC-CL，将训练图关系画像与冻结模型违例度纳入带训练已知关系过滤的固定候选构造流程，并用于 GRIP 候选级对比学习。三个数据集的单种子完整测试展示了验证选定配置相对本地 B1 的直接解码差异。FB 固定配置对照中，Full 高于均匀随机和两个单信号组，但与保留其逐题频率桶配额的随机对照仅差 0.07 个百分点；低频关系分层亦未显示 Full 优势。因此，当前证据支持可追溯的候选学习流程及有条件的性能观察，尚不足以支持超出其诱导频率分布的独有联合选择收益。候选来源、频率组成和答案选择规则需要共同报告，才能界定开放世界关系候选学习的实际效果与适用范围。

A 补充设置、结果与候选审计

A.1 历史 NELL 排序模型的运行设置

表 6 根据附录 B的历史 NELL23K 排序运行配置和候选库元数据列出实际设置。Stage 2 从 Stage 1 adapter 初始化，优化候选级 InfoNCE 与生成损失。采样温度 τ_s 控制候选分布，候选温度 τ_c 控制对比目标。

Table 6: 历史 NELL23K 排序运行设置；不是正文验证选定的直接解码配置。数值对应训练种子 2026 的已完成运行。

字段	设置
基座模型	Qwen2.5-7B-Instruct
候选数 K	9
均匀混合系数 ρ	$1/3$
结构权重 α / 违例权重 β	1.0 / 1.0
采样温度 τ_s	0.25
候选损失温度 τ_c	1.0
候选损失权重 λ_{cand}	1.0
LoRA rank / alpha	4 / 8
LoRA 目标模块	`down_proj`, `up_proj`, `gate_proj`
Stage 2 轮数 / 优化步数	10 / 240
学习率 / 权重衰减	10^{-3} / 10^{-4}
单设备批大小 / 梯度累积步数	1 / 512
计算精度	bfloat16
候选库随机种子 / 训练种子	2026 / 2026
候选来源与过滤	train-only

A.2 WN18RR 直接解码补充结果

WN18RR 的训练期候选库覆盖 2,709 条关系问题，每题包含九个互异候选，构造失败数为 0；来源检查记录为 train-only 且与任务问题对齐。在训练种子 2026 下，使用完整验证集选择候选损失权重 $\lambda_{\text{cand}} = 0.25$，获选模型在 3,134 条测试问题上的直接解码 EM 为 86.89%，训练为 5 个 epoch、125 个优化步。

同一测试文件上的本地 B1 直接解码 EM 为 32.67%。该本地基线与原始 GRIP 报告的五次运行均值 64.30% 存在待核验的复现差异 (Feng et al., 2026)。WN18RR 的补充结果对应单个获选模型的直接解码评估，完整候选重排、同预算随机对照和多种子重复尚未完成。

A.3 FB15K237-2 候选 InfoNCE 参考实验

该参考实验展示独立配置下的候选 InfoNCE 表现。B1 与 InfoNCE-i0 均在同一本地测试文件的 10,000 条问题上评分；i0 使用单独的配对候选文件、LoRA rank 24、Stage 2 训练 5 个 epoch 和候选损失权重 0.1。表 7 单独标记该配置，当前 SC-CL 直接解码结果见正文表 2，该历史 i0 不与当前 FB 控制混合。

Table 7: FB15K237-2 候选 InfoNCE 参考结果（%，10,000 条测试问题）。InfoNCE-i0 为独立候选及训练配置，方法身份与 SC-CL 分别记录。

方法	直接解码 EM	重排 H@1	MRR	H@3
B1	73.23	79.91	88.01	95.80
InfoNCE-i0	88.69	91.62	95.41	99.20

A.4 候选来源与真值状态审计

候选库的来源检查核对训练划分、问题标识、目标关系、每题九个互异候选和训练已知关系过滤结果。文件哈希、脚本版本、候选评分及模型配置共同标识运行产物。来源合规与

事实真值分别记录：训练已知关系冲突表示候选命中该实体对的训练关系，持出正例重叠表示候选命中持出划分中的已知正例，其余候选保留开放世界未判定状态。

实体替换与关系替换使用各自的候选空间。CoDEx 的人工核验实体替换负例用于其三元组判断设定 (Safavi & Koutra, 2020)；固定实体对后的关系替换，按训练已知关系和持出正例分别核对真值状态。

Table 8: 候选来源与真值状态的审计规则。该表定义状态分类，实测来源检查结果见正文。

状态	判定规则
训练已知关系冲突	候选属于当前实体对的训练已知关系集合 $T_{\text{tr}}(h,t)$。
持出正例重叠	候选对应的三元组出现在持出划分的已知正例中；该记录用于审计。
开放世界未判定	候选未被已知正例或其他核验证据确认，真值维持未判定。
候选不足	训练已知关系过滤后 $\lvert P_q\rvert < K$，记录该问题及原因。
问题对齐异常	候选库与训练任务的问题标识、目标关系或候选文本不一致。

A.5 候选库记录与构造伪代码

每条候选库记录包含问题标识、数据划分、实体对、目标关系、候选关系和采样来源。逐候选记录包括结构相似度、违例度、utility、B1 候选分数及其与目标分数的差值；来源清单包含过滤划分、采样参数、随机种子、脚本版本和文件哈希。这些字段将候选采样结果关联到原始任务及其离线评分。

```
for q in train_questions:
    assert q.split == "train"
    P = train_relations - {q.gold} - known_train_relations(q.head, q.tail)
    if len(P) < K:
        record_insufficient_pool(q)
        continue
    for r in P:
        s = profile_similarity(phi[q.gold], phi[r])
        v = b1_score_violation(q, r)
        u[r] = alpha * s + beta * v
    candidates = sample_without_replacement(
        P, mixture_softmax(u, rho, tau_s), K=9)
    write_frozen_bank(q, candidates, manifest=provenance)
```

候选库按训练来源限定、已知关系过滤和候选采样的顺序构建。来源检查核对问题标识与关系文本的一致性，固定候选库供整个 Stage 2 使用。

A.6 数据、模型与产物记录

完整直接解码比较使用 NELL23K、CoDEx-M 和 FB15K237-2，另有独立历史 NELL 排序运行及 WN18RR 补充结果；基座模型为 Qwen2.5-7B-Instruct (Qwen Team, 2024)，LoRA 用于参数高效训练 (Hu et al., 2022)。实验处理既有知识图谱关系问题，未新增个人敏感数据采集。预测、候选分数、训练配置、adapter 与来源清单保存在本地实验归档中，当前未提供公开下载地址。

A.7 FB 候选来源对照的复现设置

FB 五组固定 Stage 1、12,136 条 QA、3,109 条候选资格和每题九候选。LoRA rank 为 24，alpha 为 48，目标模块为 `down_proj`、`up_proj` 和 `gate_proj`；微批大小为 1，梯度累积为 512，精度为 bfloat16。获选学习率为 9.4762275×10^{-4}，权重衰减为 8.8899022×10^{-5}，Adam epsilon 为 10^{-8}；候选损失权重为 0.11229874，候选温度为 0.88639612。训练实际停止于 32 步，同时保留五轮、120 步线性调度。候选采样参数与损失温度分别记录，不将采样温度 0.25 当作候选损失温度。

Full 采用结构/违例权重 1/1，Profile-only 为 1/0，Violation-only 为 0/1；三组均保留均匀下限 1/3 和采样温度 0.25。均匀随机从完整合法池无放回抽样。Full 由验证集选定；Random 复

用其配置并曾完整评估验证集，单信号和配额匹配组则预先固定 32 步，不执行新完整验证或重新选模。

对频率配额匹配组，记 Full 候选的桶序列为 $(b_1, \ldots, b_9)$，其中 $b_i = \lfloor \log_2 f(r_i) \rfloor$。对桶 b，合法池为 $P_{q,b} = \{r \in P_q : b(r) = b\}$，配额为 $m_{q,b} = \sum_i \mathbf{1}[b_i = b]$。在 $P_{q,b}$ 中均匀无放回抽取 $m_{q,b}$ 个关系，依次放回原桶槽位；对同桶第 j 次抽取，其条件概率为 $1/(|P_{q,b}| - j + 1)$。配额不足时拒绝继续，不跨桶补齐。Full 候选允许被重新抽到，避免通过排除原候选引入额外干预。所有统计仅来自训练图和已冻结 Full 训练候选，不使用验证/测试关系频次。

分层分析在完整测试结果已观察后进行。分组边界取训练词表关系频次排序的第 $\lceil R/3 \rceil$ 和第 $\lceil 2R/3 \rceil$ 个值（R 为训练关系数），分别为 215 和 689；同频次保持同组。按测试中出现的关系等权平均其 EM，得到表 9；未在测试中出现的训练关系不补零。各组的测试关系数分别为低频 67、中频 72、高频 76，完整测试共 215 个关系。该统计与按测试题等权的总体 EM 具有不同权重。

Table 9: FB 五方法的按关系等权平均 EM（%）。分别在各组测试中出现的关系内等权；全体一列对全部 215 个测试关系等权，而不是对三组均值等权。低、中、高频组分别包含 67、72 和 76 个测试关系。

方法	低频	中频	高频	全体关系
均匀随机-9	54.60	70.21	85.03	70.59
Profile-only-9	44.62	62.26	80.83	63.33
Violation-only-9	49.21	63.18	83.86	66.14
Full 配额匹配随机-9	60.31	79.89	86.57	76.15
Full SC-CL-9	57.43	78.71	87.57	75.21

B 历史 NELL 候选重排与成本

B.1 实验设置与评价指标

本附录记录独立的历史排序运行，模型不同于正文表 2的验证选定模型。该运行使用 NELL23K、Qwen2.5-7B-Instruct 和训练种子 2026，在 4,943 条十选一关系问题上评价 SC-CL。候选重排通过 teacher-forced continuation score 逐一评分，以 H@1、MRR 和 H@3 衡量给定候选集合中的关系排序；直接解码 EM 衡量原始输出路径下的预测。两种评估使用相同题目与选项，分别报告结果。

B1 为原始 GRIP 的 generation-only 基线。B1 与 SC-CL 的同候选重排比较覆盖测试文件的前 200 题；两者沿用各自现有训练配置，比较条件集中见第 6 节。完整测试集报告 SC-CL 的排序表现，以及两个模型的直接解码表现。本次历史运行的训练设置见附录表 6，WN18RR 的直接解码补充结果见附录 A.2。

B.2 NELL23K 候选排序结果

SC-CL 在完整测试集上达到 95.27% MRR、91.52% H@1 和 99.07% H@3。在同候选前 200 题上，SC-CL 的 MRR 为 94.96%，比 B1 高 1.60 个百分点；H@1 为 91.00%，比 B1 高 2.50 个百分点。表 10 给出全量结果与配对结果。

Table 10: NELL23K 候选重排结果（%，训练种子 2026）。配对区块按测试文件顺序取前 200 题，两个模型使用相同问题与候选列表；全量区块报告 SC-CL 的 4,943 题结果，全量 B1 重排尚未完成。Δ 为配对子集上的百分点差。

范围	模型	n	H@1	MRR	H@3
配对前 200 题	B1	200	88.50	93.36	97.50
配对前 200 题	SC-CL-9	200	**91.00**	**94.96**	**99.50**
配对差异	Δ(SC-CL-9, B1)	–	+2.50	+1.60	+2.00
全量测试	SC-CL-9	4,943	91.52	95.27	99.07

B.3 配对预测的逐题变化

在同候选前 200 题上，9 题由 B1 错误转为 SC-CL 正确，4 题发生反向变化，净增加 5 题正确预测；其余为 173 题共同正确和 14 题共同错误。逐题变化与 H@1 的 2.50 个百分点差异一致，并展示两模型预测差异的分布。

B.4 直接解码与候选评分

在相同的 4,943 条测试问题上，SC-CL 与 B1 的直接解码 EM 分别为 87.03% 和 87.46%，相差 −0.43 个百分点（表 11）。SC-CL 通过逐候选评分选择答案时，H@1 为 91.52%。直接解码考察关系文本输出，逐候选评分考察给定选项间的排序，本文围绕后一目标组织主要分析。

Table 11: NELL23K 直接解码结果（%，4,943 题，训练种子 2026）。模型在列出相同十个选项的题目上生成关系文本，按 Exact Match 计分。

模型	直接解码 EM
B1	87.46
SC-CL-9	87.03

B.5 候选构造与来源追溯

NELL23K 的固定候选库覆盖 3,253 条训练问题，每题包含九个互异关系，候选构造失败数为 0。来源检查记录了训练划分、任务问题对齐与候选库标识；采样清单保存结构画像、B1 违例度及采样参数。SC-CL Stage 2 完成 10 个 epoch、240 个优化步，归档了 adapter、直接解码预测和候选重排输出。这些记录将候选构造与模型训练关联到同一运行，便于追溯每个候选的来源。

B.6 离线构造与运行成本

训练运行记录的硬件为 NVIDIA GeForce RTX 3090（24 GiB）。表 12 按阶段报告本次运行的资源用量：离线 B1 评分覆盖 644,094 个训练关系候选，Stage 2 处理 12,148,720 个输入 token，完整测试重排覆盖 4,943 条问题。固定候选库在训练期间复用离线采样结果。

Table 12: NELL23K 单次运行的分阶段成本。显存数值对应离线评分阶段的记录。

阶段	耗时（秒）	峰值显存（GiB）
冻结 B1 离线评分	19,027	15.21
Stage 2 联合训练	80,870	–
全测试候选重排	3,567	–

References

Kian Ahrabian, Aarash Feizi, Yasmin Salehi, William L. Hamilton, and Avishek Joey Bose. Structure aware negative sampling in knowledge graphs. In *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing*, pp. 6093–6101, 2020. doi: 10.18653/v1/2020.emnlp-main.492. URL https://aclanthology.org/2020.emnlp-main.492/.

Antoine Bordes, Nicolas Usunier, Alberto Garcia-Duran, Jason Weston, and Oksana Yakhnenko. Translating embeddings for modeling multi-relational data. In *Advances in Neural Information Processing Systems*, volume 26, 2013. URL https://proceedings.neurips.cc/paper/2013/hash/1cecc7a77928ca8133fa24680a88d2f9-Abstract.html.

Liwei Cai and William Yang Wang. KBGAN: Adversarial learning for knowledge graph embeddings. In *Proceedings of the 2018 Conference of the North American Chapter of the Association for Computational Linguistics*, 2018. URL https://aclanthology.org/N18-1133/.

Ching-Yao Chuang, Joshua W. Robinson, Yen-Chen Lin, Antonio Torralba, and Stefanie Jegelka. Debiased contrastive learning. In *Advances in Neural Information Processing Systems*, volume 33, 2020. URL https://papers.nips.cc/paper/2020/hash/63c3ddcc7b23daa1e42dc41f9a44a873-Abstract.html.

Tim Dettmers, Pasquale Minervini, Pontus Stenetorp, and Sebastian Riedel. Convolutional 2d knowledge graph embeddings. In *Proceedings of the Thirty-Second AAAI Conference on Artificial Intelligence*, volume 32, 2018. doi: 10.1609/aaai.v32i1.11573. URL https://ojs.aaai.org/index.php/AAAI/article/view/11573.

Jiarui Feng, Donghong Cai, Yixin Chen, and Muhan Zhang. GRIP: In-parameter graph reasoning through fine-tuning large language models. In *Proceedings of the 32nd ACM SIGKDD Conference on Knowledge Discovery and Data Mining*, 2026. doi: 10.1145/3770855.3817895. URL https://arxiv.org/abs/2511.07457.

Aidan Hogan, Eva Blomqvist, Michael Cochez, Claudia d'Amato, Gerard de Melo, Claudio Gutierrez, Sabrina Kirrane, Jose Emilio Labra Gayo, Roberto Navigli, Sebastian Neumaier, Axel-Cyrille Ngonga Ngomo, Axel Polleres, Sabbir M. Rashid, Anisa Rula, Lukas Schmelzeisen, Juan Sequeda, Steffen Staab, and Antoine Zimmermann. Knowledge graphs. *ACM Computing Surveys*, 54(4):1–37, 2021. doi: 10.1145/3447772. URL https://doi.org/10.1145/3447772.

Edward J. Hu, Yelong Shen, Phillip Wallis, Zeyuan Allen-Zhu, Yuanzhi Li, Shean Wang, Lu Wang, and Weizhu Chen. Lora: Low-rank adaptation of large language models. In *International Conference on Learning Representations*, 2022. URL https://arxiv.org/abs/2106.09685.

Shaoxiong Ji, Shirui Pan, Erik Cambria, Pekka Marttinen, and Philip S. Yu. A survey on knowledge graphs: Representation, acquisition, and applications. *IEEE Transactions on Neural Networks and Learning Systems*, 33(2):494–514, 2022. doi: 10.1109/TNNLS.2021.3070843. URL https://arxiv.org/abs/2002.00388.

Qwen Team. Qwen2.5 technical report. *arXiv preprint arXiv:2412.15115*, 2024. URL https://arxiv.org/abs/2412.15115.

Tara Safavi and Danai Koutra. CoDEx: A comprehensive knowledge graph completion benchmark. In *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing*, pp. 8328–8350, Online, 2020. Association for Computational Linguistics. doi: 10.18653/v1/2020.emnlp-main.669. URL https://aclanthology.org/2020.emnlp-main.669/.

Zhiqing Sun, Zhi-Hong Deng, Jian-Yun Nie, and Jian Tang. Rotate: Knowledge graph embedding by relational rotation in complex space. In *International Conference on Learning Representations*, 2019. URL https://arxiv.org/abs/1902.10197.

Théo Trouillon, Johannes Welbl, Sebastian Riedel, Eric Gaussier, and Guillaume Bouchard. Complex embeddings for simple link prediction. In *Proceedings of the 33rd International Conference on Machine Learning*, volume 48 of *Proceedings of Machine Learning Research*, pp. 2071–2080, 2016. URL https://proceedings.mlr.press/v48/trouillon16.html.

Liang Wang, Wei Zhao, Zhuoyu Wei, and Jingming Liu. SimKGC: Simple contrastive knowledge graph completion with pre-trained language models. In *Proceedings of the 60th Annual Meeting of the Association for Computational Linguistics*, pp. 4281–4294, 2022. doi: 10.18653/v1/2022.acl-long.295. URL https://aclanthology.org/2022.acl-long.295/.

Jun Xia, Lirong Wu, Ge Wang, Jintao Chen, and Stan Z. Li. ProGCL: Rethinking hard negative mining in graph contrastive learning. In *Proceedings of the 39th International Conference on Machine Learning*, volume 162 of *Proceedings of Machine Learning Research*, pp. 24332–24346. PMLR, 2022. URL https://proceedings.mlr.press/v162/xia22b.html.

Liang Yao, Chengsheng Mao, and Yuan Luo. Kg-bert: Bert for knowledge graph completion. In *arXiv preprint arXiv:1909.03193*, 2019. URL https://arxiv.org/abs/1909.03193.