面向 GRIP 参数内化图推理的结构反事实对比学习

Anonymous Authors

Paper under double-blind review

摘要

GRIP 将图知识内化到语言模型参数，并通过生成式问答训练模型检索和推理。本文提出结构反事实对比学习（Structure-Counterfactual Contrastive Learning, SC-CL），作为 GRIP Stage 2 的关系判别扩展：保留原有 Stage 1 初始化、提示和生成目标，增加关系候选级 InfoNCE，使目标关系与反事实关系共同参与训练。为提供可控的关系比较对象，SC-CL 依据训练图关系画像和冻结 generation-only GRIP 基线 B1 的逐题分数违例度构造候选库，过滤训练图中同一实体对的已知关系，并记录候选来源。

在 NELL23K、CoDEx-M 和 FB15K237-2 的单种子本地测试中，验证选定配置相对本地 generation-only 基线的直接解码 EM 分别高 3.22、2.24 和 8.03 个百分点；这些比较包含配置搜索，不能单独识别新增对比目标的贡献。在 FB 固定配置对照中，完整 SC-CL 配置比均匀随机候选高 3.42 个百分点，但比保留其逐题频率桶配额的随机对照仅高 0.07 个百分点。NELL 的直接解码与候选重排差异方向相反；WN18RR 的历史候选池对照呈现较大的正差异，但保留单种子、55 条训练实体对核验缺口及本地基线复现差异。实验评估了这一 GRIP 训练扩展及其关系判别信号；现有结果将其表现限定在当前配置、候选组成和答案选择规则下，尚未确立普遍收益或因果机制。

1 引言

给定实体对及其图上下文，关系预测需要识别相应的关系标签。GRIP 将图知识内化到语言模型参数，并通过生成式问答训练模型检索和推理；其原始 Stage 2 使用 QA 生成目标训练答案 (Feng et al., 2026)。本文关注如何增强 GRIP Stage 2 中的关系辨别：在保留原有生成式 QA 目标的同时，让目标关系与合理的反事实关系显式竞争。为此，我们将关系候选级对比目标接入 GRIP 的参数内化训练流程。

关系候选对比目标需要为每个训练问题提供替代关系。训练图的关系画像可描述关系的结构接近程度，generation-only GRIP 基线的分数可揭示现有模型的关系混淆；两种信号共同决定对比训练实际看到的关系。知识图谱的不完整性还要求区分学习用途与事实真值：未标注关系在开放世界中保留未判定状态。因此，本文的核心设计是扩展 GRIP 的关系训练目标，并以可追溯的反事实候选库实现这一目标；来源替换和条件匹配对照用于界定扩展的实证范围。

为此，我们提出结构反事实对比学习（SC-CL）作为 GRIP Stage 2 的训练扩展。它在原生成目标之外增加候选级 InfoNCE；训练图关系画像与冻结 generation-only 基线 B1 的分数违例度共同决定反事实关系候选，在过滤实体对训练已知关系后固定候选库。该扩展沿用 GRIP Stage 1 和原始提示。本文的结构反事实操作是在固定实体对上替换关系标签，候选构造与新增训练目标见图 1。

我们从两个层面评估这一 GRIP 扩展。NELL23K、CoDEx-M 和 FB15K237-2 的单种子完整测试中，验证选定的 Stage 2 配置相对本地 B1 获得更高的直接解码 EM；由于比较包含训练调参，不能单独识别新增对比目标的贡献。随后，我们固定 FB 训练配置并替换对比目标使用的关系候选，以分析训练信号的组成：Full 的 89.90% 高于均匀随机的 86.48%，但与保留 Full 逐题频率桶配额的随机组（89.83%）仅差 0.07 个百分点；独立按训练边频次比例抽样的组为 70.57%，低于均匀随机。同题十选项重排中，Full 相对配额匹配组的 H@1 仅高 0.13 个百分点。这些来源对照用于说明新增关系判别信号的条件作用；它们不能单独证明双信号候选具有独有或普遍的性能收益。

跨图来源控制补充了这一判断：NELL 中 Full 相对配额组的直接 EM 略高，但重排 H@1 略低；在第四个数据集 WN18RR 的历史候选池条件下，Full 的直接 EM 为 86.89%，高于均匀随机 11.90 个百分点、高于配额组 8.49 个百分点，重排 H@1 也呈正差。因此，FB 的配额近零差是特定配置下的观察，不能推广为所有数据集的共同解释。WN 的实体对核验缺口及 B1 复现差异限定了该结果的探索性身份，相关设置与边界随结果一起报告。

本文的贡献包括三个方面：（1）将关系候选级 InfoNCE 接入 GRIP Stage 2，形成保留图知识参数内化与生成式 QA 目标的关系判别扩展；（2）提出由训练图关系画像和冻结 GRIP 基线分数共同驱动的反事实候选构造，并通过训练已知关系过滤、固定候选库和逐候选记录使训练信号可追溯；（3）在三个主数据集及补充的 WN18RR 历史条件实验中评估该扩展，并通过候选来源、频率组成和答案规则对照界定其收益解释。现有比较尚不能将所有性能

差异单独归因于新增对比目标或候选采样；历史 NELL 候选重排作为独立模型的补充证据保留，直接解码与重排采用各自的评价规则。

2 相关工作

关系预测与生成式图推理。 TransE、ComplEx、RotatE 和 ConvE 通过不同的三元组打分函数建模实体与关系 (Bordes et al., 2013; Trouillon et al., 2016; Sun et al., 2019; Dettmers et al., 2018)。KG-BERT 将三元组判断转为文本建模 (Yao et al., 2019)，SimKGC 在预训练语言模型上使用多种实体负例进行对比学习 (Wang et al., 2022)。GRIP 以图知识参数内化和生成式问答实现图推理，并比较图到嵌入方法 OFA/GOFA 与有无边列表上下文的 Qwen/Llama；其知识图谱结果同时报告准确率和输入 token 数 (Feng et al., 2026)。本文以 GRIP 为目标框架，在其 Stage 2 生成式 QA 目标上增加关系候选级 InfoNCE，使竞争关系参与参数更新。结构画像与冻结基线反馈用于构造该训练目标所需的反事实关系；来源对照检验候选变化对该扩展结果的影响。相关原文数值与本地比较边界见表 1。

困难候选与假阴性。 SC-CL 的核心改动是在 GRIP Stage 2 增加关系候选级对比目标；候选构造为该目标提供用于关系判别的训练输入。结构感知负采样 SANS 和对抗式采样 KBGAN 分别从图结构与模型反馈寻找困难负例 (Ahrabian et al., 2020; Cai & Wang, 2018)，去偏对比学习与 ProGCL 讨论了对比候选难度和假阴性风险 (Chuang et al., 2020; Xia et al., 2022)。本文借鉴这些问题设定，将关系画像与冻结 GRIP 基线的分数违例度用于固定实体对上的关系标签比较，并用训练已知关系过滤、均匀采样下限和固定候选库明确新增训练目标所使用的信号。结构或模型困难采样本身并非本文首次提出；本文关注其在 GRIP 参数内化式关系 QA 中的训练目标扩展及实证边界。该设计也不构成对 SANS 或 KBGAN 的同协议性能比较。本文采用的开放世界真值约定见问题定义节。

关系候选评估。 传统 link prediction 常在实体替换候选上报告 MRR/Hits，CoDEx 还提供经过人工核验的实体替换困难负例 (Safavi & Koutra, 2020)。实体替换与关系替换对应不同的候选空间。本文在固定实体对上评价关系标签排序，并分别使用直接解码与逐候选评分衡量两种答案选择方式；实体替换负例保留其三元组判断用途，关系候选按各自的已知事实与未判定状态记录。

3 问题定义

3.1 训练图与候选关系

令训练知识图谱为 $\mathcal{G}_{\text{tr}} = (\mathcal{V}, \mathcal{E}_{\text{tr}})$，其中 $\mathcal{E}_{\text{tr}} \subseteq \mathcal{V} \times \mathcal{R}_{\text{tr}} \times \mathcal{V}$，$\mathcal{R}_{\text{tr}}$ 是训练关系词表。一个关系问答样本表示为 $q = (h, t, r^+)$，其中 r^+ 是目标关系，h, t 是有序实体对。定义同一实体对在训练图中的已知关系集合为

$$T_{\text{tr}}(h, t) = \{r : (h, r, t) \in \mathcal{E}_{\text{tr}}\}. \tag{1}$$

候选池为

$$P_q = \mathcal{R}_{\text{tr}} \setminus \big(\{r^+\} \cup T_{\text{tr}}(h, t)\big). \tag{2}$$

式 2 从训练关系词表中排除目标关系和该实体对的已知训练关系。其余关系作为真值未判定的训练替代项，遵循知识图谱的开放世界假设 (Ji et al., 2022; Hogan et al., 2021)。本文的结构反事实操作固定实体对 (h, t)，将目标关系替换为 $r \in P_q$；“负候选”表示其在对比目标中的角色，事实真值保持未判定。

3.2 答案选择与候选学习目标

本文区分两种答案选择规则。直接解码在列出十个关系选项的题目上输出关系文本，以 Exact Match（EM）评价原始解码路径下的预测。候选重排给定同一题目的候选集合，用关系续接分数（continuation score）$z_\theta(q, r)$ 逐项排序，以 Hits@1（H@1）、H@3 和 MRR 评价候选间的关系辨别。重排 H@1 等于按最高分选项计算的 EM。两种规则分别报告，模型间的表现差异采用相同答案选择规则比较。

给定冻结 bank $B(q) = \{r_1^-, \ldots, r_K^-\}$，候选损失写为

$$\mathcal{L}_{\text{cand}}(q) = -\log \frac{\exp(z_\theta(q, r^+)/\tau_c)}{\exp(z_\theta(q, r^+)/\tau_c) + \sum_{k=1}^{K} \exp(z_\theta(q, r_k^-)/\tau_c)}. \tag{3}$$

其中 τ_c 是候选温度。训练阶段联合优化原始生成损失 $\mathcal{L}_{\text{gen}}$ 与候选损失：

$$\mathcal{L} = \mathcal{L}_{\text{gen}} + \lambda_{\text{cand}} \mathcal{L}_{\text{cand}}. \tag{4}$$

SC-CL 沿用 GRIP 的 Stage 1 和生成目标，并将候选级 InfoNCE 作为 Stage 2 的新增关系判别训练项。

4 SC-CL：面向 GRIP Stage 2 的关系判别扩展

SC-CL 将关系候选级对比目标接入 GRIP Stage 2，以增强生成式 QA 对目标关系和竞争关系的辨别。它保留原始 Stage 1 adapter、提示和生成损失，并新增候选级 InfoNCE。训练前，离线阶段融合训练图关系画像与冻结 B1 在训练问题上的违例度，在过滤后的关系池中采样并固定每题 K 个候选，默认 $K = 9$；学习阶段从 Stage 1 adapter 初始化 GRIP，在固定候选库上联合优化新增候选损失与原始生成损失。

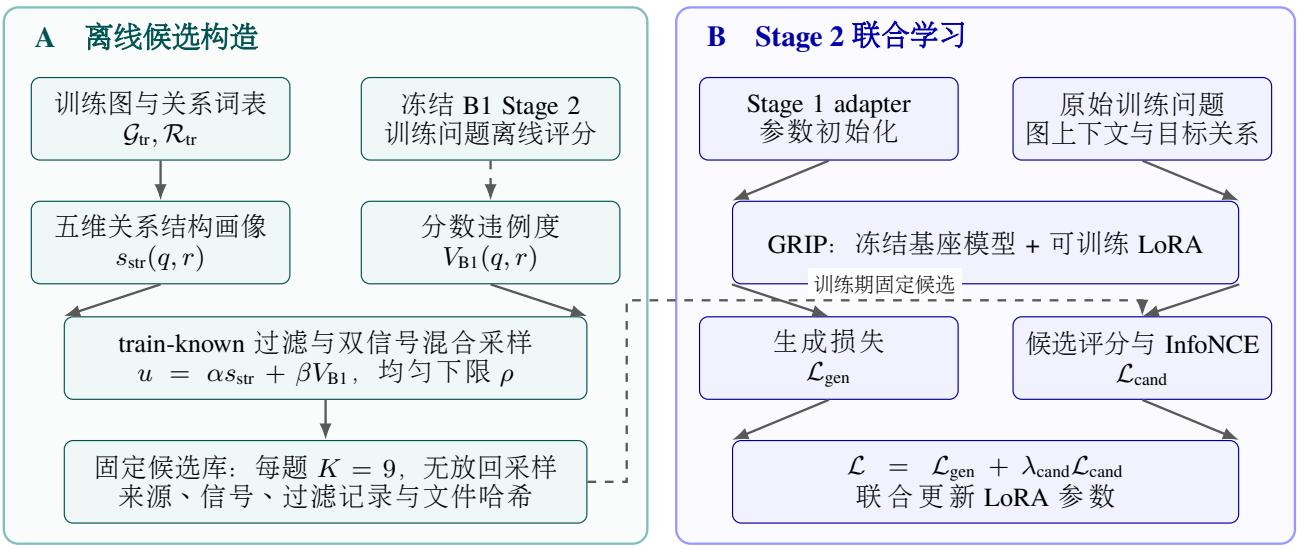


Figure 1: SC-CL 的候选构造与联合学习。A：训练图结构画像与冻结 B1 违例度共同指导采样，train-known 过滤与无放回采样形成每题 $K = 9$ 的固定候选库。B：Stage 2 从 Stage 1 adapter 初始化，联合优化生成损失与加权候选 InfoNCE；冻结 B1 为离线候选构造提供评分。

结构画像寻找统计上接近的关系，模型违例度寻找冻结基线难以区分的关系；均匀项为其余合法关系保留被采样的机会。设计假设是两种信号能够提供互补的候选信息，但它们也可能共同改变关系频率组成。因此，实验同时比较单信号替换与频率配额匹配，而不从设计本身推出互补收益。

4.1 训练图关系画像

对每一个 $r \in \mathcal{R}_{\text{tr}}$，我们从 $\mathcal{E}_{\text{tr}}$ 计算五维关系画像

$$\phi(r) = \big(\log(1+|E_r|), \log(1+|H_r|), \log(1+|T_r|), \log(1+\bar{d}_{H,r}), \log(1+\bar{d}_{T,r})\big), \tag{5}$$

其中 $|E_r|$ 为关系边数，$|H_r|$ 和 $|T_r|$ 分别为关系覆盖的头实体数与尾实体数，$\bar{d}_{H,r} = |H_r|^{-1} \sum_{h \in H_r} d_{\text{out}}(h)$ 是不同头实体在训练图中的平均出度，$\bar{d}_{T,r} = |T_r|^{-1} \sum_{t \in T_r} d_{\text{in}}(t)$ 是不同尾实体的平均入度。五个统计量均使用 $\log(1+x)$ 压缩尺度；度数对训练图全部关系计算。

对目标关系 r^+ 和候选 r，定义归一化结构相似度

$$s_{\text{str}}(q, r) = 1 - \frac{1}{5} \sum_{j=1}^{5} \frac{|\phi_j(r^+) - \phi_j(r)|}{1 + |\phi_j(r^+)| + |\phi_j(r)|}, \tag{6}$$

分母中的常数 1 保证非零，分数裁剪到 $[0, 1]$。该分数衡量五维图统计画像的接近程度；实体对的已知关系由式 2 单独过滤。

4.2 冻结 B1 的边界违例度

B1 是从共享 Stage 1 初始化继续训练得到的原始 GRIP generation-only Stage 2 分支；SC-CL 使用同一 Stage 1 adapter 初始化。我们在训练问题上离线计算全关系词表的 continuation score。若离线记录已有 pairwise confusion，则直接使用裁剪到 $[0, 1]$ 的 confusion；否则按该运行评分清单指定的温度，对候选和正关系的分数差使用平滑违例度

$$V_{\text{B1}}(q, r) = \sigma\left(\frac{z_{\text{B1}}(q, r) - z_{\text{B1}}(q, r^+)}{\tau_v}\right). \tag{7}$$

候选分数越接近或超过正关系，V_{B1} 越大。本文核验的四数据集候选 bank 均直接使用已缓存的 pairwise confusion，因此式 7的温度回退路径未用于这些 bank。B1 在训练问题上的离线分数于候选库构造时固定，提供与后续 Stage 2 参数更新分离的候选评分依据。

4.3 结构反事实候选分布

将结构相似度和分数违例度合成为

$$u(q, r) = \alpha s_{\text{str}}(q, r) + \beta V_{\text{B1}}(q, r), \qquad r \in P_q. \tag{8}$$

候选分布使用均匀下限与 utility softmax 的混合：

$$p(r \mid q) = \frac{\rho}{|P_q|} + (1-\rho) \frac{\exp(u(q, r)/\tau_s)}{\sum_{r' \in P_q} \exp(u(q, r')/\tau_s)}. \tag{9}$$

我们从 $p(r \mid q)$ 无放回抽取 $K = 9$ 个负候选。主实验参数为 $\rho = 1/3$、$\alpha = 1$、$\beta = 1$、$\tau_s = 0.25$。当 $|P_q| < K$ 时，若构造配置不允许 shortfall，bank 构建记录失败并停止，不将不足 K 的候选行默认为完整样本；本研究纳入的三个主实验库均满足每题九个候选。WN18RR 的历史 bank 范围与 55 道未核实实体对另行说明。

结构反事实操作在固定实体对上替换关系标签，其候选池与开放世界真值约定见问题定义节。

4.4 固定候选库与来源追溯

SC-CL 为每个训练问题记录问题标识、目标关系、九个候选及其结构相似度、违例度、utility 和 B1 score gap，并保存采样参数、数据划分与已知关系过滤记录。候选库遵循四项来源约束：

1. 问题来源和已知关系过滤均使用训练划分；
2. 每个样本恰有一个正关系和 $K = 9$ 个互异候选，候选均属于 $\mathcal{R}_{\text{tr}}$；
3. 候选与 $T_{\text{tr}}(h, t)$ 不相交，问题标识与训练任务一一对齐；
4. 候选库哈希、脚本版本、随机种子和采样参数写入来源清单，构造后的候选库在训练中保持固定。

训练时，候选 continuation score 代入式 3，生成损失沿用原始 GRIP 路径计算。两项损失按式 4 共同优化 Stage 2 的 LoRA 参数。

4.5 计算复杂度与离线构造

关系画像通过一次线性扫描训练边得到，复杂度为 $O(|\mathcal{E}_{\text{tr}}|)$。给定离线模型分数后，每个问题在关系词表上计算 utility，复杂度为 $O(|\mathcal{R}_{\text{tr}}|)$；采样后的候选库大小为 $O(K|Q_{\text{tr}}|)$，其中 Q_{tr} 为训练问题集合。计算过程包括训练图统计、冻结 B1 离线评分和 Stage 2 联合训练；分阶段资源记录见第 B.6 节。

5 实验与结果

5.1 GRIP 关系判别扩展的评价设置与比较层次

本文评估将候选级 InfoNCE 接入 GRIP Stage 2 后的关系判别训练配置，以 NELL23K、CoDEx-M 和 FB15K237-2 的完整测试直接解码结果为主，并在 FB 与 NELL 上进一步固定训练设置、替换候选来源，在第四个数据集 WN18RR 上补充历史候选池条件下的探索性来源对照。基座均为 Qwen2.5-7B-Instruct，训练种子为 2026。直接解码在题目给定的关系选项下生成关系文本，按 Exact Match（EM）计分；三个主数据集为十选项，WN18RR 保留原十一选项。模型间核对问题标识、提示、选项顺序和目标，报告同题差异。训练候选仅来自训练关系词表，训练已知关系过滤的核验范围按数据集记录；WN 的历史实体对核验例外见附录 A.3。

两层比较回答不同问题。三数据集比较展示验证选定的 Stage 2 配置与本地 generation-only B1 分支的结果；配置搜索及部分优化设置同时变化，不能将差异单独归因于候选损失。来源对照在各图内复用获选 Full 配置，固定训练 QA、Stage 1 初始化、损失、LoRA 及优化设置，只替换冻结候选库。后者估计该配置下的候选替换差异，不是各方法等预算调参后的最优性能比较。NELL 与 WN 的 Full 模型为历史权重复用，两个控制为新训练。独立历史 NELL 长周期排序模型见附录 B，不与本节当前模型混合。本节分别报告直接解码 EM 与候选重排，后者不改变既有直接解码答案。

原始 GRIP 将图到嵌入方法 OFA/GOFA，以及无上下文或附加边列表上下文的 Qwen/Llama 作为外部比较系统；其表格报告十选一准确率和平均输入 token 数。表 1转录这些已发表结果，并保留原文 GRIP 模型作为候选学习方法所依托的外部参照。该文献表不替代本地同题 B1 和候选来源控制：尤其是本文的 FB15K237-2 为 10,000 题子集，且跨来源的提示及候选身份没有逐题核验，因此不从文献数值计算 SC-CL 的增益。

Table 1: GRIP 原文知识图谱关系预测的已发表比较结果。单元依次为准确率（%）/平均输入 token 数。

方法（原文设置）	NELL23K	CoDEx-M	FB15K237
图到嵌入基线			
OFA	–	–	70.84 / 1304.90
GOFA	–	–	80.69 / 1304.90
无显式图上下文的语言模型			
Qwen-7B	77.38 / 160.80	83.09 / 124.21	79.65 / 155.74
Llama-8B	20.05 / 160.33	71.03 / 124.61	56.66 / 152.75
提供边列表上下文的语言模型			
Qwen-7B + context	81.38 / 590.37	73.32 / 1055.29	79.19 / 1330.56
Llama-8B + context	53.33 / 586.15	47.46 / 1044.44	44.68 / 1304.90
GRIP 参数内化模型			
GRIP-Qwen-7B	87.74 / 160.80	94.42 / 124.21	88.75 / 155.74
GRIP-Llama-8B	77.40 / 160.33	91.58 / 124.61	77.79 / 152.75
完整图上下文	OOC / $>$ 0.5M	OOC / $>$ 5M	OOC / $>$ 10M

数据转录自 GRIP 论文表 2–3 (Feng et al., 2026)。准确率为十选一缺失关系预测的精确匹配；第二项为平均输入 token 数。GRIP 论文注明 OFA/GOFA 数值取自其原论文；“–”表示原文未报告该数据集结果，OOC 表示完整图序列超出上下文窗口。此表是已发表文献结果，不是本地复现实验。原文使用标准 FB15K237；本文本地 FB15K237-2 为 10,000 题子集，且不同来源的逐题提示与候选身份尚未逐项核验。因此本表用于说明既有方法与输入成本，不计算相对 SC-CL 的直接增益；同协议主比较见表 2和表 3。

5.2 三数据集完整测试结果

表 2给出验证选定模型的完整测试结果。NELL23K、CoDEx-M 和 FB15K237-2 相对匹配 B1 分别净增加 159、231 和 803 题正确预测，对应 3.22、2.24 和 8.03 个百分点。这些数值描述单种子本地协议下的模型配置表现，不是严格原论文复现、多种子统计或纯采样机制的隔离收益。

Table 2: 三数据集本地协议的完整测试直接解码结果（%，seed=2026）。B1 与方法的问题、选项顺序和目标对齐；方法为验证选定的 Stage 2 配置。Δ 为方法减 B1 的百分点差。训练调参及部分优化设置同时变化，故该表不隔离候选损失或采样机制。

数据集	n	B1 EM	SC-CL EM	Δ (pp)	净增题数
NELL23K	4,943	84.58	87.80	+3.22	+159
CoDEx-M	10,311	94.34	96.58	+2.24	+231
FB15K237-2	10,000	81.87	89.90	+8.03	+803

5.3 FB 固定配置下的候选来源对照

FB 各组共享 12,136 条训练 QA，其中 3,109 条具备候选损失资格，每题九个候选。均从相同 Stage 1 初始化，实际训练 32 个优化步，并保持原五轮、120 步线性学习率调度。Full 配置由验证集预先选定；后续对照的第 32 步模型在测试前固定，不根据测试结果重采候选、换种子或延长训练。每个新组仅执行一次完整测试；单信号及配额匹配组不再执行全量验证。具体设置见附录 A.9。

均匀随机组从同一合法池无放回抽取九个关系。Profile-only 保留结构项并移除 B1 违例项，Violation-only 保留 B1 违例项并移除结构项；其余采样参数与 Full 一致。我们还加入独立频次比例组：每题按训练图关系边数成比例、逐次无放回抽取九个合法关系，不读取 Full 候选、B1 分数或结构画像，也不继承 Full 逐题频率桶配额。该组使用相同固定训练配置。表 3显示 Full 的 EM 为 89.90%，高于均匀随机的 86.48%，并分别高于 Violation-only 和 Profile-only 2.81 和 5.01 个百分点。Profile-only 为 84.89%，低于均匀随机 1.59 个百分点。独立频次比例组为 70.57%，低于均匀随机 15.91 个百分点；Full 相对该组高 19.33 个百分点，在 10,000 题中纠错 2,251 题、退化 318 题。因而，按全局训练边频次比例抽样这一具体规则在当前配置下没有复现 Full 表现；这一结果不排除其他频率采样规则，也不能单独识别结构信号的因果作用。

Table 3: FB15K237-2 候选来源对照（10,000 题，直接解码 EM，seed=2026）。各组使用同一 Stage 1、训练 QA、合法池、$K = 9$、损失与优化设置，固定 32 步并保持 120 步调度。独立频次组按训练边数成比例无放回抽样；配额匹配组继承 Full 逐题频率桶配额。Δ 为 Full 减该行。结果限于单种子和 Full 选定配置。

候选来源	正确数	EM (%)	Δ (pp)
Full SC-CL-9	8,990	89.90	+0.00
均匀随机-9	8,648	86.48	+3.42
Profile-only-9	8,489	84.89	+5.01
Violation-only-9	8,709	87.09	+2.81
Full 配额匹配随机-9	8,983	89.83	+0.07
独立频次比例随机-9	7,057	70.57	+19.33

保留 Full 频率配额的条件随机对照。 令 $f(r)$ 为关系 r 在训练图中的边数，固定频率桶 $b(r) = \lfloor \log_2 f(r) \rfloor$。对每道训练题，先记录 Full 九个候选对应的桶序列，再从同桶合法池内均匀无放回抽取替代关系，保持逐题桶配额和槽位桶不变。3,109 题全部匹配，未跨桶回退；其候选集合均不同于 Full，平均每题共享 0.635 个原候选。27,981 个抽样槽位中 82 个因桶池大小等于配额而被迫选定。该对照保留的是 *Full* 诱导的逐题频率配方，不是独立于 Full 的一般频率采样器；也不要求桶内具体边数或 B1 困难度相同。

配额匹配随机组达到 89.83% EM，相对均匀随机提高 3.35 个百分点，与 Full 仅差 0.07 个百分点、净 7 题。这说明均匀随机对照不足以识别 Full 在其诱导频率桶分布之外的额外收益。频率分布仍是需要保留的替代解释；该结果既不证明频率造成全部收益，也不证明结构信息无效或两模型统计等效。配额从 Full 候选库提取，本身携带 Full 的选择信息。

5.4 相同测试候选上的完整排序

候选损失直接优化关系间的相对分数，因此直接解码 EM 之外还需检验排序本身。我们复用 Full、配额匹配随机和均匀随机的三个固定模型，对同 10,000 题的原十选项逐项评分；不新增训练或选模。评分采用包含答案标签的续接 token 平均对数概率，并沿用原实现的截断规则，细节见附录 A.10。

Full 相对均匀随机的 H@1 高 1.17 个百分点；相对配额匹配随机仅高 0.13 个百分点，MRR 高 0.0983 个百分点。后者在 170 题上纠错、157 题上退化，净多 13 题正确。独立频次比例组的 H@1 和 MRR 分别为 87.01% 和 92.1324%，Full 分别高 7.84 和 5.1175 个百分点；H@1 上 Full 纠错 1,024 题、退化 240 题，净多 784 题；相对均匀随机的 H@1 也低 6.67 个百分点。由此，Full 与配额匹配组接近的现象仍出现在排序评价中，而单独按训练边频次比例抽样的控制明显较低。所有差异均来自同一测试集和单一固定配置，不能据此宣称统计等效、频率方法普遍失效或结构机制得到因果识别；重排范围仍限于原十选项。

Table 4: FB 同题同十选项的完整候选重排（%，seed=2026，$n = 10{,}000$）。Full、配额匹配和均匀随机复用既有固定模型；独立频次组采用对应固定配置模型。无新增选模；直接解码结果另列于表 3。

候选来源	H@1	MRR	H@3
Full SC-CL-9	94.85	97.2499	99.75
Full 配额匹配随机-9	94.72	97.1517	99.66
均匀随机-9	93.68	96.5722	99.56
独立频次比例随机-9	87.01	92.1324	96.72

5.5 跨数据集来源对照：NELL23K 与 WN18RR

为检验 FB 中配额匹配组接近 Full 的现象是否也出现在其他关系图上，我们在 NELL23K 与 WN18RR 分别增加均匀随机和 Full 配额匹配随机两个控制，复用各自历史验证获选的 Full 模型。各图内固定训练问题、候选资格、$K = 9$ 及优化设置，不新增验证选模或按测试结果扩大训练预算。NELL 使用 12,014 条训练 QA，其中 2,974 条具有候选损失资格，训练 32 步并保留 240 步调度；WN 使用 12,334 条 QA，其中 2,709 条合格，训练 125 步、调度 125 步。两图均完成全部三模型的直接解码与原选项重排，完整结果见表 5。

Table 5: NELL23K 与 WN18RR 的三来源完整测试结果（%，seed=2026）。NELL 共 4,943 题、原 10 选项；WN 共 3,134 题、原 11 选项。各图复用历史获选 Full，新增两个固定配置控制，不独立重新调参。WN 为历史候选池条件下的探索性比较，实体对核验与 B1 复现限制见附录 A.3；这里的 MRR 为原选项内重排指标。

数据集	候选来源	直接 EM	H@1	MRR	H@3
NELL23K	均匀随机-9	87.17	90.17	94.42	98.83
	Full 配额匹配随机-9	87.54	90.63	94.73	98.87
	Full SC-CL-9	87.80	90.33	94.53	98.73
WN18RR	均匀随机-9	74.98	76.99	86.74	96.04
	Full 配额匹配随机-9	78.40	80.34	88.97	97.48
	Full SC-CL-9	86.89	88.42	93.15	97.83

NELL 上，Full 的直接 EM 为 87.80%，高于均匀随机 0.63 个百分点，高于配额匹配组 0.26 个百分点；但 Full 的重排 H@1 为 90.33%，低于配额匹配组的 90.63%，MRR 亦低 0.20 个百分点。Full 相对配额匹配组在直接解码上净多 13 题正确，在重排上则净少 15 题。因此，同一训练配置的候选来源差异依赖答案选择规则，不能将 NELL 概括为 Full 在两种协议下均优于配额组。

WN 呈现更大的来源差异。Full 的直接 EM 为 86.89%，均匀随机为 74.98%，配额匹配组为 78.40%；Full 分别高 11.90 和 8.49 个百分点。其重排 H@1 为 88.42%，分别高于均匀随机和配额组 11.42 和 8.07 个百分点，MRR 为 93.15%。与 FB 和 NELL 相比，WN 的 Full 相对配额组在两种答案规则下均有较大的正差，说明保留 Full 频率配额后能够复现多少收益并非跨图不变。WN 沿用历史候选池，存在 55 条训练 QA 实体对未独立核实及本地 B1 复现差异，故该结果属于探索性条件比较，而非已修复 B1 后的主效果验证。完整配对变化与核验范围见附录 A.4和附录 A.3。

5.6 比较条件与可追溯性

FB 六种候选来源共同使用 464 条训练实体对关系 QA 修复。验证用于开发及 Full 配置选择，既有测试暴露历史不因后续固定对照而消除；NELL 开发也存在先前测试暴露和验证 few-shot 使用。NELL 方法与其 B1 的 Adam epsilon 不同，CoDEx-M 方法与 B1 的微批大小不同；三数据集配置差异在解释主表时保留。表 1只作为外部文献参照，不与本地配对结果混算；逐题检验反映当前固定模型与测试题上的条件差异，不能替代训练种子间不确定性估计。

候选库保存逐题关系、训练频次、结构相似度、B1 违例度和过滤依据，并关联冻结代码、输入身份、训练与评测日志、原始响应和逐题正确标记。FB 五方法的 50,000 条判定及配对汇总均按相同 EM 规则复核。新增控制的检查点保留范围按数据集披露，NELL 均匀随机的早期状态丢失例外见附录 A.4。来源审计使这些比较可追溯，但不等于其余候选在开放世界中都已被确认为假关系，真值分类见附录 A.6。

6 候选组成与排序边界分析

来源对照同时改变了候选身份与频率组成。本节先检查固定候选库实际选择了哪些关系，再检验来源差异是否随目标关系频率变化，以及增加训练候选数量是否持续改善排序。

6.1 三数据集采样信号与原始关系边际

我们对三个拥有已训练、逐题对齐均匀与配额对照的冻结 $K = 9$ 候选库计算关系画像相似度和缓存的 B1 分数违例度，并在每题合法候选池中转换为中秩百分位。百分位越高表示候选在该题的合法池中相对更结构相似或更难；它不代表跨题绝对分数，也不是真实关系标签的概率。三库合计覆盖 8,792 道合格训练问题和 79,128 个 Full 负例槽位。CoDEx-M 因缺少已训练的对应对照而不纳入本节诊断；本节不将解析 Uniform 当作已观测随机对照。

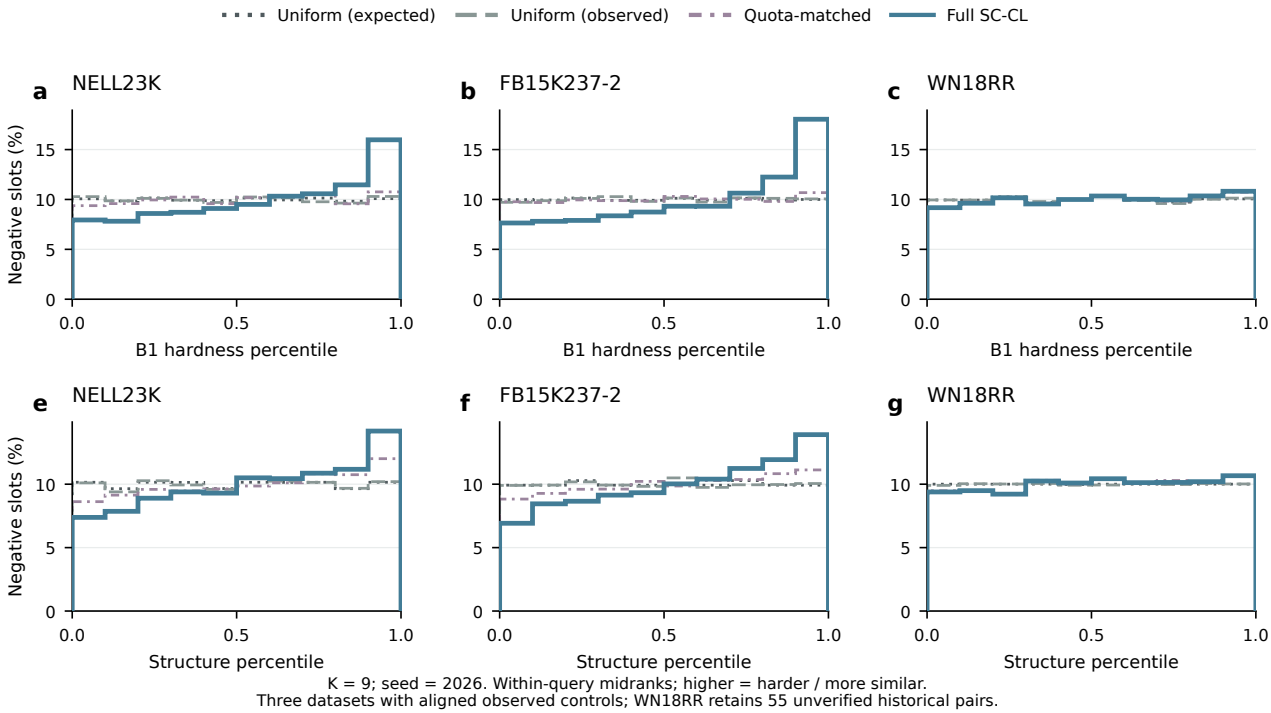


Figure 2: 三个具有已训练均匀与配额对照的数据集实际负例库的题内选择分布。上排为冻结 B1 困难度百分位，下排为关系画像相似度百分位；均在每题合法候选池内计算，并列取中秩。每道题等权，每个实际 bank 每题包含九个不同负例（seed=2026）。均匀期望对各题合法池内的全部候选求平均。CoDEx-M 因没有已训练的对应对照而不纳入本图；WN18RR 沿用历史候选池，包含 55 道实体对未核实问题。图示为候选生成分数，不是最终模型预测分数。

图 2显示，Full 的平均题内结构相似度/困难度百分位在 NELL23K 为 0.550/0.558，在 FB15K237-2 为 0.553/0.573，在 WN18RR 为 0.511/0.510。相对已观测 Uniform，三者的平均困难度百分位分别高 5.87、7.06 和 1.06 个百分点。FB 两个已完成单信号对照呈现了预期的选择分离：Profile-only 的平均结构/困难度百分位为 0.543/0.500，Violation-only 为 0.511/0.570，Full 为 0.553/0.573（图 5）。这些数值表明冻结候选库的选取分数随信号设计而变，不度量训练后模型性能。

图 3进一步显示 Full 相对于逐题合法池均匀期望的结构—困难度联合富集。图 4将每个关系的训练边概率与其在 Full 负例中的概率直接对照；实际采样边际并未复刻原始训练边频率。方法按每道训练问题从合法池构造候选，其目标并非拟合全图边的边缘频率。尤其是 WN 的合法池几乎总是被 $K = 9$ 选满，且包含 55 道实体对未独立核实的问题，故其可观察的采样移动较小。所有分布图均为一个冻结库实现的描述性结果；它们不能确认负候选的事实真假，也不能单独解释下游性能差异。

6.2 总体接近是否掩盖频率层级差异

表 6并列报告纠错和退化。Full 与配额匹配组共同正确 8,642 题、共同错误 669 题，另有 348 题仅 Full 正确、341 题仅配额匹配组正确。总体 EM 接近仍伴随 689 题判定变化，需要进一步检查其分布。

Table 6: FB 同 10,000 题上的配对变化。纠错表示左侧方法正确、右侧错误，退化为相反情况；净变化为纠错减退化。

比较方向	纠错	退化	净变化
Full – 均匀随机	553	211	+342
Full – Profile-only	755	254	+501
Full – Violation-only	582	301	+281
Full – 配额匹配随机	348	341	+7
配额匹配 – 均匀随机	534	199	+335
Full – 独立频次	2251	318	+1933
配额匹配 – 独立频次	2232	306	+1926
均匀随机 – 独立频次	2095	504	+1591

为检查总体净差是否掩盖不同频率关系上的相反变化，我们按训练关系词表中各关系边数的三分位次序统计量定义低、中、高频组，同频次不拆分；两条边界为 215 和 689。边界仅由训练图决定，不按测试正确率调整。测试

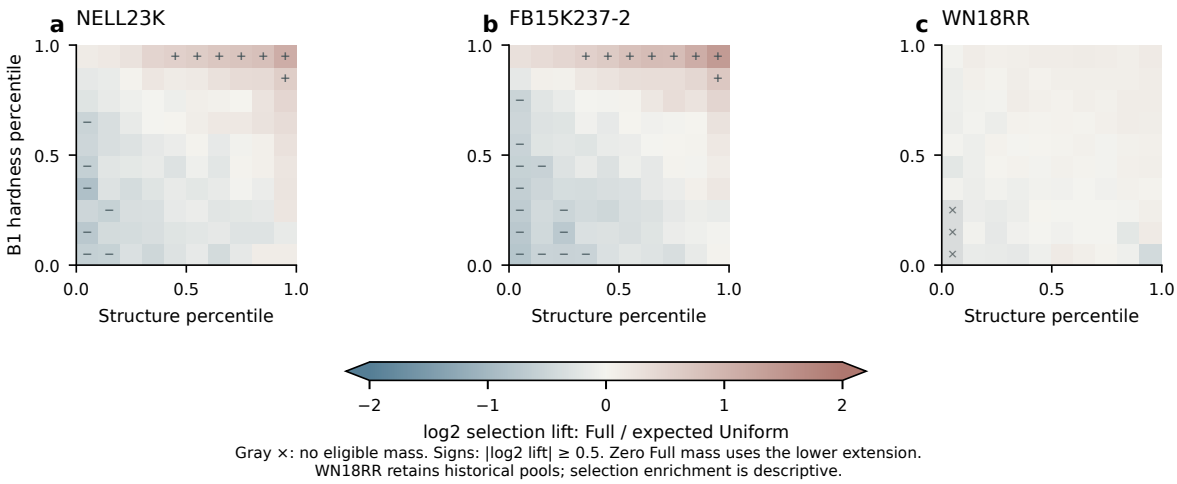


Figure 3: 三个具有已训练均匀与配额对照的数据集相对于逐题均匀期望的联合选择富集。颜色表示固定的结构相似度与 B1 困难度百分位二维桶上的 $\log_2(P_{\text{Full}}/P_{\text{Uniform}})$。0 表示质量相同，+1 表示 Full 质量为参照的两倍。所有面板使用 $[-2, 2]$ 色限，超出部分以色条两端延伸。正负号标记绝对 log2 富集至少为 0.5 的格子；灰叉表示合法池在该格中没有质量。Full 质量为 0 时使用色条下端且不加伪计数。WN18RR 结果限定于历史候选池。该图描述采样分布，不检验因果交互或下游性能提升。

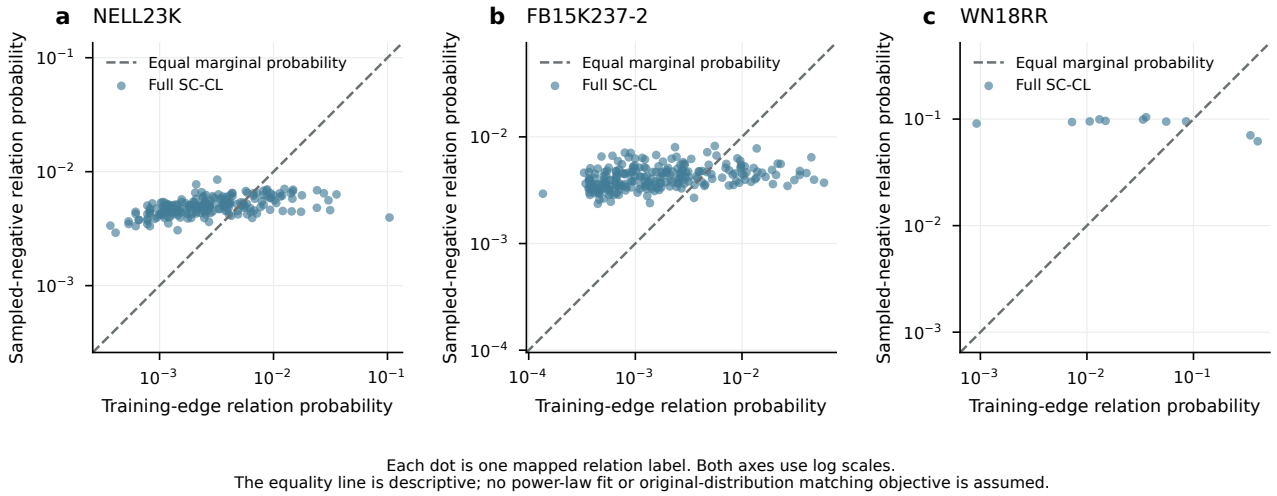


Figure 4: 三个数据集的训练图关系边际与 Full 实际负例关系边际。每个点代表一个映射后的训练关系标签，横纵轴分别为其训练边概率及 Full 负例概率，采用双对数坐标。虚线为边际概率相等线，用于描述偏离程度；不拟合幂律，也不预设采样目标是匹配训练边分布。所有图均为 seed 2026 冻结候选库；WN18RR 保留历史候选池范围。

问题按目标关系的训练频次归组，所有 10,000 题均纳入，覆盖 215 个测试中出现的训练关系。该分析是在总体结果观察后的描述性分析，不构成独立确认性检验。

Table 7: 按目标关系训练边数划分的 FB 描述性配对分析。边界为训练关系词表频次的三分位次序统计量，同频次不拆分；未按测试表现调边界。EM 单位为%；配额匹配指 Full 配额匹配随机。所有分组均报告，净变化合计为 7 题，不构成跨种子或因果证据。

目标关系频率	n	Full EM	配额匹配 EM	纠错	退化	净变化
低频（≤ 215）	412	60.92	65.05	24	41	-17
中频（216–689）	1089	82.74	82.64	51	50	+1
高频（> 689）	8499	92.22	91.95	273	250	+23

低频组的 412 题中，Full 相对配额匹配组纠错 24 题、退化 41 题，净减少 17 题（-4.13 个百分点）；中频组净增加 1 题，高频组净增加 23 题。因此，当前数据不支持 Full 在低频关系上的补偿性优势。高频组占测试题目的 84.99%，按题等权的总体 EM 与按关系等权的结果可能不同。以测试中出现的关系等权平均 EM，Full 为 75.21%，

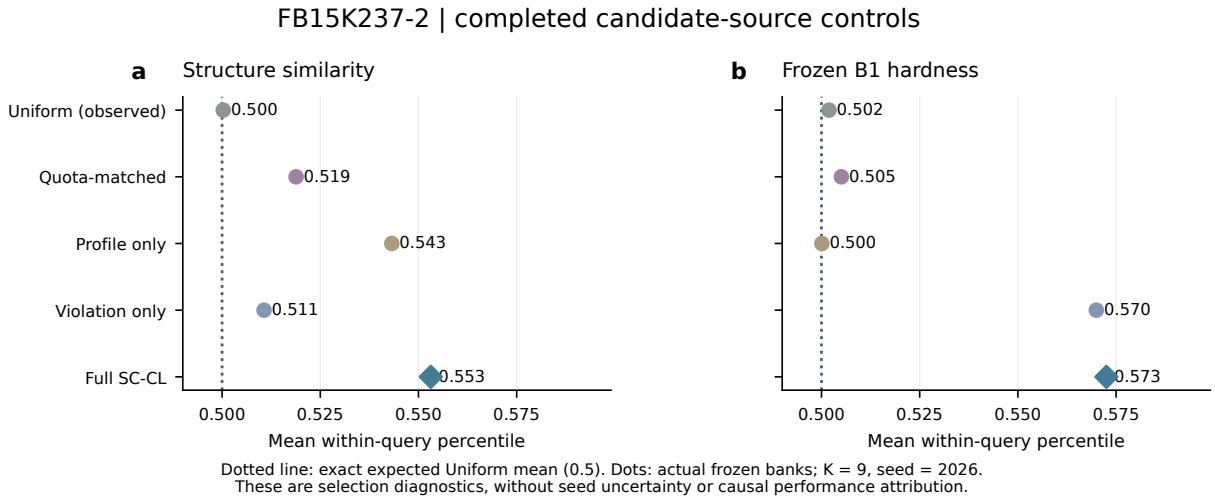


Figure 5: FB15K237-2 已完成候选来源对照的选择信号指纹。点表示实际 bank 在逐题结构相似度与冻结 B1 困难度百分位上的均值；解析 Uniform 的两轴均值精确为 0.5。Profile-only 主要改变结构属性，Violation-only 主要改变 B1 困难度，Full 在两者上均有移动。每组为单一冻结 bank 实现，不估计跨种子不确定性；采样分数移动本身不证明性能机制。

配额匹配组为 76.15%；各方法的完整分层及关系平均结果见附录表 13。这些观察说明需要同时报告问题分布与关系分布，不能将总体微小正差外推为所有频率层级的收益。

6.3 训练负例数量与排序敏感性

增加训练负例会扩大每次候选损失的比较范围，但不保证带来更好的排序。我们固定 Full-K9 获选的超参数、训练种子及优化步数，仅将训练负例数改为 $K = 3$ 或 15；$K = 9$ 模型和评测复用前述结果。三个模型始终在同十个测试选项上评估，训练负例数不改变测试候选集合。

Table 8: FB 训练负例数的排序敏感性（%，seed=2026）。同 10,000 题及原十选项，K9 复用；各 K 保持相同优化步数，非等计算量。

训练负例 K	H@1	MRR	H@3
3	95.28	97.4101	99.63
9	94.85	97.2499	99.75
15	95.03	97.3181	99.63

H@1 在三个 K 点间的跨度为 0.43 个百分点，随 K 增加没有单调改善。K3 的 H@1 与 MRR 最高，K9 的 H@3 略高；不同指标对这三个点的排序并不一致。K3 与 K15 相对 K9 分别净多 43 题与 18 题正确，完整纠错与退化计数见附录 A.10。当前结果说明，在这一单种子固定配置下，更多训练负例未持续转化为更高的排名质量；它不确定全局最优 K，也不检验不同 K 下 Full 相对配额匹配控制的优势。各组保持相同优化步数而非相同计算量，且未新增直接解码评价，故不作等成本优劣或生成鲁棒性解释。

7 讨论

SC-CL 对 GRIP 的扩展及其证据范围。 本文对 GRIP 的方法改动位于 Stage 2：在原有生成式 QA 目标之外增加关系候选级 InfoNCE，使目标关系与固定的反事实关系共同参与参数更新。候选构造为这一新增目标提供训练信号，结构画像和冻结 B1 分数决定候选身份，训练已知关系过滤与逐题记录限定其来源。三个主数据集相对本地 B1 的结果展示了选定配置表现；由于配置搜索和优化设置并未完全隔离，这些差异不能单独估计新增对比目标的因果贡献。下文的来源替换和频率匹配对照进一步说明，候选信号的性能解释依赖数据集、候选组成和答案选择规则。

候选身份与候选分布需要分开检验。 FB 的单信号消融显示，在既有 Full 配置下移除任一项都会降低直接解码 EM；但独立按训练图边频次成比例无放回抽样的控制仅达 70.57%，低于均匀随机的 86.48%。这一控制的负候选边缘分布到训练边分布的 JS 散度仅为 0.003，而 Full 为 0.272（图 11）；因此，在当前固定配置下，匹配原始训练边频率分布本身并不足以带来更高的预测表现。该观察不说明分布匹配有害，也不识别结构信号的因果效应。它与保留 Full 逐题频率配额后随机替换关系所得到的 89.83% 形成对照：全局边频率比例这一简单规则不足以复现 Full，而 Full 诱导的逐题频率桶配方与具体候选身份仍无法由现有比较完全拆开。由此可将结论限定为候选来源与频率组成共同变化时的条件性性能差异；Full 相对 Violation-only 的 2.81 个百分点差异仍不能被解释为排除频率因素后的独有结构收益。

配额匹配对照继承了什么。 配额由 Full 候选库逐题提取，因而保留了由 Full 选择过程带来的逐题频率桶组成。桶内随机化检验的是保留这一粗粒度组成后，精确选择关系身份带来多少额外差异。独立频次比例组则只使用训练图边数，结果明显较低，说明这一特定全局抽样规则并不足以复现当前 Full 表现；它没有检验其他频率变换或逐题条件分布。因此，现有直接解码与匹配重排证据既不支持频率决定全部收益，也不能证明结构无效或建立结构信号的因果效应。

总体接近不代表各关系层级一致。 689 题的判定变化在低、中、高频组并不均匀。Full 在低频组净减少 17 题，高频组净增加 23 题；按关系等权的平均 EM 也低于配额匹配组。当前数据没有显示长尾关系上的补偿性优势。训练图关系频次仅描述该关系的边数，不等同于训练 QA 数量、实体稀疏度或结构语义质量；这些分层差异需要在更多种子和独立配置中验证。

来源优势依赖数据集与答案选择规则。 NELL 的 Full 相对配额组在直接 EM 上高 0.26 个百分点，在重排 H@1 上低 0.30 个百分点；WN 则在两种规则下分别高 8.49 和 8.07 个百分点。后者表明 FB 的近零差异不能概括为所有图都只需保留频率配额，前者也说明直接解码与排序不能互相代替。WN 接近穷举的合法池中，Full 与配额组平均共享 8.644 个负候选，较高重叠与较大性能差异同时出现。当前比较没有独立控制图规模、候选自由度和历史模型选择，因此不将跨图差异单独归因于这些因素中的某一个，更不据此确立普遍的桶内身份机制。

性能观察与方法适用范围。 三个主数据集的配置表展示验证选定模型相对本地 B1 的单次表现，不能隔离优化配置与候选训练的贡献。FB 与 NELL 来源控制及 WN 历史条件对照进一步限定其解释；CoDEx-M 仍缺少对应来源控制。各控制使用此前为 Full 选定的设置，没有独立等预算调参，Full 历史权重复用也不等于三来源同版本重训。WN 的 55 条训练 QA 实体对未核实及 B1 复现差异继续保留。K 敏感性未在各 K 点补齐配额匹配对照。独立历史 NELL 长周期模型只在前 200 题有同候选 B1 重排比较，不能与当前 NELL 三来源全测试混合。多种子、完整持出正例重叠与未知真值风险审计均有待补齐。

固定候选库的价值与代价。 固定候选库将离线评分、候选构造与 Stage 2 优化分开，使每种来源替换及其频率组成能够被复核。它需要离线 B1 全关系评分的预处理，并固定训练期间的候选分布；历史分阶段成本见附录 B.6。本文的可追溯训练接口和条件对照提供了分析候选来源的手段；独有性能优势仍需相应证据，不能由来源审计本身推出。

8 结论

本文将结构反事实对比学习（SC-CL）作为 GRIP Stage 2 的关系判别扩展：保留参数内化阶段、原始提示和生成式 QA 目标，新增关系候选级 InfoNCE，并以训练图关系画像和冻结 GRIP 基线分数构建可追溯的反事实候选库。三个主数据集的单种子完整测试展示了验证选定配置相对本地 generation-only 基线的直接解码表现；这些比较包含配置搜索，尚不能单独识别新增训练目标的贡献。

固定配置来源控制显示，扩展的表现依赖候选组成和数据集。FB 的 Full 与 Full 诱导配额匹配随机在直接解码及重排上接近，而独立按训练边频次比例抽样的控制明显较低；NELL 的两种答案规则给出相反方向的小幅差异。第四个数据集 WN18RR 的探索性历史条件对照中，Full 直接 EM 达 86.89%、重排 H@1 达 88.42%，分别高于配额组 8.49 和 8.07 个百分点。WN 核验缺口与基线差异限制了其外推范围。当前证据支持将关系候选级对比目标纳入 GRIP 并对其训练信号进行分层评估；频率分层、候选数量和分布图刻画了适用边界，尚未识别普遍的独有采样机制。共同报告生成表现、候选排序、来源和频率组成，能够更完整地界定这一 GRIP 扩展的效果与适用范围。

A 补充设置、结果与候选审计

A.1 各数据集采样信号细图

以下图补充显示原始结构画像分数、缓存 B1 困难度、联合选择富集及逐题配对差异。百分位均在每题合法池内单独计算；配对曲线描述同一冻结库内的问题差异，不代表跨种子变异。

A.2 历史 NELL 排序模型的运行设置

表 9 根据附录 B的历史 NELL23K 排序运行配置和候选库元数据列出实际设置。Stage 2 从 Stage 1 adapter 初始化，优化候选级 InfoNCE 与生成损失。采样温度 τ_s 控制候选分布，候选温度 τ_c 控制对比目标。

Table 9: 历史 NELL23K 排序运行设置；不是正文验证选定的直接解码配置。数值对应训练种子 2026 的已完成运行。

字段	设置
基座模型	Qwen2.5-7B-Instruct
候选数 K	9
均匀混合系数 ρ	$1/3$
结构权重 α / 违例权重 β	1.0 / 1.0
采样温度 τ_s	0.25
候选损失温度 τ_c	1.0
候选损失权重 λ_{cand}	1.0
LoRA rank / alpha	4 / 8
LoRA 目标模块	`down_proj`, `up_proj`, `gate_proj`
Stage 2 轮数 / 优化步数	10 / 240
学习率 / 权重衰减	10^{-3} / 10^{-4}
单设备批大小 / 梯度累积步数	1 / 512
计算精度	bfloat16
候选库随机种子 / 训练种子	2026 / 2026
候选来源与过滤	train-only

A.3 WN18RR 三来源对照与历史候选池核验范围

WN18RR 共 12,334 条训练 QA，其中 2,709 条关系问题具备候选损失资格，每题包含九个互异候选。历史 Full 在完整验证集上选定 $\lambda_{\text{cand}} = 0.25$，训练 5 个 epoch、125 个优化步，候选损失温度为 1.0。LoRA rank/alpha 为 24/48，学习率为 10^{-3}，权重衰减为 10^{-4}，微批大小为 4，梯度累积为 128，精度为 bfloat16。新增 Uniform 与 Full 配额匹配随机保持这些设置及相同 Stage 1 初始化、QA 和资格门，各训练 125 步，不重新验证选模；Full 直接结果与权重复用历史获选模型。因此，这不是三种候选策略分别独立调参后的最优比较，也不是三个模型均以本次同版本代码重新训练。

完整 3,134 题测试保留原十一选项及其顺序；训练负例数 $K = 9$ 不改变评测选项数。三模型重排采用与 FB 相同的标签续接平均对数概率、$[-20, 20]$ 裁剪及原顺序破平局规则。Full 的直接 EM/H@1/MRR/H@3 为 86.89/88.42/93.15/97.83%，完整三个来源均列于正文表 5。同一测试文件上的本地 B1 直接 EM 为 32.67%，与原始 GRIP 报告的五次运行均值 64.30% 存在尚未解释的复现差异 (Feng et al., 2026)；新增来源控制没有修复 B1，也不据此宣称相对修复基线的增益。

候选来自训练关系词表，但训练实体对核验并非全部完成：2,654 条合格 QA 可与训练事实精确对应，另外 55 条历史评分记录的实体对为空，现有 QA 亦无法与训练实体对精确匹配。为保持与已训练 Full 一致，两个控制保留这些 QA 的原始文本与历史排除 mask，单独标记核验缺口；不能将这 55 条计为训练已知关系独立核验通过。因此，WN 结论限定为历史候选池条件下的单种子比较。

合法池中 2,703 题有 10 个负关系、6 题有 9 个负关系，$K = 9$ 接近穷举。Full 与 Uniform 平均共享 8.107 个候选，与配额组共享 8.644 个；配额匹配在 2,709 题全部成功，无跨桶回退，24,381 个槽位中 22,391 个因桶内池大小受限而被强制确定。较小候选自由度与较大结果差异同时存在，不能将 WN 表现单独归因于候选池规模或已证实的桶内身份机制；历史 Full 选模、代码版本与训练随机性等比较边界仍需保留。

A.4 跨图来源对照的完整配对变化与产物保留

表 10保留 NELL 与 WN 全部三对比较在两种答案规则下的纠错和退化。WN 的 Full 相对配额组在直接解码上纠错 388 题、退化 122 题，净增 266；重排纠错 365 题、退化 112 题，净增 253。NELL 对应的两种净差分别为 +13 与 −15 题，不将反向差异隐藏于总体解释中。所有结果仅对应训练种子 2026，未估计跨种子方差。

两图均保留三个模型的逐题响应、候选分数与排名、来源及频率诊断、冻结输入和配置。NELL 均匀随机组完成 32 步后，保存上限导致早期 8/16/24 步检查点不可恢复，最终 32 步模型及优化器、调度器、随机状态和训练日志保留；评测复用该最终模型，没有重训或替换。NELL 配额组的 8/16/24/32 步状态均保留。WN 两个新控制的 25/50/75/100/125 步模型与完整训练状态均保留。

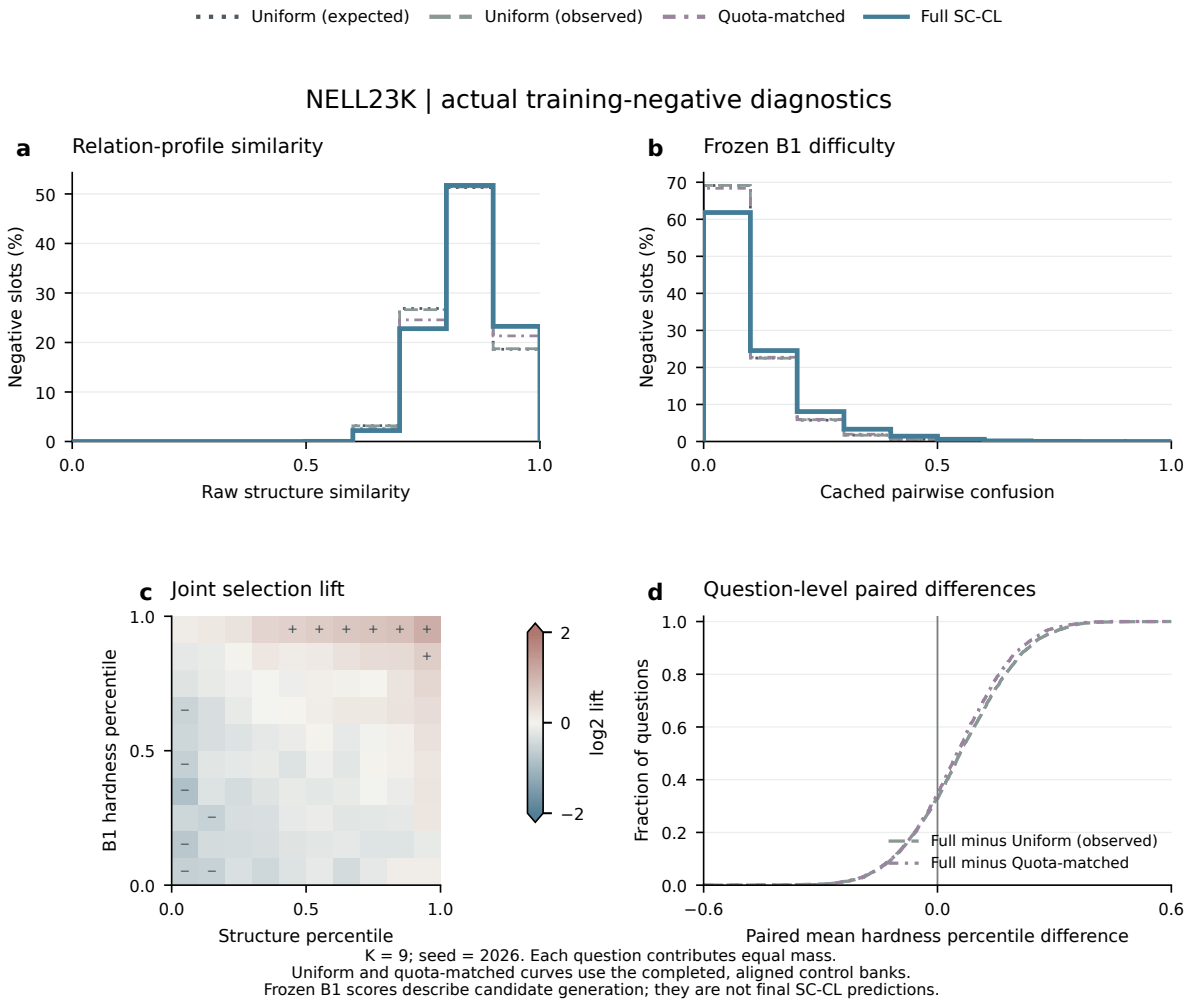


Figure 6: NELL23K 候选采样细图。a，关系画像结构相似度；b，缓存的冻结 B1 pairwise confusion；c，相对逐题合法池解析 Uniform 的联合 log2 富集；d，Full 与已训练均匀及频率配额匹配 bank 逐题平均困难度百分位的配对差异经验分布。每题等权，$K = 9$，seed=2026。

Table 10: 跨图三来源的逐题配对变化（seed=2026）。纠错/退化均按左侧方法减右侧方法计算；Δ 单位为百分点。直接 EM 与重排 H@1 分别计数，不将不同答案选择规则混为一种指标；不提供跨种子不确定性估计。

数据集	比较方向	直接纠错/退化	Δ EM	排序纠错/退化	Δ H@1
NELL23K	Full − 均匀随机	75/44	+0.63	52/44	+0.16
	Full − 配额匹配	60/47	+0.26	32/47	-0.30
	配额匹配 − 均匀随机	62/44	+0.36	46/23	+0.47
WN18RR	Full − 均匀随机	465/92	+11.90	437/79	+11.42
	Full − 配额匹配	388/122	+8.49	365/112	+8.07
	配额匹配 − 均匀随机	268/161	+3.41	259/154	+3.35

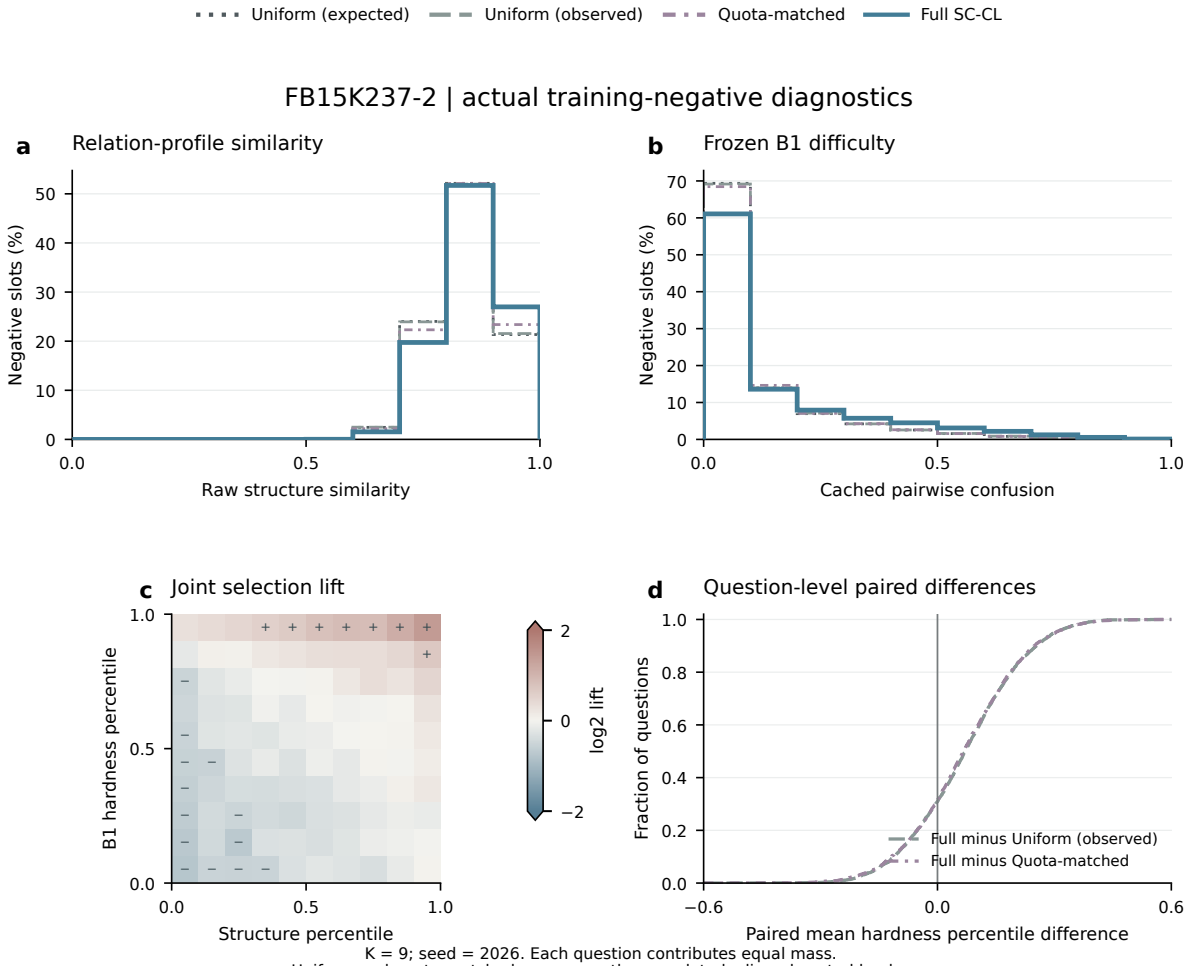


Figure 7: FB15K237-2 候选采样细图。面板定义同图 6；实际分布同时展示 Full、均匀随机和配额匹配控制。所有候选来源均已完成且题目对齐。每题等权，$K = 9$，seed=2026。

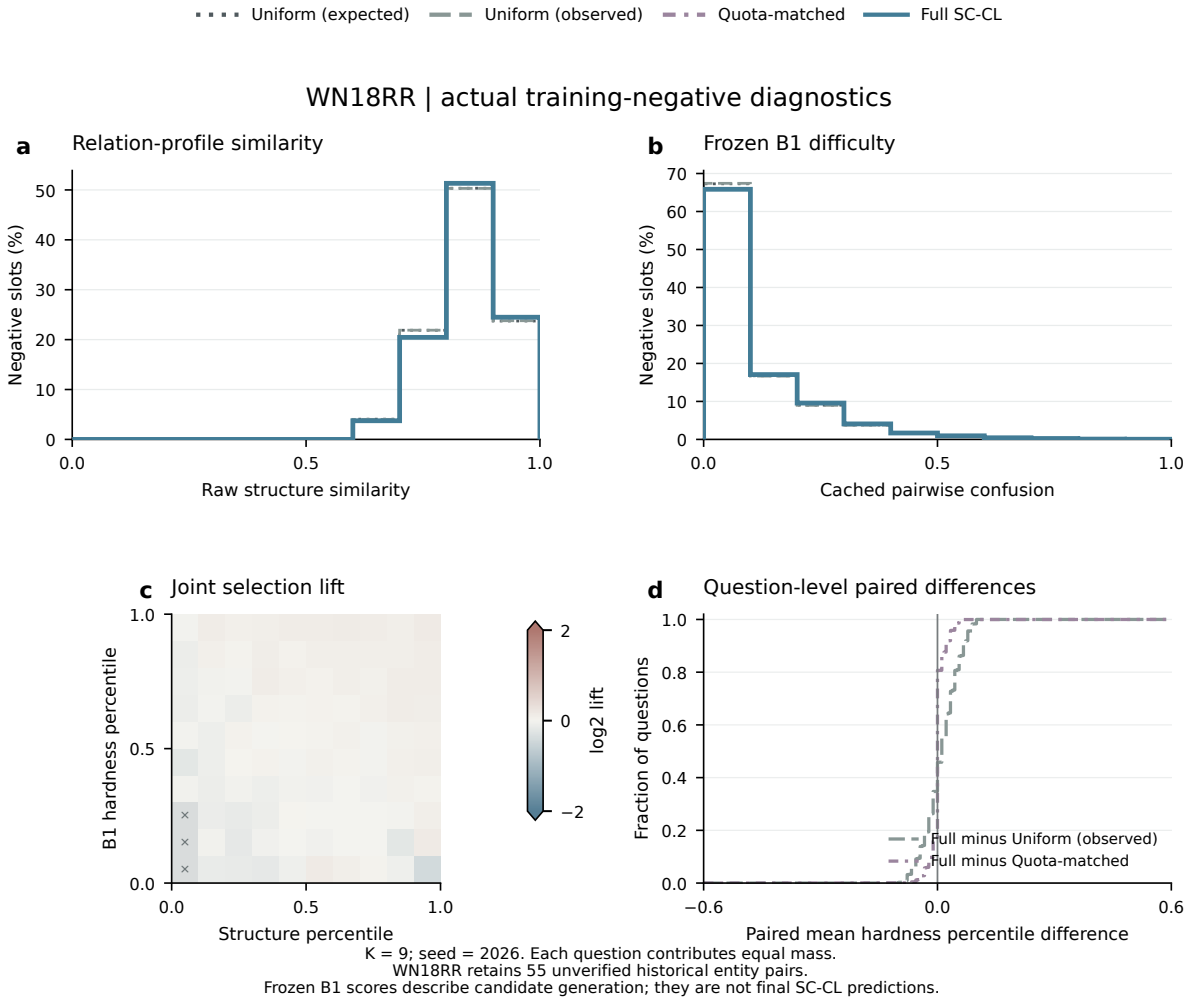


Figure 8: WN18RR 候选采样细图。面板定义同图 6；沿用历史候选池并保留 55 道实体对未核实问题。该数据集每题合法负关系数为 9 或 10，$K = 9$，因而题内 rank 百分位较离散；图为历史候选池条件下的单种子描述。

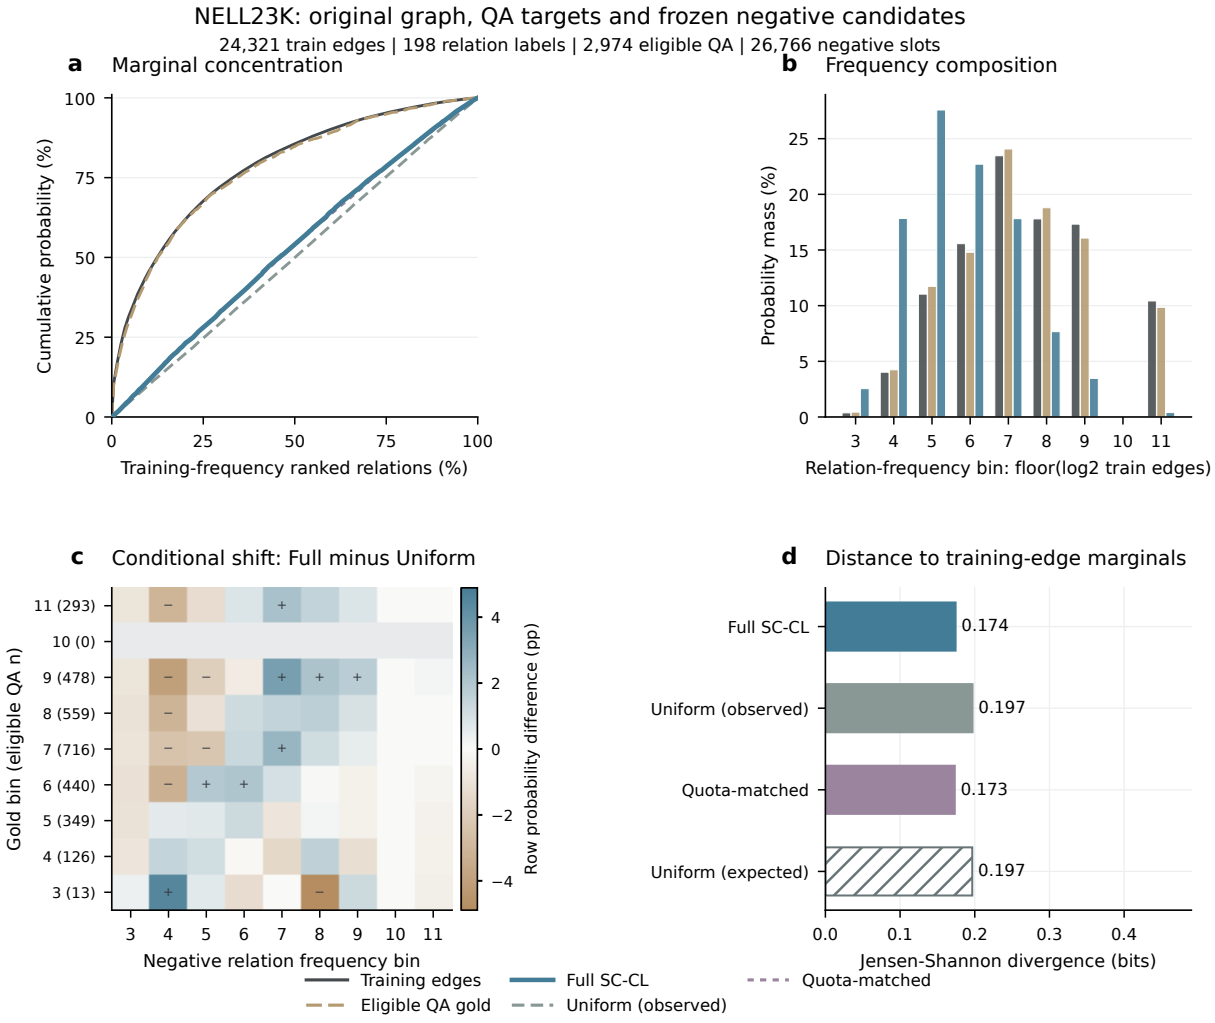


Figure 9: NELL23K 采样分布：24,321 条训练边、198 个关系标签、2,974 道合格训练 QA 与 26,766 个 Full 负候选槽位。a，固定训练频次排序的累积分布；b，训练频次的 $\lfloor \log_2 f(r) \rfloor$ 桶质量；c，在相同 gold 频率桶内，Full 负候选桶比例减去合法池 Uniform 解析期望，单位为百分点，每行归一化，纵轴括号为 QA 数；灰色为无观测 gold 桶，正负符号标出绝对值不低于本面板最大值 35% 的差异；d，到训练边关系分布的 JS 散度。条件桶样本数不同，较大色差不代表统计显著。

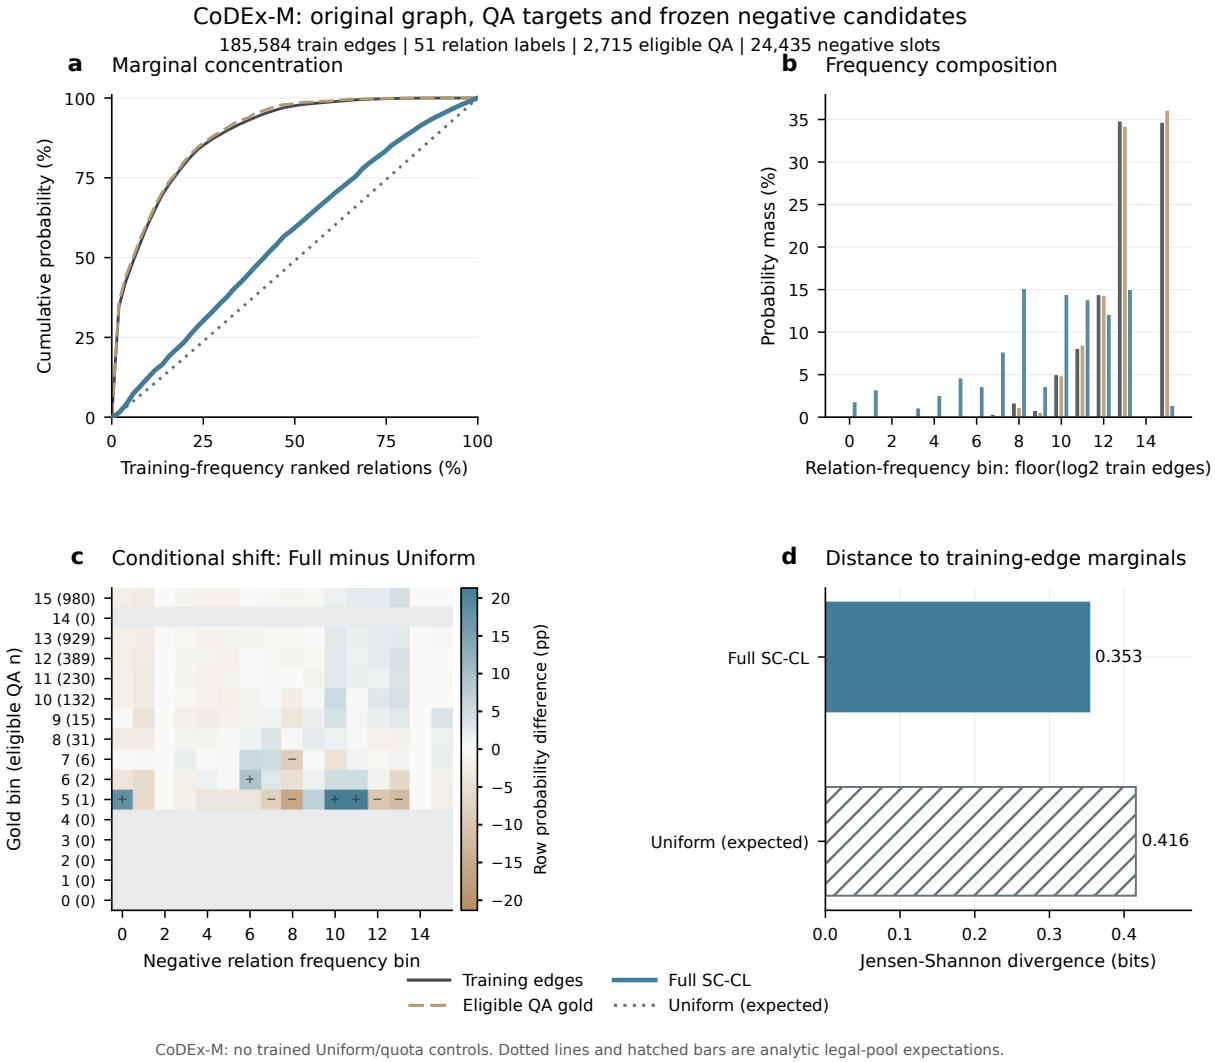


Figure 10: CoDEx-M 采样分布：185,584 条训练边、51 个关系标签、2,715 道合格训练 QA 与 24,435 个 Full 负候选槽位。面板定义同图 9。该数据集未运行匹配 Uniform 或配额控制；点线与斜线柱仅表示逐题合法池均匀解析期望。热图使用所有非空 gold 桶，并标出各桶 QA 数；稀少问题形成的条件差异不用于机制或显著性推断。

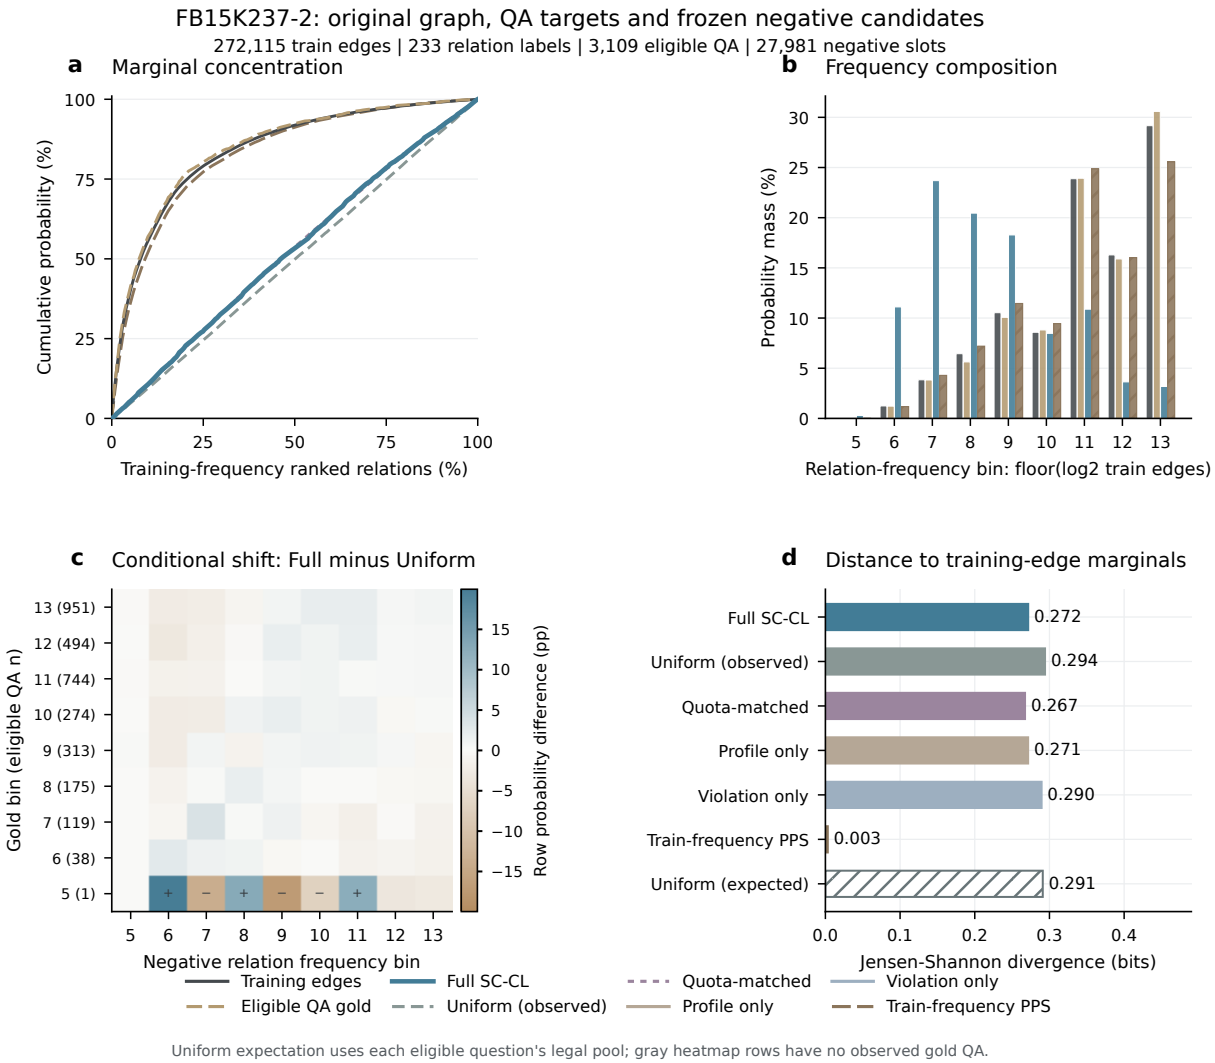
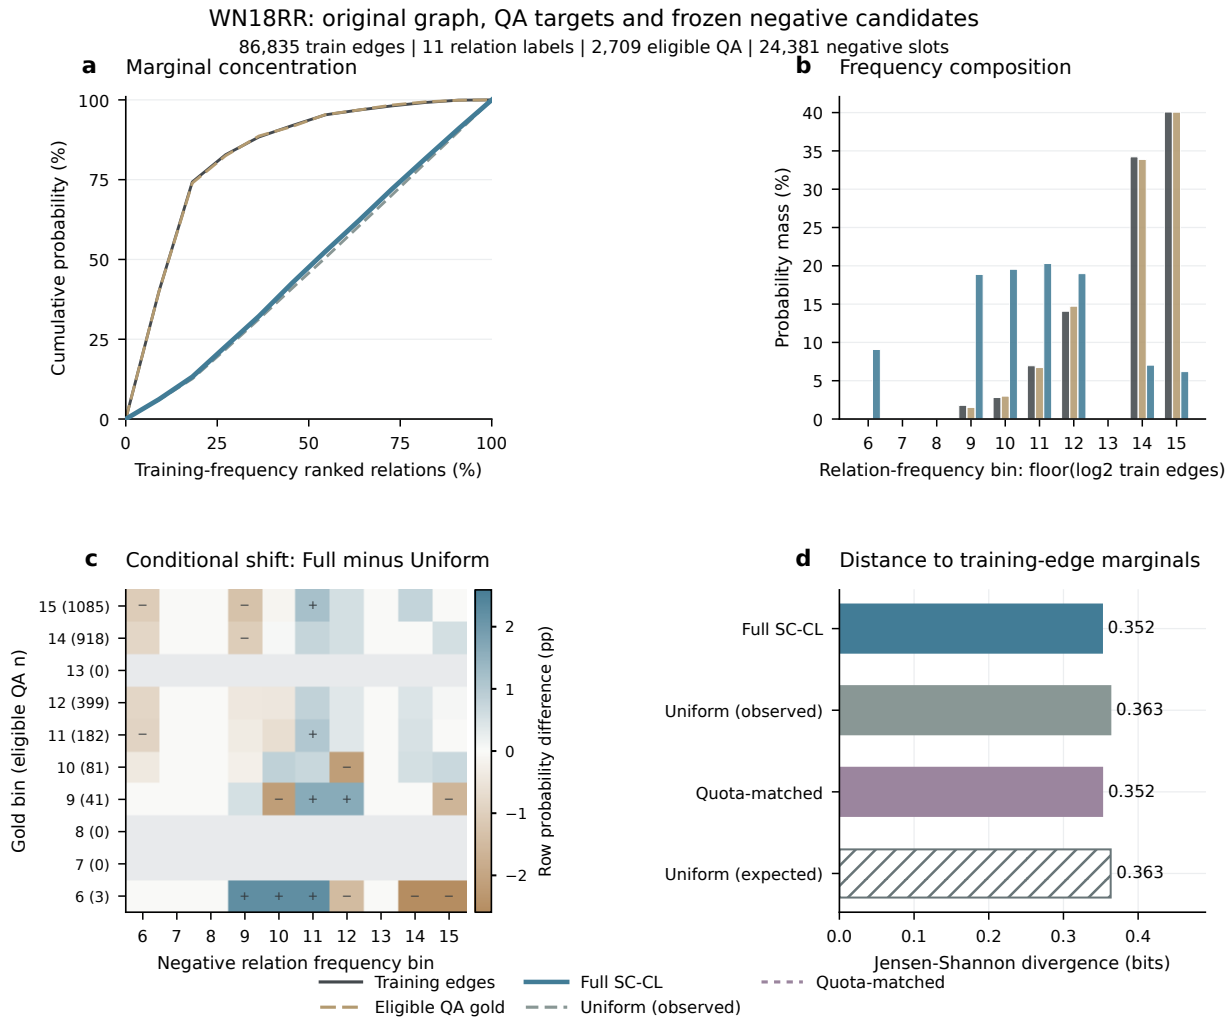


Figure 11: FB15K237-2 采样分布：272,115 条训练边、233 个映射后关系标签、3,109 道合格训练 QA 与 27,981 个 Full 及独立频次比例组负候选槽位；原始训练关系 ID 为 237 个。面板定义同图 9；a、b、d 另显示独立训练频次比例采样。其实际负候选边缘分布到训练边分布的 JS 散度为 0.003，Full 为 0.272；分布接近不代表预测性能更高，该组直接 EM 为 70.57%。c 仍显示 Full 相对合法池 Uniform 的条件频率桶差异；d 同时保留两个单信号控制。Full 与配额匹配组逐题频率桶配额相同，但具体关系可不同。



WN: 55 historical training pairs unverified; retain parent masks. Conditional baseline is the analytic legal-pool Uniform.

Figure 12: WN18RR 采样分布：86,835 条训练边、11 个关系标签、2,709 道合格训练 QA 与 24,381 个 Full 负候选槽位。面板定义同图 9。55 条历史训练 QA 实体对未独立核实，沿用原排除 mask；本图为历史池条件分析，不表示全部 train-pair 过滤已核验。排除这 55 条后，Full 到训练边分布的 JS 散度为 0.3520，与全体 0.3516 接近；两种 Full 边缘分布的 TV 为 0.00078，该敏感性检查不能修复原核验缺口。

A.5 FB15K237-2 候选 InfoNCE 参考实验

该参考实验展示独立配置下的候选 InfoNCE 表现。B1 与 InfoNCE-i0 均在同一本地测试文件的 10,000 条问题上评分；i0 使用单独的配对候选文件、LoRA rank 24、Stage 2 训练 5 个 epoch 和候选损失权重 0.1。表 11 单独标记该配置，当前 SC-CL 直接解码结果见正文表 2，该历史 i0 不与当前 FB 控制混合。

Table 11: FB15K237-2 候选 InfoNCE 参考结果（%，10,000 条测试问题）。InfoNCE-i0 为独立候选及训练配置，方法身份与 SC-CL 分别记录。

方法	直接解码 EM	重排 H@1	MRR	H@3
B1	73.23	79.91	88.01	95.80
InfoNCE-i0	88.69	91.62	95.41	99.20

A.6 候选来源与真值状态审计

候选库的来源检查核对训练划分、问题标识、目标关系、每题九个互异候选和训练已知关系过滤结果。文件哈希、脚本版本、候选评分及模型配置共同标识运行产物。来源合规与事实真值分别记录：训练已知关系冲突表示候选命中该实体对的训练关系，持出正例重叠表示候选命中持出划分中的已知正例，其余候选保留开放世界未判定状态。

实体替换与关系替换使用各自的候选空间。CoDEx 的人工核验实体替换负例用于其三元组判断设定 (Safavi & Koutra, 2020)；固定实体对后的关系替换，按训练已知关系和持出正例分别核对真值状态。

Table 12: 候选来源与真值状态的审计规则。该表定义状态分类，实测来源检查结果见正文。

状态	判定规则
训练已知关系冲突	候选属于当前实体对的训练已知关系集合 $T_{\text{tr}}(h,t)$。
持出正例重叠	候选对应的三元组出现在持出划分的已知正例中；该记录用于审计。
开放世界未判定	候选未被已知正例或其他核验证据确认，真值维持未判定。
候选不足	训练已知关系过滤后 $\lvert P_q\rvert < K$，记录该问题及原因。
问题对齐异常	候选库与训练任务的问题标识、目标关系或候选文本不一致。

A.7 候选库记录与构造伪代码

每条候选库记录包含问题标识、数据划分、实体对、目标关系、候选关系和采样来源。逐候选记录包括结构相似度、违例度、utility、B1 候选分数及其与目标分数的差值；来源清单包含过滤划分、采样参数、随机种子、脚本版本和文件哈希。这些字段将候选采样结果关联到原始任务及其离线评分。

```
for q in train_questions:
    assert q.split == "train"
    P = train_relations - {q.gold} - known_train_relations(q.head, q.tail)
    if len(P) < K:
        record_insufficient_pool(q)
        continue
    for r in P:
        s = profile_similarity(phi[q.gold], phi[r])
        v = b1_score_violation(q, r)
        u[r] = alpha * s + beta * v
    candidates = sample_without_replacement(
        P, mixture_softmax(u, rho, tau_s), K=9)
    write_frozen_bank(q, candidates, manifest=provenance)
```

候选库按训练来源限定、已知关系过滤和候选采样的顺序构建。来源检查核对问题标识与关系文本的一致性，固定候选库供整个 Stage 2 使用。

A.8 数据、模型与产物记录

完整直接解码比较使用 NELL23K、CoDEx-M 和 FB15K237-2，另有独立历史 NELL 排序运行及 WN18RR 补充结果；基座模型为 Qwen2.5-7B-Instruct (Qwen Team, 2024)，LoRA 用于参数高效训练 (Hu et al., 2022)。实验处理既有知识图谱关系问题，未新增个人敏感数据采集。预测、候选分数、训练配置、adapter 与来源清单保存在本地实验归档中，当前未提供公开下载地址。

A.9 FB 候选来源对照的复现设置

FB 六种候选来源固定 Stage 1、12,136 条 QA、3,109 条候选资格和每题九候选。LoRA rank 为 24，alpha 为 48，目标模块为 `down_proj`、`up_proj` 和 `gate_proj`；微批大小为 1，梯度累积为 512，精度为 bfloat16。获选学习率为

9.4762275×10^{-4}，权重衰减为 8.8899022×10^{-5}，Adam epsilon 为 10^{-8}(Kingma & Ba, 2015; Loshchilov & Hutter, 2019)；候选损失权重为 0.11229874，候选温度为 0.88639612。训练实际停止于 32 步，同时保留五轮、120 步线性调度。候选采样参数与损失温度分别记录，不将采样温度 0.25 当作候选损失温度。

Full 采用结构/违例权重 1/1，Profile-only 为 1/0，Violation-only 为 0/1；三组均保留均匀下限 $1/3$ 和采样温度 0.25。均匀随机从完整合法池无放回抽样。Full 由验证集选定；Random 复用其配置并曾完整评估验证集，单信号和配额匹配组则预先固定 32 步，不执行新完整验证或重新选模。

独立频次比例组在每道合格训练题 q 的合法池 P_q 中按训练边数 $f(r)$ 逐次无放回抽样，固定指数为 1：第 j 次抽取的条件概率为 $f(r)/\sum_{u\in P_q\setminus S_{j-1}} f(u)$，其中 S_{j-1} 为此前已抽取关系集合。该采样器不使用 Full 候选、Full 逐题配额、B1 分数或结构画像，也不加均匀混合下限。其与 Full、配额匹配、均匀、Profile-only 及 Violation-only 组共用相同训练 QA、合法池、Stage 1 与优化设置，固定 seed=2026，实际训练 32 步并保持 120 步调度。一次完整测试和同题原十选项重排均在训练配置冻结后执行，不做新完整验证或选模，无新 HPO 或重复种子。

对 Full 频率配额匹配组，记 Full 候选的桶序列为 $(b_1,\dots,b_9)$，其中 $b_i=\lfloor \log_2 f(r_i)\rfloor$。对桶 b，合法池为 $P_{q,b}=\{r\in P_q : b(r)=b\}$，配额为 $m_{q,b}=\sum_i \mathbf{1}[b_i=b]$。在 $P_{q,b}$ 中均匀无放回抽取 $m_{q,b}$ 个关系，依次放回原桶槽位；对同桶第 j 次抽取，其条件概率为 $1/(|P_{q,b}|-j+1)$。配额不足时拒绝继续，不跨桶补齐。Full 候选允许被重新抽到，避免通过排除原候选引入额外干预。所有统计仅来自训练图和已冻结 Full 训练候选，不使用验证/测试关系频次。前者继承 Full 逐题桶序列，独立频次比例组则只按全局训练边数设置抽样概率，两者控制的分布信息不同。

分层分析在完整测试结果已观察后进行。分组边界取训练词表关系频次排序的第 $\lceil R/3\rceil$ 和第 $\lceil 2R/3\rceil$ 个值（R 为训练关系数），分别为 215 和 689；同频次保持同组。按测试中出现的关系等权平均其 EM，得到表 13；未在测试中出现的训练关系不补零。各组的测试关系数分别为低频 67、中频 72、高频 76，完整测试共 215 个关系。该统计与按测试题等权的总体 EM 具有不同权重。

Table 13: FB 五方法的按关系等权平均 EM（%）。分别在各组测试中出现的关系内等权；全体一列对全部 215 个测试关系等权，而不是对三组均值等权。低、中、高频组分别包含 67、72 和 76 个测试关系。

方法	低频	中频	高频	全体关系
均匀随机-9	54.60	70.21	85.03	70.59
Profile-only-9	44.62	62.26	80.83	63.33
Violation-only-9	49.21	63.18	83.86	66.14
Full 配额匹配随机-9	60.31	79.89	86.57	76.15
Full SC-CL-9	57.43	78.71	87.57	75.21

A.10 FB 匹配重排与 K 敏感性的补充设置

三来源重排复用正文固定模型，全部使用同 10,000 题和原十选项，不将重排输出重新计作直接解码。评分对包含答案标签的续接 token 取平均对数概率，沿用原评分实现中区间 $[-20, 20]$ 的裁剪规则；同分时按原选项次序破平局。测试中 12 题含非目标选项的归一化同名干扰项；保留原选项与顺序，目标关系仍唯一，不合并或删除这些题。

K 敏感性仅新增 K3 和 K15 两次训练，各保持正文 FB 优化器、损失和 32 步训练、120 步调度；K9 模型及重排复用。两个新候选库在相同训练问题上构造，候选来自同一合法池，采用嵌套抽样；测试始终保持原十选项。K3 减 K9 的纠错/退化为 199/156，K15 减 K9 为 148/130，净差分别为 43 与 18。单个种子无法刻画训练随机性，三个 K 点也不用于重新选择主结果模型。

过程记录的 K3、K15 训练耗时分别约为 9,944 秒和 14,280.6 秒。前者不包含首次保存中断造成的额外开销；K9 含恢复过程的总训练成本未重测。因此，这些记录仅说明本轮完整执行的训练阶段耗时，不构成三组完整成本比较。更大的 K 会改变候选计算量，固定优化步数不等同于等 FLOPs 预算。

B 历史 NELL 候选重排与成本

B.1 实验设置与评价指标

本附录记录独立的历史排序运行，模型不同于正文表 2的验证选定模型。该运行使用 NELL23K、Qwen2.5-7B-Instruct 和训练种子 2026，在 4,943 条十选一关系问题上评价 SC-CL。候选重排通过 teacher-forced continuation score 逐一评分，以 H@1、MRR 和 H@3 衡量给定候选集合中的关系排序；直接解码 EM 衡量原始输出路径下的预测。两种评估使用相同题目与选项，分别报告结果。

B1 为原始 GRIP 的 generation-only 基线。B1 与 SC-CL 的同候选重排比较覆盖测试文件的前 200 题；两者沿用各自现有训练配置，比较条件集中见第 7 节。完整测试集报告 SC-CL 的排序表现，以及两个模型的直接解码表现。本次历史运行的训练设置见附录表 9，WN18RR 的直接解码补充结果见附录 A.3。

B.2 NELL23K 候选排序结果

SC-CL 在完整测试集上达到 95.27% MRR、91.52% H@1 和 99.07% H@3。在同候选前 200 题上，SC-CL 的 MRR 为 94.96%，比 B1 高 1.60 个百分点；H@1 为 91.00%，比 B1 高 2.50 个百分点。表 14 给出全量结果与配对结果。

Table 14: NELL23K 候选重排结果（%，训练种子 2026）。配对区块按测试文件顺序取前 200 题，两个模型使用相同问题与候选列表；全量区块报告 SC-CL 的 4,943 题结果，全量 B1 重排尚未完成。Δ 为配对子集上的百分点差。

范围	模型	n	H@1	MRR	H@3
配对前 200 题	B1	200	88.50	93.36	97.50
配对前 200 题	SC-CL-9	200	**91.00**	**94.96**	**99.50**
配对差异	Δ(SC-CL-9, B1)	–	+2.50	+1.60	+2.00
全量测试	SC-CL-9	4,943	91.52	95.27	99.07

B.3 配对预测的逐题变化

在同候选前 200 题上，9 题由 B1 错误转为 SC-CL 正确，4 题发生反向变化，净增加 5 题正确预测；其余为 173 题共同正确和 14 题共同错误。逐题变化与 H@1 的 2.50 个百分点差异一致，并展示两模型预测差异的分布。

B.4 直接解码与候选评分

在相同的 4,943 条测试问题上，SC-CL 与 B1 的直接解码 EM 分别为 87.03% 和 87.46%，相差 −0.43 个百分点（表 15）。SC-CL 通过逐候选评分选择答案时，H@1 为 91.52%。直接解码考察关系文本输出，逐候选评分考察给定选项间的排序，本文围绕后一目标组织主要分析。

Table 15: NELL23K 直接解码结果（%，4,943 题，训练种子 2026）。模型在列出相同十个选项的题目上生成关系文本，按 Exact Match 计分。

模型	直接解码 EM
B1	87.46
SC-CL-9	87.03

B.5 候选构造与来源追溯

NELL23K 的固定候选库覆盖 3,253 条训练问题，每题包含九个互异关系，候选构造失败数为 0。来源检查记录了训练划分、任务问题对齐与候选库标识；采样清单保存结构画像、B1 违例度及采样参数。SC-CL Stage 2 完成 10 个 epoch、240 个优化步，归档了 adapter、直接解码预测和候选重排输出。这些记录将候选构造与模型训练关联到同一运行，便于追溯每个候选的来源。

B.6 离线构造与运行成本

该表对应一个独立的历史 NELL23K 排序运行：其候选库覆盖 3,253 条训练问题，Stage 2 训练 240 步；它不同于正文直接解码比较所用的 2,974 道候选资格问题、32 步配置。训练记录的硬件为 NVIDIA GeForce RTX 3090（24 GiB）。表 16 分阶段列出这次历史运行的资源用量：离线 B1 评分覆盖 644,094 个训练关系候选，Stage 2 处理 12,148,720 个输入 token，完整测试重排覆盖 4,943 条问题。各阶段耗时按日志分别记录，不应解释为正文当前主配置的成本；固定候选库在该历史训练期间复用离线采样结果。

Table 16: NELL23K 单次运行的分阶段成本。显存数值对应离线评分阶段的记录。

阶段	耗时（秒）	峰值显存（GiB）
冻结 B1 离线评分	19,027	15.21
Stage 2 联合训练	80,870	–
全测试候选重排	3,567	–

References

Kian Ahrabian, Aarash Feizi, Yasmin Salehi, William L. Hamilton, and Avishek Joey Bose. Structure aware negative sampling in knowledge graphs. In *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing*, pp. 6093–6101, 2020. doi: 10.18653/v1/2020.emnlp-main.492. URL https://aclanthology.org/2020.emnlp-main.492/.

Antoine Bordes, Nicolas Usunier, Alberto Garcia-Duran, Jason Weston, and Oksana Yakhnenko. Translating embeddings for modeling multi-relational data. In *Advances in Neural Information Processing Systems*, volume 26, 2013. URL https://proceedings.neurips.cc/paper/2013/hash/1cecc7a77928ca8133fa24680a88d2f9-Abstract.html.

Liwei Cai and William Yang Wang. KBGAN: Adversarial learning for knowledge graph embeddings. In *Proceedings of the 2018 Conference of the North American Chapter of the Association for Computational Linguistics*, 2018. URL https://aclanthology.org/N18-1133/.

Ching-Yao Chuang, Joshua W. Robinson, Yen-Chen Lin, Antonio Torralba, and Stefanie Jegelka. Debiased contrastive learning. In *Advances in Neural Information Processing Systems*, volume 33, 2020. URL https://papers.nips.cc/paper/2020/hash/63c3ddcc7b23daa1e42dc41f9a44a873-Abstract.html.

Tim Dettmers, Pasquale Minervini, Pontus Stenetorp, and Sebastian Riedel. Convolutional 2d knowledge graph embeddings. In *Proceedings of the Thirty-Second AAAI Conference on Artificial Intelligence*, volume 32, 2018. doi: 10.1609/aaai.v32i1.11573. URL https://ojs.aaai.org/index.php/AAAI/article/view/11573.

Jiarui Feng, Donghong Cai, Yixin Chen, and Muhan Zhang. GRIP: In-parameter graph reasoning through fine-tuning large language models. In *Proceedings of the 32nd ACM SIGKDD Conference on Knowledge Discovery and Data Mining*, pp. 1120–1131, 2026. doi: 10.1145/3770855.3817895. URL https://dl.acm.org/doi/10.1145/3770855.3817895.

Aidan Hogan, Eva Blomqvist, Michael Cochez, Claudia d'Amato, Gerard de Melo, Claudio Gutierrez, Sabrina Kirrane, Jose Emilio Labra Gayo, Roberto Navigli, Sebastian Neumaier, Axel-Cyrille Ngonga Ngomo, Axel Polleres, Sabbir M. Rashid, Anisa Rula, Lukas Schmelzeisen, Juan Sequeda, Steffen Staab, and Antoine Zimmermann. Knowledge graphs. *ACM Computing Surveys*, 54(4):1–37, 2021. doi: 10.1145/3447772. URL https://doi.org/10.1145/3447772.

Edward J. Hu, Yelong Shen, Phillip Wallis, Zeyuan Allen-Zhu, Yuanzhi Li, Shean Wang, Lu Wang, and Weizhu Chen. Lora: Low-rank adaptation of large language models. In *International Conference on Learning Representations*, 2022. URL https://arxiv.org/abs/2106.09685.

Shaoxiong Ji, Shirui Pan, Erik Cambria, Pekka Marttinen, and Philip S. Yu. A survey on knowledge graphs: Representation, acquisition, and applications. *IEEE Transactions on Neural Networks and Learning Systems*, 33(2):494–514, 2022. doi: 10.1109/TNNLS.2021.3070843. URL https://arxiv.org/abs/2002.00388.

Diederik P. Kingma and Jimmy Ba. Adam: A method for stochastic optimization. *International Conference on Learning Representations*, 2015. URL https://arxiv.org/abs/1412.6980.

Ilya Loshchilov and Frank Hutter. Decoupled weight decay regularization. In *International Conference on Learning Representations*, 2019. URL https://arxiv.org/abs/1711.05101.

Qwen Team. Qwen2.5 technical report. *arXiv preprint arXiv:2412.15115*, 2024. URL https://arxiv.org/abs/2412.15115.

Tara Safavi and Danai Koutra. CoDEx: A comprehensive knowledge graph completion benchmark. In *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing*, pp. 8328–8350, Online, 2020. Association for Computational Linguistics. doi: 10.18653/v1/2020.emnlp-main.669. URL https://aclanthology.org/2020.emnlp-main.669/.

Zhiqing Sun, Zhi-Hong Deng, Jian-Yun Nie, and Jian Tang. Rotate: Knowledge graph embedding by relational rotation in complex space. In *International Conference on Learning Representations*, 2019. URL https://arxiv.org/abs/1902.10197.

Théo Trouillon, Johannes Welbl, Sebastian Riedel, Eric Gaussier, and Guillaume Bouchard. Complex embeddings for simple link prediction. In *Proceedings of the 33rd International Conference on Machine Learning*, volume 48 of *Proceedings of Machine Learning Research*, pp. 2071–2080, 2016. URL https://proceedings.mlr.press/v48/trouillon16.html.

Liang Wang, Wei Zhao, Zhuoyu Wei, and Jingming Liu. SimKGC: Simple contrastive knowledge graph completion with pre-trained language models. In *Proceedings of the 60th Annual Meeting of the Association for Computational Linguistics*, pp. 4281–4294, 2022. doi: 10.18653/v1/2022.acl-long.295. URL https://aclanthology.org/2022.acl-long.295/.

Jun Xia, Lirong Wu, Ge Wang, Jintao Chen, and Stan Z. Li. ProGCL: Rethinking hard negative mining in graph contrastive learning. In *Proceedings of the 39th International Conference on Machine Learning*, volume 162 of *Proceedings of Machine Learning Research*, pp. 24332–24346. PMLR, 2022. URL https://proceedings.mlr.press/v162/xia22b.html.

Liang Yao, Chengsheng Mao, and Yuan Luo. Kg-bert: Bert for knowledge graph completion. In *arXiv preprint arXiv:1909.03193*, 2019. URL https://arxiv.org/abs/1909.03193.