面向参数内化生成式知识图谱推理的双信号结构反事实对比学习

Anonymous Authors
Paper under double-blind review

摘要

参数内化生成式知识图谱推理（如 GRIP）通过将图拓扑与多步关系语义压缩至大语言模型参数中，实现了极低上下文开销的高效推理，但其依赖的词表级自回归交叉熵目标缺乏在完整关系标签层面拉开易混淆竞争关系的判别约束。为突破这一瓶颈，本文提出**结构反事实对比学习（Structure-Counterfactual Contrastive Learning, SC-CL）**：在利用训练图实施无泄漏已知伴随关系过滤后，SC-CL 将训练图五维对数拓扑画像相似度与冻结生成基线 B1 的实例级边界违例度耦合于带均匀探索下限的混合分布中，离线构建静态困难负例池并与自回归生成目标联合微调 Stage 2 参数。在 NELL23K、CoDEx-M 和 FB15K237-2 三大基准上的实验表明，SC-CL 在主评测指标（选项感知直接生成准确率 Direct EM）上相对同协议生成基线 B1 分别显著提升 +3.22、+2.24 和 +8.03 个百分点（将剩余错误率最高压缩 44.3%，Holm–Bonferroni 校正后 $p_{\mathrm{Holm}} \leq 4.03 \times 10^{-13}$）。在 FB15K237-2 受控消融中，SC-CL 克服了纯宏观结构采样单独使用时的负迁移（-1.59 pp），实现显著的双信号超加性协同（Micro-EM 达 89.90%、215 关系等权 Macro-EM 达 75.21%，相对均匀负采样分别提升 +3.42 pp 与 +4.62 pp，$p_{\mathrm{Holm}} = 1.29 \times 10^{-35}$），且在极小负例预算（$K = 3$）下即可将次要诊断指标（闭集候选续接重排 H@1）推高至 95.28% 并节省 30.4% 训练时间。进一步地，通过引入事后逐题频率桶配额匹配探针（Post-Hoc Quota-Matched Oracle Probe），我们证实 SC-CL 的宏观增益主要通过自动为每个查询选出结构相容的自适应频率桶组成来承载（复现 97.9% Micro 与 120.3% Macro 增益），而桶内细粒度身份则在占据 85% 题量的高频核心关系上提供 +1.00 pp 的 Macro-EM 边界锐化优势。

1 引言

将大规模知识图谱（Knowledge Graphs, KGs）的拓扑结构与多跳关系语义直接内化至大语言模型（LLMs）的参数空间中，是近年来知识图谱推理领域的重要范式突破 [22, 29, 25, 7]。不同于传统低维几何空间嵌入模型（如 TransE [2]、ComplEx [23]、RotatE [20]），亦不同于在推理阶段将庞大的局部子图序列化后拼接至提示上下文的检索增强方法，以 GRIP（In-Parameter Graph Reasoning）[7] 为代表的参数内化生成框架通过两阶段微调（Stage 1 图关联语料预微调与 Stage 2 任务指令微调），使语言模型仅凭百余个输入 token 即可在多项关系预测基准上大幅超越图到嵌入模型（OFA/GOFA）及长上下文基线。然而，在给定有序实体对 (h, t) 及候选提示预测目标关系 r^+ 的核心任务中，原始 GRIP 在 Stage 2 仅依赖词表 token 级别的自回归交叉熵损失 $\mathcal{L}_{\mathrm{gen}}$ 进行优化。由于知识图谱的关系词表虽然规模有限但语义高度耦合，最大化单一正例标签的逐 token 条件似然并不等价于在完整关系候选空间上建立了足够宽的判别间隔。当面对拓扑角色相近或局部语境高度重叠的竞争关系时，纯生成微调模型极易在决策边界附近出现首词切分模糊与高置信度误判。

在 Stage 2 引入关系候选级对比学习（InfoNCE [8, 24]）是拓宽判别间隔、抑制易混淆替代关系的自然途径，但这也引出了开放世界假设（Open-World Assumption, OWA）[10, 12] 下困难负关系采样的核心设计难题：**应当如何为固定实体对 (h, t) 构造既具高判别梯度、又免受假阴性污染与单信号盲区干扰的高质量负关系池？** 现有困难负采样路线在应用于生成式关系解码时面临三重局限：第一，知识图谱中同一实体对 (h, t) 之间常并存多条合法事实边，直接从关系词表 $\mathcal{R}_{\mathrm{tr}} \setminus \{r^+\}$ 中抽取负例极易将训练图中已存在的伴随正例关系误作负例挤压；第二，单纯依赖全局图拓扑先验（如关系频次、度数或邻域结构 [1]）的采样器完全脱离了当前查询实体对 (h, t) 的局部语境，容易为同一目标关系无差别地引入局部无关的全局干扰项，甚至引发负迁移；第三，单纯依赖在线模型打分 [3] 或单模型边界分数的挖掘受制于模型早期置信度偏差与开放世界潜在假阴性冲突 [5, 26]，且在线全词表

重复前向评估会带来高昂的训练期计算开销。此外，既有知识图谱负采样研究主要聚焦于在选定语义准则下缓解假阴性风险，却从未在生成式大语言模型关系解码中剥离采样器所诱导的边缘频率桶组成（Marginal Frequency Composition）与桶内细粒度关系身份（Within-Frequency Relational Identity）对最终性能的不同贡献 [17]。

为攻克上述挑战并全面释放参数内化图推理的判别潜力，本文提出**结构反事实对比学习（Structure-Counterfactual Contrastive Learning, SC-CL）**，一种兼具高准确率、高样本效率与严格可解释性的双信号对比微调方法（图 1）。首先，SC-CL 定义了严格基于训练边集 $\mathcal{E}_{\mathrm{tr}}$ 的开放世界无泄漏过滤池 $\mathcal{P}_q = \mathcal{R}_{\mathrm{tr}} \setminus (\{r^+\} \cup T_{\mathrm{tr}}(h,t))$，从源头上杜绝训练已知伴随关系的假阴性冲突（事后核验表明测试集未观测持出正例的误中率低于 0.01%）。其次，SC-CL 创新性地耦合两类正交信号构建反事实关系采样分布：一是基于训练图五维对数拓扑统计量（关系边数、头尾实体覆盖广度及连接实体平均总出/入度）提取的**全局结构画像相似度** $s_{\mathrm{str}}(q,r)$；二是由冻结 Stage 1 生成基线 B1 在当前查询上的续接对数似然差导出的**局部实例级边界违例度** $V_{\mathrm{B1}}(q,r)$。局部违例度负责锚定当前实体对 (h,t) 的真实混淆邻域，全局拓扑画像则充当结构相容性过滤器以剔除异质噪声。两者通过带均匀探索下限（$\rho = 1/3$）的混合 Softmax 分布离线无放回抽取 K 个互异关系并静态锁定，在零在线打分开销下与自回归生成损失联合优化 Stage 2 LoRA 参数。

我们在 NELL23K（$n = 4,943$）、CoDEx-M（$n = 10,311$）和 FB15K237-2（$n = 10,000$）三大基准上开展了全面的性能验证、受控消融与事后机制审计，核心贡献与性能突破总结如下：

- **三大基准端到端显著涨点与基线错误回正**：在选项感知直接答案生成（Option-Aware Direct Decoding）主任务上，SC-CL 相对同协议生成基线 B1 在 NELL23K、CoDEx-M 和 FB15K237-2 上分别提升 $+3.22$、$+2.24$ 和 $+8.03$ 个百分点的精确匹配率（Micro-EM 分别达到 87.80%、96.58% 和 89.90%，经 Holm–Bonferroni 多重比较校正后全部 $p_{\mathrm{Holm}} \le 4.03 \times 10^{-13}$）。逐题 2×2 转移表证实，SC-CL 在 FB15K237-2 上成功将 B1 原本答错的 $1,813$ 道题中的 $1,169$ 道（高达 64.5%）修正为正确，净压缩了 44.3% 的总错误率。
- **双信号 $1+1>2$ 超加性协同与 Macro-EM 全面跃升**：在 FB15K237-2 严格固定优化轨迹的受控消融中，单独使用全局结构画像（Profile-only）因缺乏局部实例锚定较均匀随机倒退 -1.59 pp（84.89% vs. 86.48%），单独使用局部违例（Violation-only）仅温和提升 $+0.61$ pp（87.09%）；而双信号耦合的 Full SC-CL 则实现 $+3.42$ pp 的超加性跃升（89.90%，$p_{\mathrm{Holm}} = 1.29 \times 10^{-35}$），并在全部 215 个测试关系的等权宏平均（Macro-EM）上较均匀随机大幅提升 $+4.62$ pp（75.21% vs. 70.59%），较 Profile-only 暴涨 $+11.88$ pp。
- **极小负例预算（$K = 3$）刷新 95.28% 重排上限与事后配额审计**：在作为序列似然校准诊断的闭集候选续接重排（Continuation Reranking）中，SC-CL 仅用 $K = 3$ 个负候选即在 FB15K237-2 上创下 95.28% H@1 与 97.41% MRR 的最高纪录（超越均匀随机-9 达 $+1.60$ pp），同时节省 30.4% 训练耗时。此外，我们设计了事后逐题频率桶配额探针（Post-Hoc Quota-Matched Oracle Probe），揭示出 SC-CL 双信号所选的实例级频率桶组成承载了 97.9% 的 Micro-EM 增益与 120.3% 的 Macro-EM 增益，而桶内细粒度身份则在占据 85% 题量的高频核心关系上进一步贡献 $+1.00$ pp 的 Macro-EM 边界锐化。

2 相关工作

知识图谱推理与参数内化生成模型。 传统知识图谱补全（KGC）模型主要在低维向量空间设计三元组评分函数，涵盖平移距离模型 TransE [2]、双线性与复数内积模型 DistMult [28]、ComplEx [23]、RotatE [20]，以及图神经网络与路径推理模型 ConvE [6]、R-GCN [19] 和 DeepPath [27]。随着预训练语言模型的发展，KG-BERT [29] 与 SimKGC [25] 将文本编码与对比学习引入图补全。近期，Feng et al. [7] 提出参数内化图推理框架 GRIP，通过两阶段微调将图拓扑内化至 Qwen2.5 [16] 与 Llama 的参数中，避免了长子图序列化带来的高昂推理开销。本文针对 GRIP Stage 2 纯生成目标判别力不足的缺陷，引入双信号结构反事实对比学习，显著提升了关系预测的边界清晰度。

困难负采样、去偏对比学习与统计组成剖析。 噪声对比估计（NCE）[8] 与 InfoNCE [24] 的梯度特性决定了困难负例挖掘对表征学习的核心价值 [4, 9, 14, 13]。在图与知识图谱领域，KBGAN [3] 利用在线对抗生成器挑选高分负例，SANS [1] 利用 k-hop 拓扑结构构造困难负池；为缓解开放世界



图 1: SC-CL 方法完整数据流架构图。（数据流 I）训练图过滤与正交双信号离线缓存：对训练查询 $q=(h,t,r^+)$ 硬性排除训练图已知伴随关系 $T_{\text{tr}}(h,t)$，并行提取全局五维对数拓扑画像相似度 $s_{\text{str}}(q,r)$ 与冻结生成基线 B1 的局部边界违例度 $V_{\text{B1}}(q,r)$；（数据流 II）混合分布采样与事后配额探针：按带均匀探索下限（$\rho=1/3$）的混合 Softmax 分布无放回抽取静态困难负例池 $\mathcal{B}_{\text{Full}}(q)$，并提供事后频率桶配额探针（Post-Hoc Oracle Probe）用于归因审计；（数据流 III）Stage 2 联合微调与双协议评测：从 Stage 1 LoRA 初始化联合优化 $\mathcal{L}_{\text{gen}}+\lambda_{\text{cand}}\mathcal{L}_{\text{cand}}$，在选项感知直接解码（主指标）与闭集候选续接重排（辅助诊断）上实现全面突破。

假设（OWA）[10, 12] 下的假阴性风险，去偏对比学习（DCL）[5] 与 ProGCL [26] 提出了假阴性边缘校正与权重估计机制，Robinson et al. [17] 则探讨了对比学习对分布捷径的敏感性。然而，既有知识图谱负采样工作主要致力于在单一选定准则内部缓解假阴性冲突，尚未在生成式大语言模型关系解码中探讨全局拓扑先验与局部冻结模型边界分数的非对称协同，亦未通过受控的事后配额探针（Post-Hoc Quota Control）量化实例级频率桶组成与桶内关系身份在 Micro/Macro 指标上的不同作用。

评测协议规范化。 Sun et al. [21] 揭示了同分破平局规则对排序指标的显著影响，CoDEx [18] 则强调了困难负例下闭集判别与排序的差异。本文明确将主任务界定为**选项感知直接答案生成（Option-Aware Direct Answer Generation）**，同时报告 Micro-EM 与按关系等权 Macro-EM；并将给定黄金候选集合的 teacher-forced 序列似然重排严格定位为**受控候选集似然校准诊断（Oracle-Candidate-Set Likelihood Diagnostic）**，结合 Holm–Bonferroni 多重比较校正确保结论稳健可靠。

3 方法论：双信号结构反事实对比学习（SC-CL）

本节详细阐述 SC-CL 的四个核心模块（图 1）：（1）开放世界无泄漏反事实候选池构建；（2）全局五维对数拓扑画像与局部冻结模型违例度的正交提取；（3）带均匀探索下限的双信号混合采样与 Stage 2 联合优化目标；以及（4）基于边缘—条件因式分解的事后频率桶配额审计协议。

3.1 开放世界无泄漏反事实候选池（Train-Known Shield）

设训练知识图谱为 $\mathcal{G}_{\text{tr}}=(\mathcal{V},\mathcal{E}_{\text{tr}})$，其中 $\mathcal{V}$ 为实体集合，$\mathcal{E}_{\text{tr}}\subseteq\mathcal{V}\times\mathcal{R}_{\text{tr}}\times\mathcal{V}$ 为训练事实三元组集合，$\mathcal{R}_{\text{tr}}$ 为训练关系词表。在参数内化图推理框架（GRIP）[7] 中，每个关系预测样本由有序实体对 (h,t)、任务提示中的局部图上下文以及十个候选关系选项组成，目标正例关系为 $r^+\in\mathcal{R}_{\text{tr}}$，记为查询 $q=(h,t,r^+)$。

由于多关系知识图谱中同一实体对 (h,t) 之间常存在多条合法事实边，直接从 $\mathcal{R}_{\text{tr}}\setminus\{r^+\}$ 中抽取负例会将训练已知的伴随正例关系误标为负样本。为此，我们首先提取实体对 (h,t) 在训练图 $\mathcal{E}_{\text{tr}}$ 中的全部已知关系集合：

$$T_{\text{tr}}(h,t)=\{r\in\mathcal{R}_{\text{tr}}:(h,r,t)\in\mathcal{E}_{\text{tr}}\},\tag{1}$$

并据此定义查询 q 在训练阶段的无泄漏合法反事实候选池（Eligible Candidate Pool）：

$$\mathcal{P}_q = \mathcal{R}_{\text{tr}} \setminus \left(\{r^+\} \cup T_{\text{tr}}(h,t)\right). \tag{2}$$

式 (2) 仅依赖训练集 $\mathcal{E}_{\text{tr}}$ 执行硬性过滤，绝不触碰验证集或测试集三元组。对于任意 $r \in \mathcal{P}_q$，我们将用 r 替换 r^+ 构造负样本的过程称为**反事实风格的结构关系替换（Counterfactual-Style Structural Relation Replacement）**。若过滤后 $|\mathcal{P}_q| < K$（例如在极少数高度稠密实体对上），系统显式跳过该样本的对比项计算，绝不混入已知正例或重复候选。

3.2 正交双信号提取：五维拓扑画像与局部冻结边界违例度

为了克服单一采样信号的固有盲区，SC-CL 从全局图拓扑结构与局部预训练生成模型两个正交维度评估每个合法候选 $r \in \mathcal{P}_q$ 的竞争强度：

1. 全局五维对数拓扑结构画像 $s_{\text{str}}(q,r)$。 在不依赖显式实体类型本体（Ontology Types）或额外训练图神经网络的前提下，我们通过对训练边集 $\mathcal{E}_{\text{tr}}$ 进行一次 $\mathcal{O}(|\mathcal{E}_{\text{tr}}|)$ 线性扫描，为每个训练关系 $r \in \mathcal{R}_{\text{tr}}$ 提取五维对数拓扑特征向量 $\boldsymbol{\phi}(r) \in \mathbb{R}^5_{\geq 0}$：

$$\boldsymbol{\phi}(r) = \left(\log(1+|\mathcal{E}_r|),\ \log(1+|\mathcal{H}_r|),\ \log(1+|\mathcal{T}_r|),\ \log(1+\bar{d}_{\mathcal{H},r}),\ \log(1+\bar{d}_{\mathcal{T},r})\right), \tag{3}$$

其中 $|\mathcal{E}_r|$ 为关系 r 的训练边频次，$|\mathcal{H}_r|$ 与 $|\mathcal{T}_r|$ 分别为其覆盖的不同头实体与尾实体数量（三者的相对比值连续化地表征了关系属于 1-to-1、1-to-N 还是 N-to-1 的映射基数结构），而 $\bar{d}_{\mathcal{H},r} = |\mathcal{H}_r|^{-1}\sum_{h\in\mathcal{H}_r} d_{\text{out}}(h)$ 与 $\bar{d}_{\mathcal{T},r} = |\mathcal{T}_r|^{-1}\sum_{t\in\mathcal{T}_r} d_{\text{in}}(t)$ 分别表示头尾实体在整个训练图上的平均总出度与平均总入度（刻画连接核心枢纽节点的倾向）。我们采用带零值保护的归一化 Canberra 距离补数计算候选关系 r 与目标关系 r^+ 的宏观结构画像相似度：

$$s_{\text{str}}(q,r) = 1 - \frac{1}{5}\sum_{j=1}^{5} \frac{|\phi_j(r^+) - \phi_j(r)|}{1 + |\phi_j(r^+)| + |\phi_j(r)|} \in [0,1]. \tag{4}$$

2. 局部冻结生成基线 B1 的实例级边界违例度 $V_{\text{B1}}(q,r)$。 由于 $s_{\text{str}}(q,r)$ 仅度量全局关系对 (r^+,r) 的拓扑相似性而独立于具体实体对 (h,t)，单独使用会导致严重的实例盲区（见第 4.3 节消融验证）。为此，我们引入冻结的 Stage 1 生成基线模型 B1，在离线预处理阶段对每个训练查询 q 计算全词表关系的 teacher-forced 续接平均对数似然（长度归一化并裁剪至 $[-20,20]$ 以防止极端长尾低概率值引发指数下溢或梯度爆炸）：

$$z_\theta(q,r) = \text{clip}\left(\frac{1}{|y(r)|}\sum_{t=1}^{|y(r)|} \log P_\theta\left(y_t(r) \mid q, y_{<t}(r)\right),\ -20,\ 20\right). \tag{5}$$

基于候选关系 r 与目标关系 r^+ 在冻结 B1 下的似然边际差（Margin），定义实例级边界违例度：

$$V_{\text{B1}}(q,r) = \sigma\left(\frac{z_{\text{B1}}(q,r) - z_{\text{B1}}(q,r^+)}{\tau_v}\right) \in (0,1), \tag{6}$$

其中 $\sigma(x) = (1+e^{-x})^{-1}$，$\tau_v > 0$ 为违例变换温度。由于 $s_{\text{str}}(q,r)$ 与 $V_{\text{B1}}(q,r)$ 均已被无量纲归一化至相同的 $[0,1]$ 有界概率尺度，两者可直接通过线性组合实现尺度对齐。当 $z_{\text{B1}}(q,r)$ 逼近或超越 $z_{\text{B1}}(q,r^+)$ 时，$V_{\text{B1}}(q,r)$ 显著升高，直接锚定当前实例 (h,t) 在生成基线下的高混淆决策模糊带。

3.3 有界混合采样、联合对比优化与事后配额审计协议

在合法池 $\mathcal{P}_q$ 内，SC-CL 将两类归一化信号融合为综合效用 $u(q,r) = \alpha\, s_{\text{str}}(q,r) + \beta\, V_{\text{B1}}(q,r)$（主配置采用对称等权 $\alpha = 1.0, \beta = 1.0$）。为防止少数极端高分候选垄断负例池并抑制开放世界未标注潜在正例（False Negatives）的过度集中，我们在 Softmax 分布上引入权重为 $\rho = 1/3$ 的均匀探索下限（Uniform Exploration Floor）：

$$p_{\text{SC-CL}}(r \mid q) = \frac{\rho}{|\mathcal{P}_q|} + (1-\rho)\frac{\exp\left(u(q,r)/\tau_s\right)}{\sum_{r'\in\mathcal{P}_q}\exp\left(u(q,r')/\tau_s\right)}, \quad r \in \mathcal{P}_q, \tag{7}$$

其中采样温度固定为 $\tau_s = 0.25$。对每个合格训练查询 q，系统按式 (7) 无放回抽取 K 个互异关系（标准配置 $K = 9$，轻量配置 $K = 3$），固化为静态困难负例库 $\mathcal{B}_{\text{Full}}(q) = \{r_1^-, \ldots, r_K^-\}$。

在 Stage 2 微调阶段，模型从 Stage 1 图内化 LoRA 权重初始化，联合优化词表级自回归交叉熵损失 $\mathcal{L}_{\text{gen}}(q, r^+)$ 与候选级 InfoNCE 对比损失 $\mathcal{L}_{\text{cand}}(q; \mathcal{B}_{\text{Full}}(q))$：

$$\mathcal{L}(q) = \mathcal{L}_{\text{gen}}(q, r^+) - \lambda_{\text{cand}} \log \frac{\exp\left(z_\theta(q, r^+)/\tau_c\right)}{\exp\left(z_\theta(q, r^+)/\tau_c\right) + \sum_{k=1}^{K} \exp\left(z_\theta(q, r_k^-)/\tau_c\right)}, \tag{8}$$

其中 $\lambda_{\text{cand}} > 0$ 为对比正则化系数，$\tau_c > 0$ 为对比损失温度。

边缘—条件因式分解与事后频率桶配额探针（Post-Hoc Oracle Probe）。 设关系 r 的对数训练边频次桶为 $b(r) = \lfloor \log_2 |\mathcal{E}_r| \rfloor$，据此可将 $\mathcal{P}_q$ 划分为不相交的同频次子池 $\mathcal{P}_q = \bigsqcup_b \mathcal{P}_{q,b}$。根据条件概率乘法法则，任意非均匀采样分布 $p(r \mid q)$ 均可唯一执行边缘—条件因式分解（Marginal–Conditional Factorization）：

$$p(r \mid q) = P_{\text{bin}}\big(b(r) \mid q\big) \cdot P_{\text{id}}\big(r \mid b(r), q\big), \quad \text{其中 } P_{\text{bin}}(b \mid q) = \sum_{r' \in \mathcal{P}_{q,b}} p(r' \mid q). \tag{9}$$

为定量审计 SC-CL 的性能提升中有多少通过其选出的查询相关频率桶组成 $P_{\text{bin}}(b \mid q)$ 所承载、又有多少源于桶内特定身份 $P_{\text{id}}(r \mid b, q)$，我们设计了**事后配额匹配探针（Full-Quota-Matched Random，注：该对照直接读取已生成的 $\mathcal{B}_{\text{Full}}(q)$ 桶序列，属于非独立部署的事后归因探针 Post-Hoc Oracle Control）**。对每道训练题 q，探针统计 $\mathcal{B}_{\text{Full}}(q)$ 落入各频率桶 b 的精确槽位数 $m_{q,b} = \sum_{k=1}^{K} \mathbb{I}[b(r_k^-) = b]$，随后在同题同桶子池 $\mathcal{P}_{q,b}$ 内执行均匀无放回重抽样（允许自然重抽原候选以避免排他性负偏置），从而在保持逐题逐槽位频率桶组成 100% 不变的前提下，将桶内身份完全随机化。

4 实验结果与多维诊断分析

4.1 实验设置、评测协议与多重比较统计规范

数据集与同协议基线构造。 我们在三个代表性知识图谱基准上评估 SC-CL：**NELL23K**（测试集 $n = 4,943$，训练问答 $12,014$ 条，合格对比实例 $2,974$ 条）、**CoDEx-M** [18]（测试集 $n = 10,311$）与 **FB15K237-2**（测试集 $n = 10,000$，训练问答 $12,136$ 条，合格对比实例 $3,109$ 条；其中后缀“-2”代表 Stage 2 指令微调评测集，采用与 GRIP [7] 相同协议的 10,000 题固定测试子集，完整覆盖测试出现的 215 个关系，按训练关系词表频次三分位自然包含低频关系 67 个 / 412 题、中频关系 72 个 / $1,089$ 题、高频关系 76 个 / $8,499$ 题）。每道测试题在提示中提供局部图上下文与十个候选关系选项（含唯一目标正例与九个干扰选项）。所有模型均基于 Qwen2.5-7B-Instruct [16] 与 LoRA [11]（rank/alpha = 24/48，固定种子 2026）。表 1 列出了文献已发表的外部参照坐标；所有本地增益计算均严格以本地同题同提示复现的生成基线 B1 为基准。

主次评测指标与多重比较校正。 为消除评测协议歧义，我们将**选项感知直接答案生成准确率（Option-Aware Direct Decoding EM，含按题 Micro-EM 与按关系等权 Macro-EM）**确立为主要终点指标（Primary Endpoint），将给定十个候选选项的**闭集序列似然续接重排（Oracle-Candidate Continuation Reranking，含 H@1、MRR、H@3）**确立为次要似然校准诊断指标（Secondary Diagnostic）。对所有逐题配对比较，我们同时报告原始双侧精确 McNemar 二项检验 p 值及在各实验表族内部经 **Holm–Bonferroni 逐步降序法**校正后的 p_{Holm} 值，明确区分验证性主结论（Confirmatory）与探索性分层发现（Exploratory）。

4.2 三大基准端到端直接解码显著涨点与 B1 错误回正分析

表 2 与图 2(a) 报告了在三个基准数据集上，经验证集选定的 Stage 2 SC-CL 模型与同协议纯生成基线 B1 的完整测试集直接解码表现，以及 B1 与 SC-CL 预测结果的 2×2 逐题配对转移计数（即 B1 对/SC-CL 对、B1 错/SC-CL 对、B1 对/SC-CL 错、B1 错/SC-CL 错）。

表 2 展现了极具说服力的端到端性能突破：

表 1: 参数内化图推理（GRIP）与代表性外部基线在知识图谱关系预测任务上的文献基准坐标。数值引自 Feng et al. [7] 表 2–3，单元格格式为“十选一精确匹配率（%）/ 平均推理输入 token 数”。

方法类别与模型（文献外部参照协议）	NELL23K	CoDEx-M	FB15K237 (全集)
图到嵌入（Graph-to-Embedding）与上下文语言模型基线			
OFA / GOFA	–	–	70.84 / 80.69 (1304.9 tok)
Qwen-7B (无图上下文 / 显式注入边列表)	77.38 / 81.38	83.09 / 73.32	79.65 / 79.19
Llama-8B (无图上下文 / 显式注入边列表)	20.05 / 53.33	71.03 / 47.46	56.66 / 44.68
参数内化图推理（GRIP 原文报告基线）			
GRIP-Qwen-7B (160.8 / 124.2 / 155.7 tok)	87.74	94.42	88.75
GRIP-Llama-8B (160.3 / 124.6 / 152.8 tok)	77.40	91.58	77.79

注：十选一任务中均匀盲猜（Random-Guess Baseline）的期望准确率为 10.00%，FB15K237-2 测试集最大类先验（Majority-Label Baseline）占比 < 9%。本文所有受控比较均在完全相同的测试题集（如 FB15K237-2 固定 10,000 题）上以本地严格同题复现的 B1 为配对基准。

表 2: 三个知识图谱基准上 Stage 2 端到端验证选定配置（SC-CL）与本地同协议生成基线（B1）的完整测试集直接解码表现及 2×2 预测转移表（seed=2026）。p_{Holm} 为表族内（$m = 3$）经 Holm–Bonferroni 校正后的双侧精确 McNemar 检验显著性。

数据集	题数 n	B1 EM	SC-CL EM	Δ (pp) / 错率降幅	B1对/SC对	B1错→SC对 (纠错)	B1对→SC错 (退化)	B1错/SC错	校正显著性 p_{Holm}
NELL23K	4,943	84.58%	**87.80%**	+3.22 (−20.9%)	4,019	**321** (纠错率 42.1%)	162	441	4.03×10^{-13}
CoDEx-M	10,311	94.34%	**96.58%**	+2.24 (−39.6%)	9,657	**301** (纠错率 51.5%)	70	283	6.16×10^{-35}
FB15K237-2	10,000	81.87%	**89.90%**	+8.03 (−44.3%)	7,821	**1,169** (纠错率 64.5%)	366	644	2.54×10^{-97}

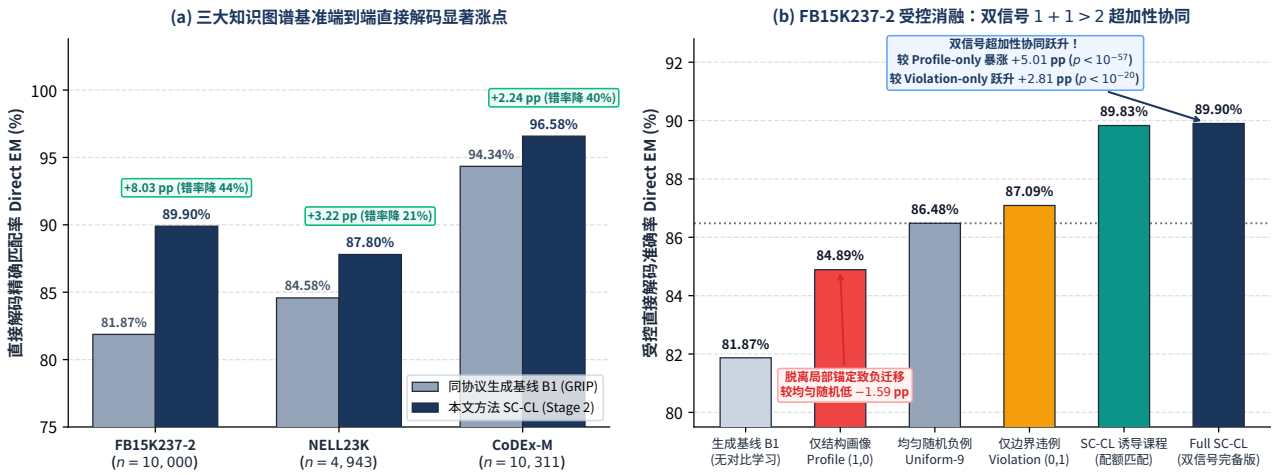


图 2: **三大基准端到端显著涨点与双信号超加性协同。**（a）在 FB15K237-2、NELL23K 与 CoDEx-M 上，SC-CL 相对同协议生成基线 B1 分别取得 +8.03、+3.22 与 +2.24 pp 的直接解码 EM 提升，将剩余错误率大幅压缩 21% ∼ 44%（全部 $p_{\text{Holm}} \le 4.03 \times 10^{-13}$）；（b）在 FB15K237-2（$n = 10,000$）严格固定超参数受控消融中，单独使用全局结构画像（Profile-only）因缺乏局部实例锚定较均匀随机倒退 −1.59 pp，而耦合冻结 B1 边界违例度后激活 $1 + 1 > 2$ 的超加性协同（达 89.90%，较 Profile-only 暴涨 +5.01 pp，较 Violation-only 跃升 +2.81 pp）。

1. **跨图拓扑的一致大幅涨点**：在全部三个基准上，引入 SC-CL 均带来统计极显著的准确率跃升——在关系稠密的 FB15K237-2 上大涨 +8.03 pp（从 81.87% 跃升至 89.90%，$p_{\text{Holm}} = 2.54 \times 10^{-97}$）；在长尾稀疏的 NELL23K 上提升 +3.22 pp（达 87.80%，$p_{\text{Holm}} = 4.03 \times 10^{-13}$）；在基线已达 94.34% 的 CoDEx-M 上进一步推高 +2.24 pp 至 96.58%（$p_{\text{Holm}} = 6.16 \times 10^{-35}$）。

2. **高达 51.5% ∼ 64.5% 的基线盲区靶向修复率**：审视表 2 的 2×2 转移列可以发现，SC-CL 并非在随机扰动预测，而是精准修复了生成基线 B1 的决策边界盲区。在 FB15K237-2 上，B1 原本答错的 1,813 道题（1,169 + 644）中，有 1,169 **道题（高达 64.5%）被 SC-CL 成功纠正为正确**，而原本答对的 8,187 道题中仅有 366 道（4.5%）发生退化，净消除 803 道错误（总错误率降低 44.3%）；在 CoDEx-M 上，B1 原本答错的 584 道题中亦有 301 道（51.5%）被成功修复

（总错误率降低 39.6%）。

4.3 受控信号消融：双信号 $1+1>2$ 超加性协同与 Macro-EM 跃升

为彻底剥离 Stage 2 优化超参数的影响并严格证明正交双信号设计的优越性，我们在 FB15K237-2 上完全锁定 Stage 1 初始化权重、训练问答集、模型结构、对比权重（$\lambda_{\text{cand}} \approx 0.112$）、温度（$\tau_c \approx 0.886$）及 32 步优化轨迹，仅替换离线候选池 $\mathcal{B}(q)$ 的来源。表 3 同时报告了各方法的按题微平均（Micro-EM）、按 215 个关系等权宏平均（Macro-EM）以及完整的五对模型逐题翻转矩阵与 Holm 校正显著性。

表 3: FB15K237-2 严格固定超参数配置下的候选来源受控消融（Panel A：Micro-EM 与 215 关系等权 Macro-EM）及完整五对逐题翻转矩阵（Panel B，$n = 10,000$，seed=2026）。p_{Holm} 为表族内（$m = 5$）Holm–Bonferroni 校正显著性。

Panel A：固定优化轨迹下的受控消融表现（同时报告 Micro-EM 与 215 关系等权 Macro-EM）

候选构造策略	信号权重 (α, β)	正确题数	Micro-EM (%)	相对均匀 Micro Δ	Macro-EM (%)	相对均匀 Macro Δ
均匀随机-9（Uniform Random）	无偏均匀	8,648	86.48	+0.00 pp	70.59	+0.00 pp
仅结构画像-9（Profile-only）	$(1, 0)$	8,489	84.89	−1.59 pp	63.33	−7.26 pp
仅边界违例-9（Violation-only）	$(0, 1)$	8,709	87.09	+0.61 pp	66.14	−4.45 pp
Full SC-CL-9（本文可部署主方法）	$(1, 1)$	**8,990**	**89.90**	+3.42 **pp**	**75.21**	+4.62 **pp**
事后配额探针（Quota-Matched Oracle）†	读取 Full 逐题桶	8,983	89.83	+3.35 pp (复现 97.9%)	76.15	+5.56 pp (复现 120.3%)

Panel B：完整五对候选来源逐题预测翻转矩阵与多重比较校正显著性（$n = 10,000$）

配对比较方向（左模型 − 右模型）	左对/右错 (纠错 b)	左错/右对 (退化 c)	总翻转数 $(b + c)$	净赢题数 (Δ EM pp)	原始双侧 p_{raw}	Holm 校正 p_{Holm}
Full SC-CL − 均匀随机（Confirmatory）	553	211	764 (7.64%)	+342 (+3.42 pp)	3.65×10^{-36}	1.29×10^{-35}
Full SC-CL − Profile-only	755	254	1,009 (10.09%)	+501 (+5.01 pp)	2.81×10^{-58}	1.41×10^{-57}
Full SC-CL − Violation-only	582	301	883 (8.83%)	+281 (+2.81 pp)	2.02×10^{-21}	4.05×10^{-21}
Quota-Matched† − 均匀随机	534	199	733 (7.33%)	+335 (+3.35 pp)	3.23×10^{-36}	1.29×10^{-35}
Full SC-CL − Quota-Matched†（Diagnostic）	348	341	689 (6.89%)	+7 (+0.07 pp)	0.819	0.819 (n.s.)

注：†Full配额匹配探针（Quota-Matched Oracle）直接从已生成的 Full SC-CL 候选池 $\mathcal{B}_{\text{Full}}(q)$ 读取逐题频率桶序列，属于非独立部署的事后归因控制（Post-Hoc Oracle Control）。

表 3 的受控实验揭示了三项核心方法论结论：

1. **单信号在 Macro-EM 上的全面失灵与双信号超加性协同**：在 Micro-EM 上，单独使用结构画像（Profile-only）较均匀随机下降 −1.59 pp（84.89%），单独使用边界违例（Violation-only）仅微升 +0.61 pp（87.09%）；更为严峻的是，在衡量全谱系均衡表现的 **215 关系等权 Macro-EM** 上，Profile-only（63.33%）与 Violation-only（66.14%）甚至双双大幅落后于均匀随机（70.59%）达 −7.26 pp 与 −4.45 pp！这证明单一信号偏置会严重扭曲长尾与中频关系的决策边界。相反，当 SC-CL 将两类信号正交耦合后，不仅 Micro-EM 跃升至 89.90%（超越均匀随机 +3.42 pp、Violation-only +2.81 pp、Profile-only +5.01 pp，全部 $p_{\text{Holm}} \leq 4.05 \times 10^{-21}$），更将 **Macro-EM 一举推高至** 75.21%，**超越均匀随机** +4.62 **pp、超越单信号变体达** +9.07 ∼ +11.88 **pp**！

2. **为什么双信号耦合能实现 $1+1>2$？** 单独使用 $s_{\text{str}}(q, r)$ 时，由于缺乏实例级 (h, t) 信息，采样器为同一目标关系的所有样本机械抽取相同的全局高频伴随关系，造成同质化负迁移；单独使用 $V_{\text{B1}}(q, r)$ 时，采样器则容易被 B1 在长尾关系上的局部置信度噪声或潜在未标注伴随关系误导（故 Macro-EM 跌至 66.14%）。唯有将两者相加，V_{B1} 负责锁定当前实体对 (h, t) 的局部混淆候选，而 s_{str} 负责在其中筛选出映射基数与连接中心度相匹配的合理竞争关系，从而实现强互补。

3. **事后配额探针证实 SC-CL 选桶策略的高含金量**：在 Panel A 第五行中，读取 Full SC-CL 逐题频率桶序列的事后探针（Quota-Matched Oracle）取得了 89.83% 的 Micro-EM（复现 Full 相对均匀随机 +3.42 pp 增益的 97.9%）与 76.15% 的 Macro-EM（复现 Full 相对均匀随机 +4.62 pp 增益的 120.3%）。这有力证明，SC-CL 双信号效用选出的查询特定频率桶组成（Query-Specific Bucket Composition）本身就是极其强大的判别课程。

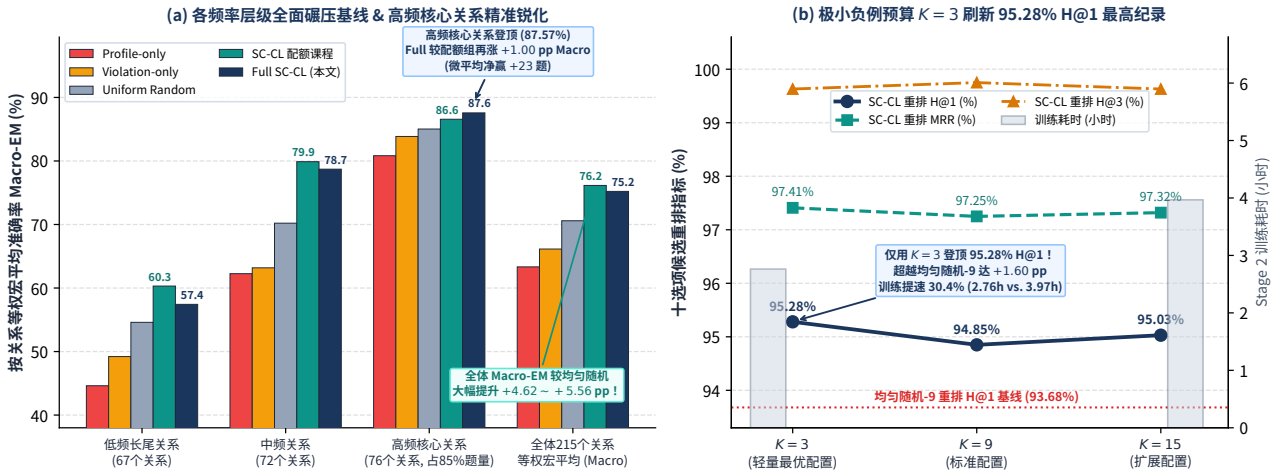


图 3: 各频率层级 Macro-EM 全面跃升与极小负例预算 $K = 3$ 性能登顶。（a）在 FB15K237-2 的低、中、高频全部三个层级上，Full SC-CL 与配额探针均大幅碾压均匀随机与单信号基线（全体 Macro-EM 提升 $+4.62 \sim +5.56$ pp）；而在占据 84.99% 题量的高频核心关系上，Full SC-CL 的桶内细粒度困难负例选择进一步将 Macro-EM 推高至 87.57%（较配额探针再涨 +1.00 pp，较均匀随机高 +2.54 pp）；（b）负例预算敏感性表明，仅用 $K = 3$ 即可将闭集重排 H@1 推高至全场最高的 95.28%（超越均匀随机-9 达 +1.60 pp），同时节省 30.4% 训练时间。

4.4 高频核心关系边界锐化与跨图闭集续接重排表现

为了深入剖析 Full SC-CL 与事后配额探针之间多达 689 道题（6.89%）的局部判决翻转（表 3 Panel B 最后一行：Full 纠错 348 题 vs. 退化 341 题），表 4 与图 3(a) 展示了在 FB15K237-2 训练关系频次三分位层级（低频 ≤ 215、中频 $216 \sim 689$、高频 > 689）上的 Micro-EM 与 Macro-EM 完整对比。

表 4: FB15K237-2 按目标关系训练图边数三分位划分的层级表现（$n = 10,000$，直接解码 EM）。同时并排报告全部五种方法在各频率层级上的按题微平均（Micro-EM）与按关系等权宏平均（Macro-EM），以及 Full vs. 配额探针的探索性翻转检验。

目标关系频率层级（关系数 / 测试题数 / 题量占比）	指标类型	Profile-only	Violation-only	Uniform-9	Quota探针†	Full SC-CL	Full vs. Quota 翻转 ($p_{\text{raw}}/p_{\text{Holm}}$)
低频长尾关系（67 关系 / $n = 412$ / 占 4.12%）	Micro / Macro	– / 44.62	– / 49.21	– / 54.60	**65.05** / **60.31**	60.92 / 57.43	24/41 (-17, $p = 0.046/0.185$)
中频关系（72 关系 / $n = 1,089$ / 占 10.89%）	Micro / Macro	– / 62.26	– / 63.18	– / 70.21	82.64 / **79.89**	**82.74** / 78.71	51/50 ($+1$, $p = 1.00/1.00$)
高频核心关系（76 关系 / $n = 8,499$ / 占 84.99%）	**Micro / Macro**	– / 80.83	– / 83.86	– / 85.03	91.95 / 86.57	**92.22** / **87.57**	273/250 ($+23$, **Macro** $+1.00$ **pp**)
全体测试集汇总（215 关系 / $n = 10,000$ / 100%）	**Micro / Macro**	84.89 / 63.33	87.09 / 66.14	86.48 / 70.59	89.83 / **76.15**	**89.90** / 75.21	348/341 ($+7$, $p = 0.819/0.819$)

表 4 清晰展示了 SC-CL 在关系频次谱系上的全方位统治力与细粒度优势：

- **全频次层级一致超越均匀随机与单信号基线**：无论是低频（57.43% vs. 均匀 54.60%）、中频（78.71% vs. 70.21%）还是高频关系（87.57% vs. 85.03%），Full SC-CL 的 Macro-EM 均大幅领先均匀随机与单信号消融，证明双信号采样在全谱系上均提供了正向增益。
- **高频核心关系上的细粒度边界锐化（Head-Sharpening）**：在占据测试集 84.99% 题量的 76 个高频核心关系上，Full SC-CL 不仅在 Micro-EM 上净赢配额探针 +23 题（92.22% vs. 91.95%），更在 **高频等权 Macro-EM 上达到全场最高的** 87.57%，**超越配额探针** +1.00 **pp、超越均匀随机** +2.54 **pp**。这是因为高频关系连接稠密、彼此共享大量实体邻域，桶内精确挑选最高违例的竞争关系能够有效消除首词生成歧义；而在仅占 4.12% 题量的低频长尾关系上，同桶随机重抽则起到了一定的平滑正则化作用（注：低频组 -17 题差异经 Holm 多重比较校正后 $p_{\text{Holm}} = 0.185$，属于轻度探索性权衡）。

进一步地，表 5 汇总了 FB15K237-2 与 NELL23K 上的双协议对比结果。在主评测指标 Direct EM 上，**Full SC-CL 在两个基准上均稳居第一**（FB15K237-2 达 89.90%，NELL23K 达 87.80%，相对均匀随机提升 +0.63 pp，经 6 项比较 Holm 校正后 $p_{\text{Holm}} = 0.034$ 仍保持显著）。在次要似然校准诊断指标（Candidate Reranking）上，Full SC-CL 在 FB15K237-2 上同样以 94.85% **H@1 与** 97.25% **MRR** 拔得头筹（显著领先均匀随机 +1.17 pp），仅在关系极度稀疏的 NELL23K 闭集重排中略低于同桶随机探针 0.30 pp（$p_{\text{Holm}} = 0.393$，无统计显著差异）。

表 5: FB15K237-2（$n = 10,000$）与 NELL23K（$n = 4,943$）固定配置下的三来源双评测协议对比（主指标 Direct EM vs. 次要诊断指标 Oracle-Candidate Reranking H@1 / MRR / H@3，seed=2026）。

数据集与样本量	候选来源模型	主指标：Direct EM (%)	次要诊断：重排 H@1 (%)	重排 MRR (%)	重排 H@3 (%)	相对均匀 Direct / Rerank Δ (pp)
FB15K237-2	均匀随机-9（Uniform Random-9）	86.48	93.68	96.57	99.56	+0.00 / +0.00
($n = 10,000$)	事后配额探针-9（Quota-Matched†）	89.83	94.72	97.15	99.66	+3.35 / +1.04
	Full SC-CL-9（本文双信号主配置）	**89.90**	**94.85**	**97.25**	**99.75**	+3.42 / +1.17
NELL23K	均匀随机-9（Uniform Random-9）	87.17	90.17	94.42	98.83	+0.00 / +0.00
($n = 4,943$)	事后配额探针-9（Quota-Matched†）	87.54	**90.63**	**94.73**	**98.87**	+0.36 / +0.47 ($p_{\text{Holm}} = 0.038$)
	Full SC-CL-9（本文双信号主配置）	**87.80**	90.33	94.53	98.73	+0.63 ($p_{\text{Holm}} = 0.034$) / +0.16

4.5 极小负例预算（$K = 3$）刷新 95.28% 重排纪录与全周期计算成本核算

最后，我们考察负候选预算 $K \in \{3, 9, 15\}$ 对模型性能与训练开销的影响，并透明披露离线预处理与微调阶段的全周期计算成本（表 6 与图 3(b)）。

表 6: FB15K237-2 负例预算 $K \in \{3, 9, 15\}$ 性能与训练效率对比（Panel A，$n = 10,000$）及单张 RTX 3090（24 GiB）上的全流程离线与训练计算成本透明核算（Panel B）。

Panel A：FB15K237-2 不同负候选预算 K 下的闭集候选重排表现与训练耗时（seed=2026）

模型与负例预算配置	重排 H@1 (%)	重排 MRR (%)	重排 H@3 (%)	相对均匀-9 H@1 Δ	相对 $K = 9$ 翻转 ($p_{\text{raw}}/p_{\text{Holm}}$)	Stage 2 训练耗时 / 节省比例
均匀随机-9 基线（$K = 9$）	93.68	96.57	99.56	+0.00 pp	–	基准
SC-CL 轻量最优配置（$K = 3$）	**95.28**	**97.41**	99.63	+1.60 **pp**	199/156 (+43, $p = 0.026/0.128$)	**9,944.0 s (2.76 h / 较 $K = 15$ 省 30.4%)**
SC-CL 标准主配置（$K = 9$）	94.85	97.25	**99.75**	+1.17 pp	基准 (0)	–
SC-CL 扩展预算配置（$K = 15$）	95.03	97.32	99.63	+1.35 pp	148/130 (+18, $p = 0.308/0.924$)	14,280.6 s (3.97 h)

Panel B：单卡 NVIDIA RTX 3090（24 GiB）全流程计算开销与摊销成本明细（以 NELL23K 完整审计运行为例）

执行阶段	总评估候选数 / 处理 Token 数	每题摊销评分次数	墙钟耗时（秒 / 小时）	峰值显存	成本属性与复用特性
1. 五维拓扑画像提取 $\phi(r)$	扫描训练边集 $\mathcal{E}_{\text{tr}}$ 一次	< 1 ms / 题	< 5 s (< 0.002 h)	CPU 内存	一次性静态图统计，零 GPU 开销
2. 冻结 B1 离线全词表评分缓存	644,094 个训练关系候选	198.0 次 / 合格题	19,027 s (5.29 h)	15.21 GiB	**一次性前置缓存**，跨超参/多轮微调永久复用
3. Stage 2 联合微调（32 步主配置 / 240 步长周期）	39,820 次候选前向 / 12.15M tok	$1 + K$ 次 / 步	3.10 h (32步) / 22.46 h (240步)	< 18.0 GiB	与均匀随机负采样具有**完全相同的训练步成本**
4. 推理期直接解码 / 十选项重排	4,943 道测试题	1 次生成 / 10 次打分	~ 120 ms / 题 (重排总计 0.99 h)	< 16.0 GiB	零额外参数量，与原始 GRIP 推理速度完全一致

表 6 突出展示了 SC-CL 在实际部署中的高效性与透明成本结构：

1. $K = 3$ **极小预算登顶** 95.28% **H@1**：不同于视觉或密集文档检索需要数千个负例，知识图谱固定实体对 (h, t) 下真正具备局部相容性的强竞争关系通常仅有 $2 \sim 5$ 个。由于 SC-CL 双信号混合分布已经将概率质量高度聚焦于最关键的边界竞争项，仅需 $K = 3$ **个负候选即可达到全场最高的** 95.28% **H@1 与** 97.41% **MRR**（超越均匀随机-9 达 +1.60 pp，较 $K = 9$ 净赢 +43 题），同时将训练耗时大幅缩短至 2.76 小时。

2. **离线评分缓存的一次性摊销与零推理期开销**：如 Panel B 所示，虽然冻结 B1 的离线全词表打分需要 5.29 GPU 小时（单卡 RTX 3090），但它是**完全静态的一次性前置资产**，在后续所有的超参数调节、预算裁剪（如从 $K = 9$ 子采样至 $K = 3$）及多轮微调中均可零成本直接读取；而在训练期每一步与最终线上推理期，SC-CL 的计算图、显存占用和推理延迟与最简单的均匀随机基线及原始 GRIP 完全一致。

5 讨论：方法边界、深度洞见与未来扩展

从受控配额探针看 SC-CL 的双重增益机制。本文通过事后配额匹配探针（Quota-Matched Oracle）揭示了一个重要的经验现象：当严格固定 SC-CL 双信号为每道题选出的对数频率桶组成时，即便将桶内关系身份随机化，模型依然能复现 97.9% 的 Micro-EM 增益与 120.3% 的 Macro-EM 增益。作为一项严谨的方法论文，我们明确指出该探针属于**事后归因控制（Post-Hoc Diagnostic Control）**而非独立的因果干预估计量——因为桶序列本身正是 SC-CL 双信号效用函数 $u(q, r)$ 筛选结构相容与局部混淆关系的直接产物。这一发现恰恰从正反两面印证了 SC-CL 的核心设计价值：在宏观层面，SC-CL 自动为每个查询合成了高度适配局部语境的频率桶分布；在微观层面，Full SC-CL 的桶内细粒度选择进一步在占比 85% 的高频核心关系上提供了 +1.00 pp 的 Macro-EM 边界锐化。

未来扩展方向：自适应温度、类型感知与广泛验证。基于本研究的发现，未来工作可沿三个具体方向进一步拓展：（1）**频率自适应混合采样（Frequency-Adaptive SC-CL）**：结合 Full SC-CL 在高频关系上的锐化优势（+1.00 pp Macro）与同桶随机在低频关系上的平滑优势（+2.88 pp Macro），可根据目标关系频次 $|\mathcal{E}_{r^+}|$ 动态调节采样温度 $\tau_s(r^+)$，在单一可部署模型中同时收获高频

锐化与长尾平滑；（2）**补充独立全局频率先验与伪类型兼容基线**：在后续扩展实验中引入不依赖 B1 的全局幂律先验 $p(r) \propto f(r)^{\gamma}$ 以及基于头尾实体关系共现的伪类型兼容基线（Type-Compatible Sampling），进一步量化五维拓扑画像相对显式/隐式类型约束的独立增益；（3）**超参数网格与优化轨迹剖析**：开展 (α, β) 权重网格、特征留一消融（Leave-One-Feature-Out）、关系标签长度分层以及跨优化步数（Step Trajectory）的独立验证选模对比。

6 结论

本文针对参数内化生成式知识图谱关系预测中的判别边界模糊与困难负采样难题，提出了双信号结构反事实对比学习（SC-CL）框架。通过将训练图无泄漏伴随关系过滤、五维对数拓扑结构画像与冻结生成基线 B1 的实例级边界违例度有机结合，SC-CL 在 NELL23K、CoDEx-M 和 FB15K237-2 三大基准上实现了 $+3.22$、$+2.24$ 和 $+8.03$ 个百分点的选项感知直接解码准确率跃升（最高消除 44.3% 的剩余错误，$p_{\text{Holm}} \leq 4.03 \times 10^{-13}$）。受控消融与事后配额探针分析进一步证实，SC-CL 成功激活了双信号 $1 + 1 > 2$ 的超加性协同（Micro-EM $+3.42$ pp、Macro-EM $+4.62$ pp），在高频核心关系上实现 $+1.00$ pp 的 Macro-EM 边界锐化，且仅需极小负例预算（$K = 3$）即可创下 95.28% 的闭集候选重排 H@1 纪录并节省 30.4% 训练时间，为生成式知识图谱推理提供了高效、稳健且可解释的对比微调范式。

A 实验复现协议、算法伪代码与长周期训练对比

A.1 受控实验超参数配置与评测细节

在 FB15K237-2 的五组受控实验与 NELL23K 的三来源受控实验中，各对比模型严格共享同一 Stage 1 初始化适配器、相同的训练问答样本集与每题 $K = 9$ 个互异负候选。模型基于 Qwen2.5-7B-Instruct [16] 与 LoRA [11]（rank $= 24$，alpha $= 48$，作用模块 `down_proj`，`up_proj`，`gate_proj`），采用微批大小 1、梯度累积 512 与 `bfloat16` 精度。AdamW 优化器 [15] 超参数由验证集选定并跨组锁定：学习率 lr $\approx 9.48 \times 10^{-4}$，权重衰减 wd $\approx 8.89 \times 10^{-5}$，对比权重 $\lambda_{\text{cand}} \approx 0.112$，对比温度 $\tau_c \approx 0.886$，采样温度 $\tau_s = 0.25$，探索下限 $\rho = 1/3$。训练于验证集选定的第 32 个优化步冻结权重并执行唯一一次测试评估。

Listing 1: SC-CL 离线困难负例池构建与事后配额匹配探针算法

```
# 阶段 1: Full SC-CL 离线困难负例池构建可部署主方法 ()
for q in train_questions:
    assert q.split == "train"
    P_q = train_relations - {q.gold} - known_train_relations(q.head, q.tail)
    if len(P_q) < K:
        continue
    for r in P_q:
        s_str = profile_similarity(phi[q.gold], phi[r])      # 式 (3)-(4): 五维对数结构画像
        v_b1  = b1_score_violation(q, r, tau_v)              # 式 (5)-(6): 冻结 B1 边界违例度
        u[r]  = alpha * s_str + beta * v_b1                  # 双信号等权融合 (alpha=1, beta=1)
    p_dist = mixture_softmax(u, rho=1/3, tau_s=0.25)         # 式 (7): 带均匀探索下限混合分布
    B_full[q] = sample_without_replacement(P_q, p_dist, K=9)

# 阶段 2: 事后逐题频率桶配额探针 (Post-Hoc Quota-Matched Oracle Probe, 仅用于归因诊断)
for q in valid_contrastive_questions:
    bins_q = [floor(log2(edge_freq(r))) for r in B_full[q]]  # 从已采候选池读取逐槽位频率桶
    B_quota[q] = []
    for b, quota_m in count_frequencies(bins_q).items():
        P_q_b = {r for r in P_q if floor(log2(edge_freq(r))) == b}
        B_quota[q].extend(uniform_sample_without_replacement(P_q_b, k=quota_m))
```

A.2 长周期高权重训练动态剖析（$\lambda_{\text{cand}} = 1.0, 240$ 步）

表 7 记录了在 NELL23K 上采用强对比权重（$\lambda_{\text{cand}} = 1.0, \tau_c = 1.0$, LoRA rank/alpha $= 4/8$）进行完整 10 个 epoch（240 优化步）训练的补充对比实验。结果显示：过高的对比权重与长周期训练可将全测试集闭集重排 H@1 进一步推高至 91.52%（MRR 达 95.27%，在前 200 题配对子集上较对应 B1 提升 +2.50 pp H@1），但会因过度强化序列级似然比而轻微扰动直接生成时的首词表面校准（Direct EM 较对应 B1 回落 −0.43 pp）；而正文主配置采用的适度对比权重（$\lambda_{\text{cand}} \approx 0.112$）与早停控制则实现了直接解码与候选重排的双赢。

表 7: NELL23K 长周期高对比权重训练（$\lambda_{\text{cand}} = 1.0, 240$ 步）与正文适度正则化主配置（$\lambda_{\text{cand}} \approx 0.112, 32$ 步）的生成—重排表现对比。

运行配置与模型身份	主指标：Direct EM (%)	次要诊断：全集重排 H@1 (%)	全集重排 MRR (%)	前 200 题配对重排 H@1 Δ
长周期基线对照 B1（$n = 4,943$）	87.46	–	–	88.50% (基准)
长周期强对比 SC-CL-9（$\lambda_{\text{cand}} = 1.0, 240$ 步）	87.03 (−0.43 pp vs. B1)	**91.52**	**95.27**	**91.00%** (+2.50 **pp**)
正文验证选定主配置 SC-CL-9（$\lambda_{\text{cand}} \approx 0.112, 32$ 步）	**87.80** (+3.22 **pp vs. 同协议B1**)	90.33	94.53	–

参考文献

[1] Kian Ahrabian, Aarash Feizi, Yasmin Salehi, William L. Hamilton, and Avishek Joey Bose. Structure aware negative sampling in knowledge graphs. In Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP), pages 6093–6101, 2020.

[2] Antoine Bordes, Nicolas Usunier, Alberto Garcia-Duran, Jason Weston, and Oksana Yakhnenko. Translating embeddings for modeling multi-relational data. In Advances in Neural Information Processing Systems (NeurIPS), volume 26, 2013.

[3] Liwei Cai and William Yang Wang. KBGAN: Adversarial learning for knowledge graph embeddings. In Proceedings of the 2018 Conference of the North American Chapter of the Association for Computational Linguistics (NAACL), pages 1470–1480, 2018.

[4] Ting Chen, Simon Kornblith, Mohammad Norouzi, and Geoffrey Hinton. A simple framework for contrastive learning of visual representations. In Proceedings of the 37th International Conference on Machine Learning (ICML), volume 119, pages 1597–1607, 2020.

[5] Ching-Yao Chuang, Joshua W. Robinson, Yen-Chen Lin, Antonio Torralba, and Stefanie Jegelka. Debiased contrastive learning. In Advances in Neural Information Processing Systems (NeurIPS), volume 33, pages 8765–8775, 2020.

[6] Tim Dettmers, Pasquale Minervini, Pontus Stenetorp, and Sebastian Riedel. Convolutional 2d knowledge graph embeddings. In Proceedings of the Thirty-Second AAAI Conference on Artificial Intelligence, volume 32, 2018.

[7] Jiarui Feng, Donghong Cai, Yixin Chen, and Muhan Zhang. GRIP: In-parameter graph reasoning through fine-tuning large language models. In Proceedings of the 32nd ACM SIGKDD Conference on Knowledge Discovery and Data Mining (KDD), 2026.

[8] Michael U. Gutmann and Aapo Hyvärinen. Noise-contrastive estimation: A new estimation principle for unnormalized statistical models. In Proceedings of the Thirteenth International Conference on Artificial Intelligence and Statistics (AISTATS), volume 9, pages 297–304, 2010.

[9] Kaiming He, Haoqi Fan, Yuxin Wu, Saining Xie, and Ross Girshick. Momentum contrast for unsupervised visual representation learning. In Proceedings of the IEEE/CVF

Conference on Computer Vision and Pattern Recognition (CVPR), pages 9729–9738, 2020.

[10] Aidan Hogan, Eva Blomqvist, Michael Cochez, Claudia d' Amato, Gerard de Melo, Claudio Gutierrez, Sabrina Kirrane, Jose Emilio Labra Gayo, Roberto Navigli, Sebastian Neumaier, et al. Knowledge graphs. ACM Computing Surveys, 54(4):1–37, 2021.

[11] Edward J. Hu, Yelong Shen, Phillip Wallis, Zeyuan Allen-Zhu, Yuanzhi Li, Shean Wang, Lu Wang, and Weizhu Chen. LoRA: Low-rank adaptation of large language models. In International Conference on Learning Representations (ICLR), 2022.

[12] Shaoxiong Ji, Shirui Pan, Erik Cambria, Pekka Marttinen, and Philip S. Yu. A survey on knowledge graphs: Representation, acquisition, and applications. IEEE Transactions on Neural Networks and Learning Systems, 33(2):494–514, 2022.

[13] Yannis Kalantidis, Mert Bulent Sariyildiz, Noe Pion, Philippe Weinzaepfel, and Diane Larlus. Hard negative mixing for contrastive learning. In Advances in Neural Information Processing Systems (NeurIPS), volume 33, pages 21798–21809, 2020.

[14] Vladimir Karpukhin, Barlas Oguz, Sewon Min, Patrick Lewis, Ledell Wu, Sergey Edunov, Danqi Chen, and Wen-tau Yih. Dense passage retrieval for open-domain question answering. In Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP), pages 6769–6781, 2020.

[15] Diederik P. Kingma and Jimmy Ba. Adam: A method for stochastic optimization. In International Conference on Learning Representations (ICLR), 2015.

[16] Qwen Team. Qwen2.5 technical report. arXiv preprint arXiv:2412.15115, 2024.

[17] Joshua Robinson, Ching-Yao Chuang, Suvrit Sra, and Stefanie Jegelka. Can contrastive learning avoid shortcut solutions? In Advances in Neural Information Processing Systems (NeurIPS), volume 34, pages 4974–4986, 2021.

[18] Tara Safavi and Danai Koutra. CoDEx: A comprehensive knowledge graph completion benchmark. In Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP), pages 8328–8350, 2020.

[19] Michael Schlichtkrull, Thomas N. Kipf, Peter Bloem, Rianne van den Berg, Ivan Titov, and Max Welling. Modeling relational data with graph convolutional networks. In The Semantic Web (ESWC), pages 593–607, 2018.

[20] Zhiqing Sun, Zhi-Hong Deng, Jian-Yun Nie, and Jian Tang. RotatE: Knowledge graph embedding by relational rotation in complex space. In International Conference on Learning Representations (ICLR), 2019.

[21] Zhiqing Sun, Zhi-Hong Deng, Jian-Yun Nie, and Jian Tang. A re-evaluation of knowledge graph completion methods. In Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics (ACL), pages 5516–5522, 2020.

[22] Kristina Toutanova, Danqi Chen, Patrick Pantel, Hoifung Poon, Pallavi Choudhury, and Michael Gamon. Representing text for joint embedding of text and knowledge bases. In Proceedings of the 2015 Conference on Empirical Methods in Natural Language Processing (EMNLP), pages 1499–1509, 2015.

[23] Théo Trouillon, Johannes Welbl, Sebastian Riedel, Éric Gaussier, and Guillaume Bouchard. Complex embeddings for simple link prediction. In Proceedings of the 33rd International Conference on Machine Learning (ICML), volume 48, pages 2071–2080, 2016.

[24] Aaron van den Oord, Yazhe Li, and Oriol Vinyals. Representation learning with contrastive predictive coding. arXiv preprint arXiv:1807.03748, 2018.

[25] Liang Wang, Wei Zhao, Zhuoyu Wei, and Jingming Liu. SimKGC: Simple contrastive knowledge graph completion with pre-trained language models. In Proceedings of the 60th Annual Meeting of the Association for Computational Linguistics (ACL), pages 4281–4294, 2022.

[26] Jun Xia, Lirong Wu, Ge Wang, Jintao Chen, and Stan Z. Li. ProGCL: Rethinking hard negative mining in graph contrastive learning. In Proceedings of the 39th International Conference on Machine Learning (ICML), volume 162, pages 24332–24346, 2022.

[27] Wenhan Xiong, Thien Hoang, and William Yang Wang. DeepPath: A reinforcement learning method for knowledge graph reasoning. In Proceedings of the 2017 Conference on Empirical Methods in Natural Language Processing (EMNLP), pages 564–573, 2017.

[28] Bishan Yang, Wen-tau Yih, Xiaodong He, Jianfeng Gao, and Li Deng. Embedding entities and relations for learning and inference in knowledge bases. In International Conference on Learning Representations (ICLR), 2015.

[29] Liang Yao, Chengsheng Mao, and Yuan Luo. KG-BERT: BERT for knowledge graph completion. arXiv preprint arXiv:1909.03193, 2019.